



UNIVERSIDAD NACIONAL
DE EDUCACIÓN A DISTANCIA

Escuela Técnica Superior de Ingeniería Informática

ANÁLISIS COMPARATIVO DE TÉCNICAS DE ANONIMIZACIÓN DE DATOS Y SU IMPACTO EN EL RENDIMIENTO Y LA ROBUSTEZ DE MODELOS DE INTELIGENCIA ARTIFICIAL

Alex Herrerías Ramírez

Director/a: Maria de los Llanos Tobarra

Trabajo de Fin de Máster

Máster Universitario
en Ingeniería y Ciencia de Datos

[Fecha de presentación/Convocatoria]

Agradecimientos

[Quisiera dedicar ...]

Resumen

El presente Trabajo Fin de Máster investiga el impacto de las técnicas de anonimización de datos sobre el rendimiento predictivo de modelos de inteligencia artificial en el ámbito sanitario. Partiendo de un conjunto de datos clínicos reales de más de 98.000 registros hospitalarios de pacientes diabéticos, se implementa un marco experimental que permite cuantificar el equilibrio entre la protección de la identidad del paciente y la utilidad analítica del dato.

El estudio aborda tres ejes fundamentales: la aplicación de privacidad sintáctica (k -anonimidad) mediante herramientas como ARX, la integración de Privacidad Diferencial en algoritmos clásicos de aprendizaje automático a través de la librería IBM Diffprivlib, y la evaluación de la robustez de los modelos resultantes frente a ataques de inferencia de membresía utilizando el Adversarial Robustness Toolbox. Los resultados se analizan no solo en términos de precisión global, sino también desde la perspectiva de la equidad algorítmica, evaluando si la degradación del rendimiento afecta de forma desproporcionada a grupos demográficos minoritarios. El trabajo concluye con un marco de recomendaciones prácticas para la selección de técnicas de anonimización en función del contexto regulatorio y el nivel de protección deseado.

Palabras clave: anonimización, privacidad diferencial, k -anonimidad, aprendizaje automático, equidad algorítmica, datos sanitarios

Abstract

This Master's Thesis investigates the impact of data anonymization techniques on the predictive performance of artificial intelligence models in the healthcare domain. Using a real clinical dataset comprising over 98,000 hospital records of diabetic patients, an experimental framework is implemented to quantify the trade-off between patient identity protection and analytical data utility.

The study addresses three fundamental axes: the application of syntactic privacy (k -anonymity) through tools such as ARX, the integration of Differential Privacy into classical machine learning algorithms via the IBM Diffprivlib library, and the evaluation of model robustness against membership inference attacks using the Adversarial Robustness Toolbox. Results are analyzed not only in terms of overall accuracy but also from the perspective of algorithmic fairness, assessing whether performance degradation disproportionately affects minority demographic groups. The work concludes with a practical recommendation framework for selecting anonymization techniques based on the regulatory context and desired level of protection.

Keywords: anonymization, differential privacy, k -anonymity, machine learning, algorithmic fairness, healthcare data

Índice general

1. Introducción	1
1.1. Motivación	1
1.2. Propuesta y objetivos	2
1.3. Estructura del documento	3
2. Estado del Arte	5
2.1. El Paradigma de la Privacidad en la Ciencia de Datos	5
2.1.1. Definición de Privacidad y Anonimización	5
2.1.2. El Dilema Privacidad frente a Utilidad	6
2.2. Privacidad Sintáctica y sus Variantes	7
2.2.1. El modelo de k -anonimidad	7
2.2.2. Vulnerabilidades y extensiones: l -diversidad y t -cercanía	7
2.3. Privacidad Semántica: Privacidad Diferencial	8
2.3.1. Paradigmas de aplicación: DP Local y DP Global	9
2.3.2. Privacidad Diferencial en el Aprendizaje Automático	9
2.4. Generación de Datos Sintéticos	10
2.5. Paradigmas Colaborativos: Aprendizaje Federado (FL)	10
2.6. Evaluación de Riesgos y Auditoría Algorítmica	11
2.6.1. Ataques a Modelos de Inteligencia Artificial	11
2.6.2. Impacto en la Equidad y Justicia Algorítmica	12
3. Materiales y Métodos	13
3.1. Entorno Experimental y Selección de Datos	13
3.1.1. Selección y Justificación del Conjunto de Datos	14
3.2. Ingesta y Preprocesamiento	15
3.3. Perfilado de Privacidad y Análisis de Riesgo Basal	16
3.3.1. Evaluación del modelo de atacante y expansión de QIDs	16
3.3.2. Resultados del Riesgo Basal Definitivo	17
3.4. Transformación Específica para Privacidad (Reducción de Dimensionalidad)	18
3.4.1. El problema de la dimensionalidad en Privacidad Diferencial	18
3.4.2. Agrupación semántica de códigos CIE-9	18

3.5. Modelado de Referencia (Baseline)	19
3.5.1. Preparación y escalado de los datos	19
3.5.2. Entrenamiento y métricas de utilidad base	20
3.6. Aplicación de Privacidad Sintáctica mediante ARX	21
3.6.1. Configuración de atributos	22
3.6.2. Jerarquías de Generalización	22
3.6.3. Modelo de supresión y métrica de utilidad	23
3.6.4. Barrido de parámetros y exportación	23
3.6.5. Reentrenamiento y métrica de comparación	24
3.7. Aplicación de Privacidad Diferencial mediante <code>diffprivlib</code>	25
3.7.1. Selección de la librería y modelos privados	25
3.7.2. Calibración de la sensibilidad y modelo de ruido	26
3.7.3. Barrido del presupuesto de privacidad	26
3.7.4. Repeticiones y métricas de estabilidad	27
4. Resultados	29
4.1. Resultados de la Aplicación de k -Anonimidad mediante ARX	29
4.2. Impacto sobre la Utilidad Predictiva de los Modelos	30
4.2.1. Robustez de los modelos lineales y de <i>ensemble</i>	31
4.2.2. Sensibilidad diferencial entre familias algorítmicas	32
4.2.3. Implicaciones para la selección de modelos en entornos privados	32
4.3. Análisis de Equidad Algorítmica	33
4.3.1. La k -anonimidad no exacerba la disparidad demográfica	33
4.3.2. Interpretación: regularización implícita en grupos minoritarios	34
4.4. Síntesis de la Fase Sintáctica	35
4.5. Resultados de la Aplicación de Privacidad Diferencial	36
4.5.1. Curva de degradación de la utilidad	36
4.5.2. Comparativa cruzada: Privacidad Diferencial frente a k -Anonimidad	37
4.5.3. Impacto sobre la equidad: el patrón Bagdasaryan se confirma	38
4.5.4. Síntesis de la Fase Diferencial	39
4.6. Defensa en Profundidad: Combinación de k -Anonimidad y Privacidad Diferencial	40
4.6.1. Comportamiento de la utilidad combinada	40
4.6.2. Implicación: la defensa en profundidad no es trivial	41
4.7. Auditoría Adversarial: Inferencia de Membresía con ART	42
4.7.1. Configuración del experimento	42
4.7.2. Resultados de la auditoría	43
4.8. Tests de Significancia Estadística	45
4.8.1. Test de McNemar para los modelos k -anonimizados	45

4.8.2. Test de Wilcoxon para los modelos diferencialmente privados	46
5. Conclusiones y trabajos futuros	47
5.1. Respuesta a la Pregunta de Investigación	47
5.1.1. Respuesta 1: la k -anonimidad es prácticamente gratuita	47
5.1.2. Respuesta 2: la Privacidad Diferencial impone un coste real	48
5.1.3. Respuesta 3: los efectos sobre la equidad son cualitativamente opuestos	48
5.1.4. Respuesta 4: el riesgo basal de membresía es bajo	48
5.2. Marco de Recomendaciones para Aplicaciones de Readmisión Hospitalaria . .	49
5.2.1. Recomendación 1: aplicar k -anonimidad con $k = 10$ cuando el objetivo sea publicar microdatos	50
5.2.2. Recomendación 2: reservar la Privacidad Diferencial para escenarios con exigencia regulatoria explícita	50
5.2.3. Recomendación 3: realizar una auditoría MIA antes de aplicar técnicas costosas	50
5.2.4. Recomendación 4: evitar la combinación naïve de k -anonimidad y DP	50
5.3. Limitaciones del Estudio	51
5.3.1. Generalización a otros conjuntos de datos y dominios	51
5.3.2. Familias algorítmicas evaluadas	51
5.3.3. Limitaciones inherentes de la herramienta de DP empleada	51
5.3.4. Tamaño muestral del barrido diferencial	52
5.3.5. Modelo de atacante de la auditoría MIA	52
5.4. Líneas Futuras de Investigación	52
5.4.1. Línea 1: DP-SGD con <code>Opacus</code> sobre redes neuronales tabulares	52
5.4.2. Línea 2: generación de datos sintéticos diferencialmente privados con CTGAN	53
5.4.3. Línea 3: validación externa y árbol de decisión refinado	53
5.5. Reflexión Final	54
Bibliografía y referencias	57

Índice de figuras

4.1. Degradación de <i>Accuracy</i> (izquierda) y <i>F1-Score</i> ponderado (derecha) de los cuatro modelos a lo largo del barrido $k \in \{0, 2, 5, 10, 25, 50\}$. El eje de abscisas se representa en escala simétrica logarítmica para resaltar la zona de transición.	31
4.2. Disparidad de utilidad de la Regresión Logística por subgrupo race a lo largo del barrido $k \in \{0, 2, 5, 10, 25, 50\}$. Las leyendas indican el tamaño n de cada subgrupo en el conjunto de prueba. La línea discontinua marca la <i>Accuracy</i> media del <i>baseline</i> .	34
4.3. Degradación de <i>Accuracy</i> (izquierda) y <i>F1-Score</i> ponderado (derecha) en función del presupuesto de privacidad ϵ . Las barras de error corresponden a la desviación típica sobre cinco repeticiones por punto. Las líneas discontinuas indican los <i>baselines</i> sin privacidad.	37
4.4. Comparativa cruzada de las dos técnicas de privacidad sobre la Regresión Logística. La curva azul (eje inferior) representa Privacidad Diferencial; la curva verde (eje superior) representa k -anonimidad. La línea discontinua indica el <i>baseline</i> sin privacidad (0,6178).	37
4.5. Disparidad de utilidad de la Regresión Logística diferencialmente privada por subgrupo race a lo largo del barrido $\epsilon \in \{0,1, 0,5, 1, 5, 10\}$. Las barras de error corresponden a la desviación típica sobre cinco repeticiones.	39
4.6. Comparativa de utilidad de la Regresión Logística: DP solo (azul) frente a combinación $k = 10 + DP$ (verde). Las líneas discontinuas indican el <i>baseline</i> y el modelo $k = 10$ sin DP como referencias.	41
4.7. Disparidad de utilidad por subgrupo race : DP solo (izquierda) vs combinación $k = 10 + DP$ (derecha). En la combinación se observa que la varianza por subgrupo se incrementa a $\epsilon = 0,1$, especialmente en el grupo <i>Asian</i> de menor tamaño.	42
4.8. Resultados de la auditoría adversarial mediante MIA Black-Box. La línea discontinua en 0,5 marca el rendimiento aleatorio de un atacante; valores próximos a esta indican ausencia de fuga estructural.	43

5.1. Árbol de decisión para la selección de técnica de privacidad en aplicaciones de clasificación clínica tabular, derivado empíricamente de los resultados del Capítulo 4.	49
--	----

Índice de tablas

2.1. Dimensiones del impacto de la anonimización sobre modelos de IA.	6
3.1. Rendimiento de los modelos Baseline sobre el conjunto de datos reducido (121 dimensiones).	20
3.2. Configuración de atributos en ARX para el conjunto de datos clínico.	22
3.3. Jerarquías de generalización empleadas en ARX.	23
4.1. Efectos estructurales de la aplicación de k -anonimidad sobre el conjunto de entrenamiento (78.442 registros).	29
4.2. Niveles de generalización efectivamente aplicados por ARX en cada cuasi-identificador. Un valor de 0 indica que el atributo conserva su granularidad original; las anotaciones entre paréntesis describen la abstracción aplicada en el primer nivel.	30
4.3. <i>Accuracy</i> de los modelos sobre el conjunto de prueba en función del nivel de privacidad sintáctica.	30
4.4. <i>F1-Score</i> ponderado de los modelos sobre el conjunto de prueba en función del nivel de privacidad sintáctica.	31
4.5. <i>Accuracy</i> de la Regresión Logística sobre el conjunto de prueba desagregada por subgrupo race	33
4.6. <i>Accuracy</i> (mean $\pm$ std, $n = 5$) de los modelos diferencialmente privados sobre el conjunto de prueba.	36
4.7. <i>F1-Score</i> ponderado (mean $\pm$ std, $n = 5$) de los modelos diferencialmente privados.	36
4.8. <i>Accuracy</i> (media de cinco repeticiones) de la Regresión Logística diferencialmente privada desagregada por subgrupo race . La última columna recoge la pérdida porcentual respecto al <i>baseline</i> a $\epsilon = 0,1$	38
4.9. <i>Accuracy</i> (mean $\pm$ std, $n = 5$) de DP solo vs combinación $k = 10 + DP$. . .	40
4.10. Auditoría adversarial mediante MIA Black-Box sobre Regresión Logística en distintos escenarios de privacidad.	43
4.11. Test de McNemar entre el <i>baseline</i> y cada modelo k -anonimizado. b representa los casos en que el <i>baseline</i> acierta y el modelo anonimizado falla; c los inversos. Significativo: $p < 0,05$	45

4.12. Test de Wilcoxon de una muestra entre la *Accuracy* del modelo DP y el
baseline. $n = 5$ repeticiones por celda. 46

Capítulo 1

Introducción

1.1. Motivación

La intersección entre la ciencia de datos y la privacidad de la información ha pasado de estar en un plano secundario a convertirse en un pilar del desarrollo tecnológico. La explosión actual de la Inteligencia Artificial ha intensificado las preocupaciones sobre el uso ético y seguro de la información personal en la sociedad.

Nos surge una problemática a resolver: por un lado, existe la necesidad técnica de utilizar grandes volúmenes de datos para el entrenamiento de modelos precisos; por otro, impera la obligación legal de proteger la identidad de los sujetos. Esta protección está estrictamente regulada por normativas vigentes, como el Reglamento General de Protección de Datos (*Reglamento (UE) 2016/679 2016*) en Europa y la Ley de IA de la Unión Europea (*Reglamento (UE) 2024/1689 2024*), las cuales exigen confianza digital en la implementación de sistemas de IA.

Especialmente en sectores críticos y regulados, como la salud o las finanzas, el acceso a datos compartibles es fundamental para los avances. Sin embargo, el riesgo de que un atacante pueda inferir la presencia de un individuo en un conjunto de entrenamiento (ataque de membresía) o descubrir atributos sensibles representa una barrera significativa que los ingenieros y científicos de datos deben superar en el diseño de sus pipelines analíticos (Shokri et al. 2017).

1.2. Propuesta y objetivos

Este Trabajo Fin de Máster se orienta como un estudio técnico-práctico que busca cuantificar el equilibrio óptimo entre la privacidad del individuo y la eficacia predictiva de los modelos de aprendizaje automático. El objetivo principal de esta propuesta es evaluar de manera comparativa el impacto de diversas técnicas de anonimización en el rendimiento, la estabilidad y la capacidad predictiva de modelos de inteligencia artificial dentro de un caso de uso específico.

Para alcanzar este fin, y demostrar la capacidad para manejar el ciclo de vida completo de un proyecto de ciencia de datos bajo restricciones de privacidad, se establecen los siguientes objetivos específicos:

- **Revisión y Sistematización del Estado del Arte:** Estudiar las técnicas fundamentales de privacidad sintáctica (k -anonimidad, l -diversidad) y privacidad semántica (privacidad diferencial), así como la generación de datos sintéticos y los marcos de aprendizaje federado.
- **Implementación de un Entorno Experimental:** Seleccionar un dominio representativo y un conjunto de datos que contenga atributos sensibles y cuasi-identificadores.
- **Aplicación Parametrizada de Técnicas:** Crear múltiples versiones del conjunto de datos original mediante la aplicación de diferentes algoritmos y niveles de protección para permitir un análisis de sensibilidad sobre los parámetros de privacidad.
- **Benchmarking de Modelos de IA:** Entrenar y validar diversas arquitecturas utilizando los diferentes conjuntos de datos (original, anonimizado y sintético) (*[Benchmarking Differential Privacy Optimizers 2024](#)*).
- **Análisis de Vulnerabilidades y Riesgo Residual:** Evaluar la robustez de los modelos frente a ataques de re identificación e inferencia de membresía para cuantificar la protección real obtenida.
- **Desarrollo de un Marco de Recomendaciones:** Sintetizar los hallazgos en una guía práctica que oriente sobre qué técnica y qué parámetros son más adecuados según el equilibrio privacidad-utilidad deseado.

1.3. Estructura del documento

Para dar respuesta a los objetivos planteados y mantener el rigor de la investigación aplicada, la presente memoria se estructura siguiendo un flujo narrativo que guía desde el planteamiento del problema hasta la validación empírica.

El **Capítulo 1** introduce la motivación del proyecto, el problema central del dilema privacidad-utilidad y define los objetivos a alcanzar. En el **Capítulo 2**, se desarrolla el estado del arte mediante una taxonomía detallada de las técnicas de privacidad, abarcando desde la privacidad sintáctica y diferencial hasta la generación de datos sintéticos y el aprendizaje federado.

El **Capítulo 3** detalla la metodología de la investigación y el entorno experimental, describiendo el flujo de trabajo desde la ingesta de datos, el perfilado de privacidad y las herramientas tecnológicas seleccionadas para el desarrollo práctico (como IBM Diffprivlib, ARX o el Adversarial Robustness Toolbox).

A continuación, el **Capítulo 4** presenta el análisis de resultados, exponiendo las métricas de evaluación del rendimiento, el impacto en la equidad (*fairness*) algorítmica y la robustez de los modelos bajo las distintas restricciones de anonimización aplicadas ([«Privacy, Utility and Fairness: Navigating Trade-offs in Differentially Private Machine Learning» 2025](#)).

Finalmente, el **Capítulo 5** recoge las conclusiones del trabajo, sintetizando los hallazgos sobre el equilibrio entre privacidad y utilidad, y propone un marco de recomendaciones prácticas junto con las futuras líneas de investigación derivadas del estudio.

Capítulo 2

Estado del Arte

2.1. El Paradigma de la Privacidad en la Ciencia de Datos

Para poder profundizar en las técnicas específicas de anonimización, es importante que establezcamos las bases conceptuales del problema subyacente. La base de cualquier investigación en privacidad aplicada a la ciencia de datos reside en la comprensión de que los datos no son entidades estáticas, sino activos que fluyen a través de procesos de transformación que pueden alterar su estructura estadística.

2.1.1. Definición de Privacidad y Anonimización

La anonimización se define conceptualmente como el proceso de transformar datos de modo que los individuos no puedan ser identificados ni directa ni indirectamente (*Reglamento (UE) 2016/679* 2016). Este proceso no es inocuo para la información original; la aplicación de estas técnicas introduce necesariamente cierto nivel de distorsión o pérdida de granularidad. Esta distorsión impacta directamente en la capacidad de los modelos de aprendizaje automático para identificar patrones complejos, lo que puede derivar en una disminución de la precisión y un aumento del sesgo algorítmico. Por lo tanto, el trabajo del ingeniero de datos debe orientarse a desmitificar la idea de que la anonimización es un proceso de “todo o nada”, presentándola en cambio como un espectro de decisiones técnicas basadas en el riesgo (Argyriou et al. 2025).

2.1.2. El Dilema Privacidad frente a Utilidad

El principal desafío en este ámbito es mantener el equilibrio constante entre la protección del individuo y el valor de la información. El concepto de utilidad del dato se refiere a su capacidad para servir al propósito analítico original. En el ámbito del aprendizaje automático, esto se traduce específicamente en la capacidad del modelo para generalizar a partir de los datos anonimizados y mantener métricas de rendimiento competitivas frente a un modelo entrenado con datos en claro.

La literatura científica advierte que la aplicación de protecciones algorítmicas fuertes puede tener consecuencias severas sobre la analítica. Por ejemplo, el uso de privacidad diferencial con un presupuesto de privacidad restrictivamente bajo, puede degradar el rendimiento hasta niveles donde el modelo pierde por completo su valor práctico ([«Differentially Private and Adversarially Robust Machine Learning: An Empirical Evaluation» 2024](#)).

La Tabla 2.1 sintetiza las principales dimensiones en las que la anonimización impacta sobre los modelos de inteligencia artificial.

Tabla 2.1: Dimensiones del impacto de la anonimización sobre modelos de IA.

Dimensión	Impacto de la Anonimización	Consecuencia en el Modelo
Estructura Estadística	Alteración de medias, varianzas y correlaciones.	Desplazamiento de la frontera de decisión y pérdida de precisión (Dwork et al. 2006).
Granularidad	Generalización de valores (ej. rangos de edad en lugar de años exactos).	Dificultad para capturar patrones sutiles o nichos específicos (Sweeney 2002).
Representatividad	Supresión de valores atípicos (<i>outliers</i>) para evitar singularización.	Aumento del error en casos raros y posibles problemas de equidad (<i>fairness</i>) (Bagdasaryan, Poursaeed y Shmatikov 2019).
Robustez	Inyección de ruido aleatorio (Laplace/Gauss).	Puede actuar como regularizador o, en exceso, impedir la convergencia («Privacy, Utility and Fairness: Navigating Trade-offs in Differentially Private Machine Learning» 2025).

2.2. Privacidad Sintáctica y sus Variantes

Los modelos de privacidad sintáctica se basan en la alteración de la estructura de los datos para cumplir con ciertas propiedades o reglas predefinidas antes de su publicación o uso en el entrenamiento de modelos de Inteligencia Artificial. El enfoque principal de estas técnicas radica en la generalización y supresión de atributos.

2.2.1. El modelo de k -anonimidad

El concepto de k -anonimidad, formalizado por Sweeney (Sweeney 2002) para mitigar los ataques de enlace, busca que cada registro en un conjunto de datos publicado sea indistinguible de al menos otros $k - 1$ individuos con respecto a un conjunto específico de atributos conocidos como cuasi-identificadores (QID). Los cuasi-identificadores son aquellas variables que, si bien no identifican directamente a una persona, en combinación pueden utilizarse para reidentificar a un sujeto mediante el cruce con bases de datos externas.

Al agrupar a los individuos en “clases de equivalencia” de tamaño mínimo k , la probabilidad de aislar a un único individuo a partir de sus cuasi-identificadores se reduce a $1/k$. Para lograr esta propiedad, existen diversos enfoques algorítmicos. En este trabajo, es fundamental destacar algoritmos como **Mondrian** (LeFevre, DeWitt y Ramakrishnan 2006), un enfoque *top-down* que realiza particiones recursivas del espacio de datos multidimensional para crear estas clases de equivalencia de manera eficiente, optimizando la pérdida de información durante la generalización («Modeling and Evaluation of k-anonymization Metrics» 2020).

2.2.2. Vulnerabilidades y extensiones: l -diversidad y t -cercanía

Aunque la k -anonimidad ofrece una fuerte garantía contra la reidentificación de la identidad, la literatura científica ha demostrado que es vulnerable frente a ciertos tipos de ataques, particularmente los ataques de homogeneidad y los ataques de conocimiento previo (*background knowledge attacks*) (*Provably Private Data Anonymization: Or, k-Anonymity Meets Differential Privacy* 2010). Si todos los registros dentro de una clase de equivalencia comparten el mismo valor para un atributo sensible (por ejemplo, el diagnóstico médico “cáncer”), un atacante que sepa que la víctima pertenece a esa clase podrá inferir su atributo sensible, a pesar de la k -anonimidad.

Para resolver estas deficiencias, se han desarrollado extensiones del modelo original:

- ***l*-diversidad**: Propuesta por Machanavajjhala (Machanavajjhala et al. 2007), este modelo exige no solo que existan al menos k registros indistinguibles por cada clase de equivalencia, sino también que haya al menos l valores “bien representados” para los atributos sensibles dentro de dicha clase. De este modo, la confianza de un atacante para inferir un atributo sensible se limita, reduciendo el riesgo derivado de los ataques de homogeneidad.
- ***t*-cercanía (*t*-closeness)**: Propuesta por Li (N. Li, T. Li y Venkatasubramanian 2007), este modelo requiere que la distribución de un atributo sensible dentro de cualquier clase de equivalencia esté “cercana” a la distribución global de ese atributo en el conjunto de datos completo. Este enfoque semántico previene inferencias basadas en la desviación de las distribuciones locales frente a las globales, mitigando los ataques de asimetría y similitud semántica a los que la *l*-diversidad sigue siendo susceptible.

A pesar de sus beneficios, la imposición de restricciones estrictas de privacidad sintáctica (k, l, t) suele conllevar una degradación significativa en la granularidad del dato. Esta pérdida de información impacta directamente en la capacidad de los modelos de aprendizaje automático para capturar patrones sutiles, desplazando la frontera de decisión algorítmica y afectando negativamente la precisión predictiva («Secure Data Sharing in Machine Learning: Exploring K-Anonymization and Differential Privacy» 2024).

2.3. Privacidad Semántica: Privacidad Diferencial

A diferencia de los enfoques sintácticos que transforman el conjunto de datos mediante generalización o supresión, la Privacidad Diferencial aborda la protección de la información desde una perspectiva semántica. Introducida por Dwork (Dwork 2006), en la actualidad representa el estándar de oro en privacidad estadística, proporcionando garantías matemáticas sobre la divulgación de información individual.

El principal funcionamiento de la privacidad diferencial consiste en la adición de ruido aleatorio de manera controlada para ocultar la contribución de un individuo específico dentro de un conjunto de datos (Dwork et al. 2006). De este modo, el resultado de cualquier análisis o modelo entrenado sobre los datos será estadísticamente indistinguible, independientemente de si un registro particular fue incluido o no en el conjunto de entrenamiento. La magnitud de esta garantía se cuantifica mediante el presupuesto de privacidad, denotado por ϵ , donde valores más bajos de ϵ implican una protección más fuerte pero, consecuentemente, pueden degradar el rendimiento hasta niveles donde el modelo pierde su valor práctico («Privacy, Utility and Fairness: Navigating Trade-offs in Differentially Private Machine Learning» 2025).

2.3.1. Paradigmas de aplicación: DP Local y DP Global

La implementación de la privacidad diferencial puede categorizarse principalmente en dos posibles paradigmas, dependiendo de en qué etapa del flujo de datos se inyecte el ruido:

- **Privacidad Diferencial Local (LDP):** En este modelo, el ruido se añade de forma individual antes de que los datos salgan del dispositivo del usuario (Labelia Labs 2024). Esto garantiza que el agregador nunca tenga acceso a los datos en claro. Aunque proporciona el mayor nivel de privacidad frente a servidores no confiables, generalmente requiere un volumen masivo de datos para que la señal estadística supere al ruido introducido.
- **Privacidad Diferencial Global (o Centralizada):** En este modelo, los datos se recogen en claro y el ruido se añade de manera centralizada, ya sea en la salida de una consulta o durante el proceso de entrenamiento del modelo («Differentially Private and Adversarially Robust Machine Learning: An Empirical Evaluation» 2024). Este método asume la existencia de un curador de datos de confianza y permite obtener una mayor utilidad analítica con el mismo presupuesto de privacidad comparado con el enfoque local.

2.3.2. Privacidad Diferencial en el Aprendizaje Automático

La integración de la privacidad diferencial en el aprendizaje automático ha dado lugar a algoritmos especializados que adaptan la fase de optimización. Para modelos de aprendizaje profundo, el mecanismo estándar es el Descenso de Gradiente Estocástico Privado, propuesto por Abadi (Abadi et al. 2016). Este algoritmo introduce privacidad mediante dos operaciones principales en cada iteración: en primer lugar, recorta los gradientes calculados por cada ejemplo (*clipping*) para limitar la influencia máxima que un individuo puede tener en el modelo; en segundo lugar, perturba los gradientes agregados inyectando ruido antes de actualizar los pesos de la red.

En el ecosistema tecnológico actual, la implementación de estos mecanismos se facilita enormemente mediante librerías especializadas. Para el ecosistema de redes neuronales, herramientas como *Opacus* (Meta AI 2020) permiten el entrenamiento con DP y la monitorización del presupuesto de privacidad consumido a lo largo de las épocas. Por otro lado, para experimentación con modelos clásicos de aprendizaje automático, la librería *IBM Diffprivlib* (Holohan et al. 2019) ofrece una API compatible *scikit-learn*, incorporando mecanismos de privacidad diferencial de forma nativa.

2.4. Generación de Datos Sintéticos

En los últimos años, el uso de modelos generativos para crear datos artificiales que mantengan las propiedades estadísticas de los datos reales se ha consolidado como una de las áreas más dinámicas en la intersección de la ciencia de datos y la privacidad ([Synthetic Data – what, why and how? 2024](#)). El objetivo principal de esta técnica es generar un conjunto de datos completamente nuevo que no contenga una correspondencia uno a uno con los individuos originales, pero que preserve las correlaciones y la estructura multidimensional subyacente.

Para lograr esto, se emplean técnicas avanzadas de aprendizaje profundo, destacando fundamentalmente dos arquitecturas: las Redes Generativas Adversarias (GANs) (Goodfellow et al. 2014) y los Autoencoders Variacionales (VAEs). En el contexto de datos tabulares, variantes especializadas como CTGAN (Xu et al. 2019) han demostrado resultados prometedores al manejar la complejidad de columnas mixtas. El éxito de estos modelos se evalúa determinando si el conjunto sintético resultante es capaz de sustituir eficazmente al conjunto real en tareas posteriores manteniendo métricas de rendimiento y utilidad competitivas.

Sin embargo, un punto crítico en la literatura científica actual es el debate sobre si los datos sintéticos son intrínsecamente privados ([«Differentially Private Synthetic Data Enables Public Release of Behavioral Health Information with High Utility» 2025](#)). Diversos estudios han demostrado que los modelos generativos complejos tienen una tendencia a la memorización, lo que significa que pueden llegar a replicar con alta fidelidad registros atípicos presentes en el conjunto de entrenamiento original ([«Membership Inference Attacks Against Synthetic Health Data» 2022](#)). Por este motivo, se concluye que la generación de datos sintéticos a menudo requiere la integración de garantías matemáticas adicionales, como la Privacidad Diferencial, para evitar vulnerabilidades ante ataques de inferencia de membresía.

2.5. Paradigmas Colaborativos: Aprendizaje Federado (FL)

El Aprendizaje Federado, formalizado por McMahan (McMahan et al. 2017), representa un cambio de paradigma respecto al modelado tradicional centralizado. Este enfoque permite entrenar modelos de Inteligencia Artificial sin necesidad de centralizar los datos en un único servidor, manteniéndolos de forma segura en los dispositivos de origen o en locales protegidos. En lugar de compartir los microdatos, los nodos participantes entrenan un modelo localmente y únicamente comparten las actualizaciones de los pesos o gradientes con un servidor central, el cual los agrega para conformar un modelo global ([«Privacy-preserving machine learning: a review of federated learning techniques and applications» 2025](#)).

Este paradigma resulta de vital importancia en sectores como el sanitario, donde el movimiento de datos sensibles está fuertemente restringido por la legislación ([«Empirical](#)

[Analysis of Privacy-Fairness-Accuracy Trade-offs in Federated Learning» 2025](#)).

A pesar de que el FL minimiza la exposición directa de los datos, el simple intercambio de gradientes puede seguir siendo vulnerable a ataques de inversión, mediante los cuales un actor malicioso podría reconstruir parte de los datos originales a partir de las actualizaciones del modelo. Por ello, la vanguardia de la investigación aborda cómo el Aprendizaje Federado se combina sinérgicamente con otras tecnologías de mejora de la privacidad (PETs). Específicamente, la integración del FL con la Privacidad Diferencial (DP) o con la Computación Segura Multiparte (SMPC) ofrece capas adicionales de protección, permitiendo una colaboración segura entre instituciones sin violar en ningún momento la confidencialidad de los pacientes ([«Privacy-preserving machine learning: a review of federated learning techniques and applications» 2025](#)).

2.6. Evaluación de Riesgos y Auditoría Algorítmica

Para finalizar el estado del arte de la privacidad en el aprendizaje automático, necesitamos abordar las amenazas a las que se enfrentan estos sistemas y las metodologías empleadas para medir empíricamente el impacto de las protecciones implementadas. La evaluación continua de riesgos se ha convertido en un pilar de la auditoría algorítmica moderna.

2.6.1. Ataques a Modelos de Inteligencia Artificial

La robustez de un modelo frente a la reidentificación se evalúa simulando el comportamiento de un adversario. Entre las amenazas más críticas en este ámbito destacan los ataques de inferencia de membresía, formalizados por Shokri (Shokri et al. [2017](#)). La teoría detrás de un ataque MIA plantea que un atacante externo, interactuando con el modelo bajo un esquema de “caja negra”, puede intentar deducir si un individuo específico formó parte del conjunto de datos de entrenamiento.

Los modelos de aprendizaje automático, especialmente las redes neuronales profundas con tendencia al sobreajuste, suelen mostrar una mayor confianza en sus predicciones para los datos con los que fueron entrenados en comparación con datos nunca antes vistos. Los ataques MIA explotan esta diferencia en las distribuciones de confianza para vulnerar la privacidad del sujeto, lo que hace imperativo el uso de auditorías de *red teaming* y herramientas de simulación adversarial como el Adversarial Robustness Toolbox (Linux Foundation AI & Data [2018](#)) para cuantificar el riesgo real (Galileo AI [2025](#)).

2.6.2. Impacto en la Equidad y Justicia Algorítmica

Un área importante en la literatura científica actual es el estudio de cómo la inyección de privacidad impacta en la justicia algorítmica. Tradicionalmente, la evaluación de técnicas de anonimización se ha centrado en el equilibrio global entre privacidad y precisión, pero rara vez se analizaba si la degradación del rendimiento era uniforme para todos los grupos demográficos.

Investigaciones recientes, como las de Bagdasaryan (Bagdasaryan, Poursaeed y Shmatikov 2019), sugieren que técnicas robustas como la Privacidad Diferencial pueden llegar a exacerbar los sesgos en los datos. El ruido añadido y el recorte de gradientes tienden a reducir la precisión de forma mucho más severa en grupos minoritarios o subrepresentados que en los grupos mayoritarios.

Para medir y mitigar este impacto desproporcionado, la comunidad académica recomienda la adopción de métricas teóricas de justicia algorítmica. Particularmente la **Paridad Demográfica**, que evalúa si las tasas de predicción positiva son independientes de los atributos sensibles (como raza o género), y la **Disparidad de Pérdida**, que cuantifica la diferencia en las tasas de error del modelo entre diferentes subgrupos poblacionales («Privacy, Utility and Fairness: Navigating Trade-offs in Differentially Private Machine Learning» 2025). El uso de estas métricas enriquece la discusión ética y técnica en el desarrollo de IA responsable.

Capítulo 3

Materiales y Métodos

Este capítulo detalla la metodología para cumplir los objetivos de la investigación. Se describe el entorno tecnológico, el conjunto de datos y el flujo de trabajo: desde la limpieza y el perfilado de riesgo de privacidad, hasta la anonimización y la evaluación de los modelos de inteligencia artificial.

3.1. Entorno Experimental y Selección de Datos

Para garantizar la reproducibilidad de los experimentos y alinear el trabajo con los estándares actuales de la industria, el desarrollo práctico se ha llevado a cabo en un entorno basado en *cloud computing* utilizando **Google Colab**. Este entorno proporciona los recursos computacionales necesarios para el entrenamiento eficiente de modelos analíticos y la ejecución de algoritmos de inyección de ruido estadístico.

El lenguaje de programación base utilizado ha sido **Python 3**, orquestando un ecosistema de librerías dividido en dos categorías funcionales principales:

- **Librerías base de Ciencia de Datos:** Se ha utilizado *pandas* y *numpy* para la manipulación, limpieza y estructuración matricial de los microdatos. Para la estandarización de características, división de conjuntos y entrenamiento de modelos de referencia, se ha empleado el marco de *scikit-learn*.
- **Librerías especializadas en Privacidad y Seguridad:** Siguiendo la propuesta metodológica del estudio, el entorno incorpora *diffprivlib* (Holohan et al. 2019) para la implementación nativa de Privacidad Diferencial en algoritmos clásicos de Machine Learning; *opacus* (Meta AI 2020) para redes neuronales; *sdv* (Patki, Wedge y Veeramachaneni 2016) (*Synthetic Data Vault*) para la futura generación de datos sintéticos; y *adversarial-robustness-toolbox* (Linux Foundation AI & Data 2018) (ART) para las auditorías de riesgo adversarial mediante ataques de membresía. Adicionalmente, se contempla el uso de herramientas externas de escritorio como **ARX** para la aplicación estricta de métricas de privacidad sintáctica (k -anonimidad) sobre registros tabulares.

3.1.1. Selección y Justificación del Conjunto de Datos

Uno de los requisitos fundamentales de esta investigación es evaluar el impacto de las técnicas de anonimización dentro de un dominio crítico que contenga información altamente sensible sujeta a regulaciones normativas como el RGPD ([Reglamento \(UE\) 2016/679 2016](#)). Por consiguiente, se ha optado por enmarcar el estudio en el ámbito sanitario.

El conjunto de datos seleccionado es el *Diabetes 130-US hospitals for years 1999-2008 Data Set* (Strack, J. DeShazo et al. [2014](#)), importado de manera directa mediante la interfaz oficial del repositorio UCI Machine Learning ([ucimlrepo](#), ID 296). Este conjunto de datos representa registros clínicos reales y consolida información detallada sobre encuentros hospitalarios de pacientes diagnosticados con diabetes, cuya publicación original fue acompañada de un estudio sobre el impacto de la hemoglobina glicosilada (HbA1c) en las tasas de reingreso hospitalario (Strack, J. P. DeShazo et al. [2014](#)).

La elección de este *dataset* obedece a tres factores metodológicos críticos:

1. **Volumen de la muestra:** En su ingesta original, el conjunto cuenta con 101.766 registros. Este elevado volumen es un prerequisite indispensable para la aplicación de algoritmos de Privacidad Diferencial, ya que conjuntos de datos excesivamente pequeños sufren una destrucción de la señal predictiva ante la inyección de ruido matemático (Dwork et al. [2006](#)).
2. **Riqueza dimensional:** Compuesto por 48 características originales, abarca atributos demográficos, historial de admisiones, resultados de pruebas de laboratorio y medicación administrada.
3. **Naturaleza de las variables:** Permite realizar una segmentación exacta requerida por la teoría de la anonimización, presentando de manera natural *cuasi-identificadores* (como raza, género o edad), *atributos sensibles* (como los diagnósticos primarios y secundarios estructurados en códigos CIE-9, o los tratamientos con insulina) y una *variable objetivo* clara: predecir si el paciente será readmitido en el hospital en un plazo determinado (*readmitted*).

Es relevante señalar que la variable **age** (edad) en este *dataset* no se registra como un valor numérico exacto, sino que ya viene agrupada en rangos de décadas poblacionales (*[0-10)*, *[10-20)*, ..., *[90-100)*). Esta generalización previa reduce de forma intrínseca el riesgo de reidentificación, lo cual se analizará en detalle durante la fase de perfilado de privacidad y se discutirá como una limitación del estudio en el apartado de conclusiones.

La conjunción de este entorno tecnológico estandarizado y un conjunto de datos clínico de alta dimensionalidad asienta las bases empíricas necesarias para cuantificar el dilema entre la protección de la identidad del paciente y la utilidad analítica del dato (Argyriou et al. [2025](#)).

3.2. Ingesta y Preprocesamiento

La primera fase se centra en la preparación y depuración del conjunto original para garantizar su viabilidad en los procesos algorítmicos posteriores. Para esta etapa de ingesta y limpieza, se ha utilizado la librería `pandas` nativa de Python.

Tras la importación del *dataset* clínico (compuesto inicialmente por 101.766 registros y 48 características), se llevó a cabo un análisis exploratorio exhaustivo. El conjunto de datos presentaba los valores ausentes codificados mediante el carácter `?`, los cuales fueron transformados a un formato nulo estándar (NaN) para permitir su tratamiento estadístico.

El análisis de completitud reveló una alta variabilidad en la distribución de valores nulos, lo que exigió la aplicación de tres estrategias de preprocesamiento diferenciadas para evitar la introducción de sesgos algorítmicos:

- **Supresión de características no recuperables:** Se identificó que la variable `weight` (peso del paciente) presentaba un 96,85% de valores nulos. Dada la imposibilidad de realizar una imputación fiable sobre una muestra tan exigua sin distorsionar gravemente la distribución real, esta columna fue eliminada del espacio de características.
- **Imputación semántica de la ausencia de dato:** Variables clínicas críticas relativas a pruebas de laboratorio presentaban altos índices de valores ausentes (ej. `max_glu_serum` con 94,74%, `A1Cresult` con 83,27% y `medical_specialty` con 49,08%). En el contexto de un registro médico, la ausencia de una prueba clínica no es un error de recolección, sino información médica de valor semántico (indica que el facultativo no consideró necesario realizar dicha prueba). Por tanto, estos valores nulos fueron imputados mediante la creación de una nueva categoría unificada denominada "No_Registrado".
- **Eliminación de registros (*Listwise Deletion*):** Para las columnas restantes con un porcentaje de nulos residual (inferior al 3%, como `race`, `diag_1`, `diag_2` y `diag_3`), se procedió a la eliminación de las filas afectadas. Esta decisión se fundamenta en la necesidad de preservar la integridad absoluta de la variable `race` (raza), ya que está designada como un *cuasi-identificador* troncal indispensable para la correcta ejecución matemática de las técnicas de *k*-anonimidad en las fases posteriores (Sweeney 2002).

Como resultado de esta fase de depuración metodológica, el conjunto de datos se redujo a una matriz de **98.053 registros completamente limpios y 47 características**. Tras la eliminación se verificó que la distribución de la variable `race` no había sufrido sesgos significativos, ya que esta verificación resulta esencial para los análisis de equidad algorítmica (*fairness*) en fases posteriores. La distribución resultante mostró una representación mayoritaria de pacientes caucásicos (76,6 %) frente a afroamericanos (19,3 %), hispanos (2,0 %), otros (1,5 %) y asiáticos (0,6 %), un desbalanceo que resultará de particular interés al evaluar

el impacto diferencial de las técnicas de privacidad sobre grupos minoritarios (Bagdasaryan, Poursaeed y Shmatikov 2019).

Finalmente, se ejecutó la primera acción de anonimización directa consistente en la verificación de la ausencia de identificadores explícitos. La interfaz `fetch_ucirepo` del repositorio UCI separa automáticamente los identificadores directos (`encounter_id` y `patient_nbr`) del espacio de *features*, por lo que el conjunto de datos importado ya no contenía variables con capacidad de identificación unívoca directa antes de iniciar el perfilado algorítmico del riesgo de reidentificación.

3.3. Perfilado de Privacidad y Análisis de Riesgo Basal

Una vez garantizada la integridad estructural del conjunto de datos y verificada la ausencia de identificadores directos, la siguiente fase metodológica consistió en realizar un perfilado de privacidad. El objetivo de este proceso es cuantificar empíricamente la vulnerabilidad de la base de datos ante posibles ataques de enlace (*linkage attacks*) antes de aplicar cualquier técnica algorítmica de protección.

Para ello, se llevó a cabo una clasificación formal de los atributos restantes según la taxonomía de la privacidad de datos:

- **Variable Objetivo (*Target*):** `readmitted`, que indica si el paciente fue readmitido en el hospital, fundamental para evaluar la utilidad posterior de los modelos de clasificación.
- **Atributos Sensibles (SA):** Compuestos por la información clínica confidencial, incluyendo los diagnósticos médicos y las pautas de medicación (ej. administración de insulina, metformina, etc.).
- **Cuasi-identificadores (QID):** Atributos que, si bien no identifican a un individuo de forma aislada, pueden combinarse para reidentificar a un sujeto si el atacante posee conocimiento previo (*background knowledge*) (Sweeney 2002).

Para evaluar el riesgo de reidentificación basal, se procedió a agrupar los registros en *clases de equivalencia* —subconjuntos de pacientes que comparten exactamente la misma combinación de cuasi-identificadores—. El análisis se realizó de forma iterativa para modelar diferentes capacidades del atacante.

3.3.1. Evaluación del modelo de atacante y expansión de QIDs

En una primera iteración, se asumió un modelo de atacante estándar con conocimiento de cuatro cuasi-identificadores básicos: raza (`race`), género (`gender`), edad (`age`) y tiempo de estancia hospitalaria (`time_in_hospital`).

El cálculo de las clases de equivalencia arrojó un riesgo de reidentificación bajo: únicamente 133 pacientes resultaron ser únicos en la base de datos (vulnerabilidad extrema correspondiente a $k = 1$, un 0,14% del total), y solo 662 pacientes (0,68%) se encontraban en grupos inferiores al umbral de seguridad médico recomendado de $k = 5$. Este riesgo basal reducido se explica por la generalización previa existente en la variable **age** (agrupada en rangos de décadas), que reduce el espacio de combinaciones posibles a solo 1.009 combinaciones únicas de QIDs.

Si bien estos resultados indican que el conjunto de datos posee cierta protección inherente con cuatro cuasi-identificadores, un riesgo basal inferior al 1% dificultaría la justificación y la cuantificación del impacto de las técnicas avanzadas de anonimización que constituyen el objetivo central de esta investigación. Por ello, se procedió a expandir el modelo de amenaza, asumiendo un atacante con un escenario más realista que tuviera acceso a registros administrativos complementarios (como una factura de admisión). Para ello, se incorporó un quinto cuasi-identificador: el tipo de ingreso hospitalario (**admission_type_id**).

3.3.2. Resultados del Riesgo Basal Definitivo

La inclusión de este quinto cuasi-identificador fragmentó significativamente las clases de equivalencia, revelando la verdadera vulnerabilidad subyacente del conjunto de datos. Sobre el total de 98.053 registros evaluados, se identificaron 3.516 combinaciones únicas de QIDs, arrojando las siguientes métricas de riesgo basal:

- **Vulnerabilidad extrema ($k = 1$):** 920 pacientes presentaron una combinación totalmente singular de características, lo que representa un riesgo de reidentificación directa del 0,94%. Cualquier atacante que conociera estos cinco datos demográficos y administrativos de uno de estos pacientes podría enlazar inequívocamente su identidad con sus atributos médicos sensibles.
- **Vulnerabilidad estándar ($k < 5$):** 3.448 pacientes (el 3,52% del total del conjunto) quedaron expuestos en grupos menores a 5 individuos. Este umbral de $k = 5$ es el recomendado en la literatura de privacidad en el ámbito sanitario ([«Secure Data Sharing in Machine Learning: Exploring K-Anonymization and Differential Privacy» 2024](#)).

El descubrimiento empírico de estos más de 3.400 registros vulnerables valida la premisa teórica de la investigación: la simple supresión de identificadores directos (*seudonimización*) es una medida de seguridad insuficiente. Estos resultados justifican formalmente la necesidad de aplicar esquemas de privacidad sintáctica avanzados (mediante herramientas como ARX) y técnicas de inyección de ruido (Privacidad Diferencial) en las siguientes fases del proyecto.

3.4. Transformación Específica para Privacidad (Reducción de Dimensionalidad)

La preparación de datos categóricos para el entrenamiento de modelos de *Machine Learning* requiere, por norma general, la aplicación de técnicas de codificación como el *One-Hot Encoding* (OHE). Al aplicar este proceso sobre el conjunto de datos limpio, se identificó un problema crítico de alta cardinalidad: el espacio de características original (47 columnas) se expandió hasta alcanzar las 2.405 dimensiones.

Esta explosión de dimensionalidad tuvo su origen en las variables correspondientes a los diagnósticos médicos principales y secundarios (`diag_1`, `diag_2` y `diag_3`), las cuales contenían cientos de códigos distintos basados en la Clasificación Internacional de Enfermedades (CIE-9). Un primer modelo exploratorio de Regresión Logística entrenado sobre estas 2.405 dimensiones arrojó un *Accuracy* de 0,6260, confirmando la capacidad predictiva inherente del conjunto de datos pero evidenciando que la explosión de dimensionalidad no aporta una ganancia significativa frente a los problemas que introduce para las técnicas de privacidad.

3.4.1. El problema de la dimensionalidad en Privacidad Diferencial

En un contexto analítico tradicional, los modelos como la Regresión Logística regularizada pueden manejar espacios altamente dimensionales. Sin embargo, en el marco de la Privacidad Diferencial, la dimensionalidad se convierte en un factor limitante severo.

Los algoritmos de *Machine Learning* diferencialmente privados (como los implementados en la librería `diffprivlib`) garantizan la privacidad inyectando ruido matemático — típicamente mediante mecanismos de Laplace o Gauss— directamente en la función de coste o en los gradientes durante el entrenamiento (Dwork et al. 2006). La magnitud de este ruido es proporcional a la sensibilidad de la función y se distribuye entre todos los parámetros del modelo. En consecuencia, inyectar ruido sobre 2.405 parámetros diluye excesivamente la señal estadística legítima, provocando un colapso en la capacidad predictiva del modelo y reduciendo su utilidad a niveles cercanos al azar (Abadi et al. 2016).

3.4.2. Agrupación semántica de códigos CIE-9

Para viabilizar la experimentación con Privacidad Diferencial garantizando al mismo tiempo un *trade-off* aceptable entre privacidad y utilidad, se procedió a realizar una reducción de dimensionalidad guiada por el conocimiento del dominio clínico.

En lugar de aplicar técnicas puramente matemáticas (como el Análisis de Componentes Principales o PCA) que ofuscarían la interpretabilidad de las características sensibles, se desarrolló una función de mapeo para agrupar los códigos CIE-9 originales en nueve macrocategorías médicas estandarizadas:

- **Diabetes:** Códigos 250.x.
- **Sistema Circulatorio (*Circulatory*):** Códigos 390-459 y 785.
- **Sistema Respiratorio (*Respiratory*):** Códigos 460-519 y 786.
- **Sistema Digestivo (*Digestive*):** Códigos 520-579 y 787.
- **Sistema Genitourinario (*Genitourinary*):** Códigos 580-629 y 788.
- **Sistema Musculoesquelético (*Musculoskeletal*):** Códigos 710-739.
- **Lesiones (*Injury*):** Códigos 800-999.
- **Neoplasias (*Neoplasms*):** Códigos 140-239.
- **Otras/No clasificadas (*Other*):** Códigos restantes, suplementarios (V o E) y valores faltantes arrastrados.

Tras aplicar este mapeo semántico a las tres variables de diagnóstico y eliminar la característica `medical_specialty` (cuya distribución introducía redundancia tras la agrupación), se volvió a ejecutar el proceso de codificación OHE.

El resultado fue una drástica reducción del espacio de características, pasando de **2.405 a 121 dimensiones**. Esta optimización del conjunto de datos preserva la integridad de la señal médica subyacente, a la vez que proporciona una base computacionalmente estable y matemáticamente apta para la convergencia de los algoritmos de Privacidad Diferencial en las fases posteriores.

3.5. Modelado de Referencia (Baseline)

Para poder cuantificar con rigor científico la pérdida de utilidad (*utility loss*) que introducen los mecanismos de anonimización y Privacidad Diferencial, es imperativo establecer primero un escenario de referencia o *Baseline*. Este modelo base representa el "techo de rendimiento" predictivo, entrenado sobre los datos originales en claro tras su limpieza y reducción de dimensionalidad, pero sin la aplicación de ninguna perturbación de privacidad.

3.5.1. Preparación y escalado de los datos

Antes del entrenamiento algorítmico, el conjunto de datos reducido (121 dimensiones) fue sometido a una fase final de adecuación matemática:

1. **Binarización de la variable objetivo:** La variable dependiente `readmitted` originalmente presentaba tres clases (*NO*, *<30 días*, *>30 días*). Para simplificar la evaluación

de la degradación del modelo y enmarcarlo en un problema de clasificación binaria estándar, se transformó de manera que el valor *NO* representa la clase negativa (0, no readmitido) y cualquier otro valor representa la clase positiva (1, readmitido).

2. **Partición del conjunto de datos:** Se realizó una división del conjunto en un subconjunto de entrenamiento (80%, 78.442 registros) y un subconjunto de prueba (20%, 19.611 registros). Para mantener la representatividad de las clases, se aplicó un muestreo estratificado (`stratify`) basado en la variable objetivo.
3. **Estandarización (*Scaling*):** Se aplicó la transformación `StandardScaler` de *scikit-learn* sobre el conjunto de entrenamiento, ajustando las características numéricas para que presentasen una media de 0 y una varianza de 1 ($\mu = 0, \sigma = 1$). Este paso no solo es una buena práctica para garantizar la convergencia de modelos lineales, sino que es un **requisito matemático estricto** para la futura aplicación de Privacidad Diferencial, ya que los algoritmos de `diffprivlib` requieren conocer o acotar la norma máxima de los vectores de entrada para calibrar correctamente la inyección de ruido (Holohan et al. 2019).

3.5.2. Entrenamiento y métricas de utilidad base

Para establecer una línea de referencia completa, se entrenaron cuatro modelos de clasificación representativos de diferentes paradigmas de aprendizaje. La selección de estos modelos obedece a un criterio doble: en primer lugar, abarcar familias algorítmicas con distintos mecanismos de aprendizaje (lineales, basados en árboles y probabilísticos); en segundo lugar, priorizar aquellos para los que existen implementaciones homólogas con Privacidad Diferencial en la librería `diffprivlib`, lo que permitirá una comparativa simétrica en fases posteriores.

Los cuatro modelos entrenados y sus respectivos resultados sobre el conjunto de prueba aislado se presentan en la Tabla 3.1.

Tabla 3.1: Rendimiento de los modelos Baseline sobre el conjunto de datos reducido (121 dimensiones).

Modelo	<i>Accuracy</i>	<i>F1-Score</i> (Pond.)
Random Forest	0,6300	0,6277
Regresión Logística	0,6178	0,6159
Árbol de Decisión	0,6138	0,6138
Naive Bayes (Gaussian)	0,5912	0,5599

Los resultados muestran un rendimiento consistente entre los modelos, con un rango de *Accuracy* comprendido entre 0,59 y 0,63. Es necesario contextualizar estos valores: el *dataset* de diabetes 130-US hospitals es reconocido en la literatura como un problema de clasificación intrínsecamente difícil, ya que la readmisión depende de numerosos factores

clínicos y socioeconómicos no capturados en las variables disponibles (Strack, J. P. DeShazo et al. 2014). Estos resultados son consistentes con los reportados en trabajos previos sobre este mismo conjunto de datos.

El rendimiento moderado del *baseline* resulta favorable para los objetivos de esta investigación. Un modelo con un techo de rendimiento excesivamente alto (por encima de 0,95) haría que cualquier degradación por privacidad fuera dramática y difícil de analizar de forma gradual. Con un *baseline* de aproximadamente 0,63, existe un margen suficiente para observar y cuantificar cómo las distintas técnicas de anonimización degradan progresivamente la capacidad predictiva sin provocar un colapso inmediato del modelo.

Cabe señalar que el modelo de Naive Bayes (Gaussian) muestra un rendimiento notablemente inferior al resto. Esto se debe en parte a que, a diferencia de los otros tres modelos que incorporan `class_weight='balanced'` para compensar el desbalanceo de clases, el clasificador `GaussianNB` de *scikit-learn* no soporta este parámetro de forma nativa, lo que lo hace más sensible a la distribución asimétrica de la variable objetivo.

Estos valores se establecen formalmente como las **cotas máximas de utilidad**. Cualquier modelo entrenado posteriormente sobre datos perturbados sintácticamente (vía ARX) o mediante ruido algorítmico (vía Privacidad Diferencial) será comparado contra estos registros para calcular el *trade-off* exacto entre privacidad y utilidad de esta investigación.

3.6. Aplicación de Privacidad Sintáctica mediante ARX

Una vez establecida la cota de utilidad sobre los datos en claro, la siguiente fase consiste en aplicar las garantías de privacidad sintáctica formalizadas en el Capítulo 2. Para ello se ha empleado la herramienta **ARX Data Anonymization Tool** (Prasser y Kohlmayer 2015), una solución de código abierto desarrollada por la Technische Universität München y referente metodológico en la literatura de privacidad de datos sanitarios. ARX implementa de forma nativa el algoritmo **Flash** (Kohlmayer et al. 2012), una variante optimizada de los métodos clásicos de búsqueda en el retículo de generalizaciones, así como otras heurísticas que permiten obtener soluciones globalmente óptimas para los criterios de privacidad seleccionados.

La elección de ARX frente a alternativas como **Amnesia** o implementaciones basadas en Mondrian sobre Python obedece a tres motivos: (i) ofrece una interfaz gráfica que facilita la auditoría visual del retículo de generalizaciones y de las clases de equivalencia resultantes; (ii) permite la combinación de múltiples criterios de privacidad de forma simultánea (*k*-anonimidad, *l*-diversidad, *t*-cercanía); y (iii) es la herramienta empleada en numerosos estudios reproducibles del ámbito sanitario, lo que facilita la comparación de resultados con la literatura existente.

3.6.1. Configuración de atributos

Siguiendo la taxonomía de privacidad establecida en la sección de perfilado, se configuraron los atributos del conjunto de datos en ARX según los cuatro tipos canónicos que admite la herramienta, tal como se detalla en la Tabla 3.2.

Tabla 3.2: Configuración de atributos en ARX para el conjunto de datos clínico.

Tipo en ARX	Atributo(s)	Justificación
Quasi-identifying	race, gender, age, time_in_hospital, admission_type_id	Combinación de cinco atributos identificada en el perfilado de riesgo basal como vector de reidentificación realista.
Insensitive	41 atributos restantes (incluida readmitted)	Variables clínicas y de medicación que se conservan sin transformación para preservar la utilidad analítica del modelo. La variable objetivo <code>readmitted</code> se trata como Insensitive en esta fase porque su protección se aborda específicamente mediante Privacidad Diferencial en la fase posterior; aplicar l -diversidad sobre ella en el mismo experimento mezclaría dos efectos y dificultaría la atribución de la pérdida de utilidad a una técnica concreta.

La decisión de no marcar `readmitted` como *Sensitive* en ARX merece una nota metodológica: hacerlo obligaría a definir un criterio de privacidad adicional (típicamente l -diversidad o t -cercanía) que actuaría sobre la distribución de la variable objetivo dentro de cada clase de equivalencia. Esto introduciría un segundo eje de variación no deseado en este experimento, cuya pregunta de investigación se centra exclusivamente en cuantificar el impacto de la generalización sobre los cuasi-identificadores. La protección frente a inferencia de la variable objetivo se aborda en una fase posterior a través del ruido controlado de la Privacidad Diferencial. La aplicación combinada de l -diversidad y t -cercanía sobre `readmitted` queda recogida como línea de trabajo futura en el Capítulo 5.

3.6.2. Jerarquías de Generalización

Para cada cuasi-identificador se diseñó una jerarquía de generalización que define los niveles de abstracción que ARX puede aplicar para conformar las clases de equivalencia. El criterio rector ha sido preservar la semántica clínica y demográfica en los niveles intermedios, evitando saltos artificiales que comprometan la interpretabilidad. La Tabla 3.3 resume las jerarquías construidas.

Tabla 3.3: Jerarquías de generalización empleadas en ARX.

QID	Niveles	Estrategia de generalización
race	3	Original $\rightarrow$ binario <i>White/NonWhite</i> $\rightarrow$ supresión total (*).
gender	1	Supresión directa cuando sea necesario; incluye la categoría <i>Unknown/Invalid</i> presente en el dataset original.
age	3	Deciles originales $\rightarrow$ tramos de 20 años $\rightarrow$ tramos de 40 años $\rightarrow$ *.
time_in_hospital	3	Días individuales $\rightarrow$ bins de 2–3 días $\rightarrow$ bins de 7 días $\rightarrow$ *.
admission_type_id	3	Códigos UCI $\rightarrow$ etiquetas semánticas (<i>Urgente/Electivo/Newborn/Desconocido</i>) $\rightarrow$ binario <i>Conocido/Desconocido</i> $\rightarrow$ *.

El diseño de tres niveles permite a ARX seleccionar dinámicamente el grado de generalización óptimo para cada clase de equivalencia, minimizando la pérdida de información mientras se cumple el criterio de privacidad solicitado.

3.6.3. Modelo de supresión y métrica de utilidad

ARX permite combinar generalización con supresión local de registros que no encajan en ninguna clase de equivalencia válida. En este trabajo se ha empleado el criterio por defecto de la herramienta: se permite hasta un 100 % de supresión cuando matemáticamente sea necesario, dejando que el optimizador encuentre el punto de equilibrio entre supresión y generalización. La métrica de utilidad seleccionada es la *Loss metric* (Iyengar 2002), que cuantifica la pérdida de información agregando, para cada celda, la fracción del rango de valores que la generalización engloba. Esta métrica es continua, monótona y permite comparar de forma uniforme distintos niveles de k .

3.6.4. Barrido de parámetros y exportación

Con el objetivo de caracterizar la curva de degradación de la utilidad en función de la fortaleza de la garantía de privacidad, se ha aplicado un barrido sobre cinco valores de k : $k \in \{2, 5, 10, 25, 50\}$. La justificación de este intervalo es la siguiente:

- $k = 2$ representa el umbral mínimo de privacidad sintáctica (cada registro indistinguible de al menos otro) y permite calibrar la sensibilidad de los modelos a una protección débil.
- $k = 5$ es el umbral recomendado en la literatura de privacidad sanitaria ([«Secure Data Sharing in Machine Learning: Exploring K-Anonymization and Differential Privacy» 2024](#)) y suele adoptarse como referencia regulatoria.

- $k = 10$ refuerza la garantía a un nivel comúnmente exigido en publicaciones de micro-datos.
- $k = 25$ y $k = 50$ exploran el extremo de máxima protección, donde la pérdida de utilidad es esperable que sea severa pero proporciona un punto de comparación frente a la Privacidad Diferencial con ϵ bajos.

Para cada valor de k se ha exportado el conjunto anonimizado en formato CSV (separador ;) bajo el patrón `arx_output_k<k>.csv`. El conjunto de prueba (20% del total, 19.611 registros) se mantiene sin anonimizar y conserva los valores originales de los cuasi-identificadores; esta decisión refleja un escenario realista en el que el modelo se entrena sobre datos protegidos pero recibe en producción consultas con información en claro.

3.6.5. Reentrenamiento y métrica de comparación

Tras la anonimización, cada conjunto `arx_output_k<k>.csv` se reincorpora al pipeline de *Machine Learning* aplicando la misma codificación *One-Hot Encoding* y estandarización utilizadas en el *baseline*. Un punto metodológico crítico de esta fase es la garantía de que el espacio de características (column space) sea idéntico entre el conjunto de entrenamiento anonimizado y el conjunto de prueba en claro. Para ello, se aplica el OHE de manera *conjunta* sobre la concatenación de ambos subconjuntos, preservando así la coherencia dimensional necesaria para la transferencia del modelo entrenado al espacio de evaluación.

Sobre cada versión anonimizada se reentrenan los cuatro modelos de referencia (Regresión Logística, Random Forest, Árbol de Decisión y Naive Bayes Gaussian) con los mismos hiperparámetros del *baseline*, y se computan las métricas globales de *Accuracy* y *F1-Score* ponderado, junto con dos métricas de diagnóstico de privacidad: el porcentaje de filas suprimidas por ARX y el número de filas efectivas tras la supresión. Adicionalmente, para cuantificar el impacto en la equidad algorítmica, se desagregan las métricas por subgrupo de la variable *race* en el conjunto de prueba, calculando la *Loss Disparity* respecto al *baseline* (Bagdasaryan, Poursaeed y Shmatikov 2019). Esta desagregación permite responder a la pregunta de investigación sobre si la generalización afecta de forma desproporcionada a los grupos minoritarios, en línea con las recomendaciones del docx guía y de la literatura reciente sobre justicia algorítmica ([«Privacy, Utility and Fairness: Navigating Trade-offs in Differentially Private Machine Learning» 2025](#)).

3.7. Aplicación de Privacidad Diferencial mediante `diffprivlib`

Una vez caracterizada la fase sintáctica, se aborda la integración de **Privacidad Diferencial (DP)** en el ciclo de entrenamiento de los modelos de aprendizaje automático. A diferencia de la k -anonimidad, que opera sobre los microdatos antes del entrenamiento mediante generalización y supresión, la Privacidad Diferencial introduce ruido matemáticamente calibrado durante la estimación de los parámetros del modelo, garantizando que la presencia o ausencia de un único registro tenga un impacto acotado por el presupuesto de privacidad ϵ (Dwork et al. 2006; Dwork 2006).

3.7.1. Selección de la librería y modelos privados

Se ha empleado la librería **IBM Diffprivlib** (Holohan et al. 2019) en su versión 0,6,6, por su API directamente compatible con `scikit-learn` y por su implementación nativa de los mecanismos de Laplace y Gauss para la inyección de ruido en algoritmos clásicos de *Machine Learning*. La elección se justifica además por la coherencia metodológica que aporta al permitir reutilizar el mismo *pipeline* de codificación, estandarización y evaluación que se utilizó en el *baseline* y en la fase ARX.

La selección de los modelos a privatizar se ha realizado a partir de la lectura de los resultados de la fase sintáctica recogidos en el Capítulo 4. De los cuatro algoritmos del *baseline*, los dos que mejor justifican la comparativa simétrica son **Regresión Logística** y **Naive Bayes Gaussian**, por tres motivos:

- Constituyen los **dos extremos del espectro de robustez** observado bajo k -anonimidad: la Regresión Logística mostró una invariancia prácticamente total ($\Delta_{\text{Accuracy}} \in [-0,07\%, +0,45\%]$) mientras que Naive Bayes fue el modelo más sensible ($\Delta_{\text{F1}} = -25\%$ a $k = 50$). Replicar el experimento con DP permite contrastar si esa polaridad se mantiene cuando la perturbación es de ruido en vez de generalización.
- Ambos disponen de **implementación nativa** en `diffprivlib` (`LogisticRegression` y `GaussianNB`) con la misma firma de API que sus homólogos de *scikit-learn*, lo que garantiza una comparativa simétrica metodológicamente impecable.
- Random Forest y Decision Tree existen en `diffprivlib` pero con parámetros internos distintos a sus homólogos de *scikit-learn* (el bosque aleatorio diferencialmente privado utiliza divisiones aleatorias sin *bootstrap*), por lo que su inclusión introduciría ruido metodológico en la comparación cruzada con el *baseline*.

3.7.2. Calibración de la sensibilidad y modelo de ruido

La inyección de ruido en `diffprivlib` requiere especificar la cota de sensibilidad de las funciones de coste, parametrizada de forma distinta según el algoritmo:

- **Regresión Logística diferencialmente privada:** requiere el parámetro `data_norm`, que representa la norma L_2 máxima esperada de los vectores de entrada. La librería utiliza este valor para acotar la sensibilidad de la función de pérdida y calibrar el ruido de Laplace inyectado en el optimizador. Sobre los datos de entrenamiento estandarizados ($\mu = 0$, $\sigma = 1$), el percentil 99 de la norma alcanza valores muy superiores a la mediana debido a la cola larga de variables clínicas como `num_lab_procedures`. Para evitar una sobrecalibración del ruido, se ha adoptado el **percentil 95 de la norma L_2 del conjunto de entrenamiento escalado** (`data_norm` $\approx 16,04$), confiando en el mecanismo interno de `diffprivlib` que recorta a esta cota las filas que la excedan. Este criterio de *clipping* percentilar es coherente con la práctica recomendada por Abadi et al. (Abadi et al. 2016) para algoritmos diferencialmente privados.
- **Naive Bayes Gaussian diferencialmente privado:** requiere el parámetro `bounds`, que define el rango por característica para acotar las estimaciones de media y varianza por clase. Análogamente al caso anterior, se han adoptado como cotas inferiores y superiores los **percentiles 1 y 99** de cada característica del conjunto de entrenamiento escalado, en lugar de los valores extremos absolutos, para evitar que un único registro atípico inflar artificialmente el ruido inyectado.

3.7.3. Barrido del presupuesto de privacidad

Para caracterizar la curva de degradación de la utilidad en función de la fortaleza de la garantía de privacidad, se ha realizado un barrido sobre cinco valores de ϵ , cubriendo de forma logarítmica el intervalo recomendado por la literatura del campo: $\epsilon \in \{0,1, 0,5, 1, 5, 10\}$. La elección del rango sigue las recomendaciones del docx guía y se justifica como sigue:

- $\epsilon = 0,1$ representa una protección **muy fuerte**, próxima al límite operativo de la DP en escenarios con datos de alta dimensionalidad.
- $\epsilon = 0,5$ y $\epsilon = 1$ son los **valores canónicos** más utilizados en aplicaciones de privacidad estadística.
- $\epsilon = 5$ y $\epsilon = 10$ describen el extremo **moderado**, donde la protección formal se mantiene pero el ruido es lo suficientemente reducido como para que la utilidad converja al *baseline*.

3.7.4. Repeticiones y métricas de estabilidad

A diferencia de los métodos sintácticos, la Privacidad Diferencial es un proceso **estocástico**: cada entrenamiento produce un modelo distinto debido al ruido aleatorio inyectado. Para obtener estimaciones estadísticamente robustas, cada combinación de modelo y ϵ se ha entrenado y evaluado **cinco veces** con semillas distintas (`random_state` $\in \{42, 43, 44, 45, 46\}$), reportándose la media y desviación típica de *Accuracy* y *F1-Score*. Adicionalmente, para la Regresión Logística diferencialmente privada se ha fijado `max_iter`= 100, valor que en pruebas preliminares garantizó la convergencia sin penalizar el rendimiento del optimizador L-BFGS bajo ruido.

El total de experimentos en esta fase asciende a 5 valores de $\epsilon \times 5$ repeticiones $\times$ 2 modelos = 50 entrenamientos, sobre los que se realizan dos análisis: (i) una comparativa de la curva de degradación promedio frente al *baseline*, y (ii) un análisis de equidad por subgrupo **race** replicando la metodología utilizada en la fase ARX. Esta segunda dimensión es especialmente relevante en el contexto de DP, dado que la literatura ha advertido que el ruido puede exacerbar la disparidad demográfica preexistente (Bagdasaryan, Poursaeed y Shmatikov 2019; «Privacy, Utility and Fairness: Navigating Trade-offs in Differentially Private Machine Learning» 2025).

Capítulo 4

Resultados

Este capítulo presenta el análisis cuantitativo del impacto de las técnicas de anonimización aplicadas a los datos clínicos. Siguiendo la estrategia definida en el Capítulo 3, los resultados se exponen en torno a tres ejes: la degradación global de las métricas de utilidad de los modelos, la cuantificación del riesgo residual mediante las propiedades estructurales del conjunto anonimizado, y el análisis de la equidad algorítmica desagregado por subgrupos demográficos. La interpretación de cada bloque se contrasta con las predicciones teóricas de la literatura recogida en el Capítulo 2.

4.1. Resultados de la Aplicación de k -Anonimidad mediante ARX

Tras configurar la herramienta ARX según los parámetros descritos en la Sección 3.6 y ejecutar el barrido $k \in \{2, 5, 10, 25, 50\}$, se obtuvieron cinco versiones anonimizadas del conjunto de entrenamiento. La Tabla 4.1 resume los efectos estructurales de cada nivel de privacidad sobre los datos.

Tabla 4.1: Efectos estructurales de la aplicación de k -anonimidad sobre el conjunto de entrenamiento (78.442 registros).

k	Filas suprimidas	% Supresión	Clases de equiv.	$k_{\text{mín}}$	$k_{\text{máx}}$
2	918	1,17 %	2.388	2	757
5	1.467	1,87 %	888	5	1.412
10	3.204	4,08 %	630	10	1.412
25	4.079	5,20 %	292	25	2.396
50	3.972	5,06 %	220	50	2.396

El comportamiento del optimizador de ARX revela un patrón coherente con la teoría: para valores bajos de k , la herramienta prioriza la **supresión local** de los registros singulares por encima de la generalización global, ya que la métrica *Loss* considera más costoso degradar

todas las celdas que eliminar un pequeño porcentaje de filas atípicas. A medida que el umbral de privacidad se incrementa, este equilibrio se desplaza progresivamente hacia la generalización, como se detalla en la Tabla 4.2.

Tabla 4.2: Niveles de generalización efectivamente aplicados por ARX en cada cuasi-identificador. Un valor de 0 indica que el atributo conserva su granularidad original; las anotaciones entre paréntesis describen la abstracción aplicada en el primer nivel.

Cuasi-identificador	$k = 2$	$k = 5$	$k = 10$	$k = 25$	$k = 50$
race	0	0	0	0	1 (<i>White/NonWhite</i>)
gender	0	0	0	0	0
age	0	0	0	1 (tramos 20 años)	1
time_in_hospital	0	1 (bins 2–3 días)	1	1	1
admission_type_id	0	0	0	0	0

Este escalonamiento empírico es relevante en el dominio clínico: confirma que ARX preserva la granularidad de los atributos demográficos (**race**, **gender**, **age**) hasta los umbrales más exigentes, y antes recurre a generalizar variables de carácter operativo (**time_in_hospital**). La variable **gender** y **admission_type_id** permanecen sin generalización en todo el barrido, lo que implica que la cardinalidad reducida de estos atributos era ya naturalmente compatible con los criterios de privacidad gracias a la supresión de los valores atípicos (como *Unknown/Invalid* en **gender** o el código 4 *Newborn* en **admission_type_id**).

4.2. Impacto sobre la Utilidad Predictiva de los Modelos

Sobre cada uno de los conjuntos anonimizados se reentrenaron los cuatro modelos de referencia descritos en el Capítulo 3 y se evaluaron contra el conjunto de prueba inalterado (19.611 registros). La Tabla 4.3 y la Tabla 4.4 recogen las métricas de *Accuracy* y *F1-Score* ponderado, respectivamente, comparando el escenario *baseline* ($k = 0$) con cada nivel de anonimización.

Tabla 4.3: *Accuracy* de los modelos sobre el conjunto de prueba en función del nivel de privacidad sintáctica.

Modelo	$k = 0$	$k = 2$	$k = 5$	$k = 10$	$k = 25$	$k = 50$
Random Forest	0,6300	0,6257	0,6288	0,6264	0,6270	0,6294
Regresión Logística	0,6178	0,6185	0,6189	0,6182	0,6200	0,6206
Árbol de Decisión	0,6138	0,6132	0,6125	0,6168	0,5971	0,5960
Naive Bayes (Gaussian)	0,5912	0,5944	0,5568	0,5575	0,5575	0,5499

La Figura 4.1 representa gráficamente la curva de degradación obtenida, permitiendo visualizar de un solo vistazo el comportamiento diferencial de cada familia algorítmica frente al incremento de la garantía de privacidad.

Tabla 4.4: $F1$ -Score ponderado de los modelos sobre el conjunto de prueba en función del nivel de privacidad sintáctica.

Modelo	$k = 0$	$k = 2$	$k = 5$	$k = 10$	$k = 25$	$k = 50$
Random Forest	0,6277	0,6250	0,6280	0,6258	0,6268	0,6278
Regresión Logística	0,6159	0,6166	0,6169	0,6159	0,6167	0,6157
Árbol de Decisión	0,6138	0,6136	0,6129	0,6139	0,5975	0,5965
Naive Bayes (Gaussian)	0,5599	0,5689	0,4497	0,4536	0,4543	0,4207




Figura 4.1: Degradación de $Accuracy$ (izquierda) y $F1$ -Score ponderado (derecha) de los cuatro modelos a lo largo del barrido $k \in \{0, 2, 5, 10, 25, 50\}$. El eje de abscisas se representa en escala simétrica logarítmica para resaltar la zona de transición.

4.2.1. Robustez de los modelos lineales y de *ensemble*

Random Forest y Regresión Logística exhiben una robustez notable frente a la anonimización sintáctica: incluso bajo el escenario más restrictivo ($k = 50$), la pérdida absoluta de $Accuracy$ es inferior al 0,7% (Random Forest) y prácticamente nula en Regresión Logística (de hecho, esta última experimenta una mejora marginal de +0,28 puntos respecto al *baseline*). Este comportamiento contradice la asunción intuitiva de que toda generalización degrada la utilidad y se explica por dos mecanismos complementarios. Por un lado, la generalización actúa como una técnica de regularización implícita que reduce la varianza del modelo al eliminar variabilidad espuria de los cuasi-identificadores. Por otro lado, los modelos lineales y los *ensembles* de árboles capturan principalmente la señal predictiva en variables clínicas (medicaciones, número de procedimientos, diagnósticos) que la herramienta no anonimiza, por lo que el deterioro de los QID demográficos apenas afecta a la frontera de decisión aprendida.

4.2.2. Sensibilidad diferencial entre familias algorítmicas

El comportamiento del Naive Bayes Gaussian contrasta de forma marcada con el resto: ya en $k = 5$ pierde un 5,8 % de *Accuracy* y un 19,7 % de *F1-Score* ponderado, alcanzando una pérdida del -25 % en *F1* a $k = 50$. Este desplome se explica por la asunción de independencia condicional entre características que asume el algoritmo. La generalización categórica introducida por ARX agrupa valores que originalmente eran independientes en una misma celda (por ejemplo, los catorce días individuales de `time_in_hospital` colapsan en cinco bins ordinales), lo que rompe la asunción y desplaza las distribuciones gaussianas estimadas en el entrenamiento. Adicionalmente, este modelo no admite el parámetro `class_weight=balanced`, agravando su sensibilidad al desbalanceo (Strack, J. P. DeShazo et al. 2014).

El Árbol de Decisión presenta un patrón intermedio especialmente revelador: se mantiene estable hasta $k = 10$ (con una mejora puntual de +0,3 % de *Accuracy* a $k = 10$ explicable por el efecto regularizador de la supresión de *outliers*) y experimenta una caída abrupta de -2,7 % a -2,9 % a partir de $k = 25$. Este punto de inflexión coincide exactamente con el momento en que ARX comienza a generalizar la variable `age` de deciles a tramos de 20 años, reduciendo de manera abrupta la cardinalidad disponible para los *splits* del árbol. La observación es coherente con el análisis teórico de Sweeney (Sweeney 2002) sobre el impacto de la cardinalidad en los algoritmos basados en particiones recursivas.

4.2.3. Implicaciones para la selección de modelos en entornos privados

Los resultados anteriores refuerzan una recomendación práctica clave para la fase de *benchmarking* privacidad-utilidad de un proyecto de ciencia de datos: la elección del algoritmo de aprendizaje es tan determinante como el parámetro de privacidad seleccionado. Los modelos lineales y los *ensembles* presentan una superficie de pérdida casi plana frente a la anonimización sintáctica, lo que los convierte en candidatos preferentes en escenarios donde la publicación de microdatos sea un requisito regulatorio (por ejemplo, en repositorios sanitarios). Por el contrario, los modelos generativos paramétricos como Naive Bayes deberían reservarse para escenarios en los que el conjunto de entrenamiento mantenga la granularidad original.

4.3. Análisis de Equidad Algorítmica

La literatura reciente sobre privacidad y aprendizaje automático ha alertado de que las garantías formales de privacidad pueden tener un impacto desproporcionado sobre los grupos demográficos minoritarios (Bagdasaryan, Poursaeed y Shmatikov 2019; «Privacy, Utility and Fairness: Navigating Trade-offs in Differentially Private Machine Learning» 2025). Para evaluar empíricamente esta hipótesis en el contexto de la anonimización sintáctica, se desagregaron las métricas de utilidad de la Regresión Logística (modelo de referencia más estable del barrido) por subgrupo de la variable **race** en el conjunto de prueba. La Tabla 4.5 presenta los resultados.

Tabla 4.5: *Accuracy* de la Regresión Logística sobre el conjunto de prueba desagregada por subgrupo **race**.

Subgrupo	n_{test}	$k = 0$	$k = 2$	$k = 5$	$k = 10$	$k = 25$	$k = 50$
Caucasian	14.970	0,6157	0,6156	0,6159	0,6150	0,6176	0,6184
AfricanAmerican	3.821	0,6210	0,6218	0,6229	0,6231	0,6208	0,6210
Hispanic	410	0,6585	0,6732	0,6707	0,6707	0,6683	0,6634
Other	295	0,6305	0,6475	0,6508	0,6441	0,6542	0,6610
Asian	115	0,6087	0,6174	0,6087	0,6174	0,6435	0,6348
Loss Disparity*	—	0,0498	0,0576	0,0620	0,0557	0,0507	0,0450

* Diferencia entre el subgrupo con mayor y menor *Accuracy* en cada nivel de k . Valores menores indican mayor equidad.

La Figura 4.2 muestra la evolución de la *Accuracy* por subgrupo a lo largo del barrido, junto con la línea media del *baseline* como referencia.

4.3.1. La k -anonimidad no exacerba la disparidad demográfica

El hallazgo más relevante de este análisis es que la métrica *Loss Disparity* **no se incrementa monótonamente con el nivel de privacidad**, contrariamente a lo que prediría la extrapolación directa de los resultados de Bagdasaryan et al. (Bagdasaryan, Poursaeed y Shmatikov 2019) para la Privacidad Diferencial. La disparidad parte de 0,0498 en el *baseline*, alcanza un máximo de 0,0620 en $k = 5$ y desciende progresivamente hasta 0,0450 en $k = 50$, situándose por debajo del valor original.

Este comportamiento se explica por un mecanismo cualitativamente distinto al del ruido diferencial: mientras que la inyección de ruido de Laplace o Gauss penaliza desproporcionadamente a las muestras minoritarias por amplificar el error en regiones de baja densidad estadística, la generalización sintáctica **homogeneiza** la representación de los grupos al colapsar valores demográficos en categorías más amplias. El efecto neto es que los subgrupos minoritarios (Hispanic, Other, Asian) experimentan mejoras de *Accuracy* de +2,2 %, +4,8 % y +4,3 % respectivamente bajo $k = 50$, frente al +0,4 % del grupo mayoritario (Caucasian).




Figura 4.2: Disparidad de utilidad de la Regresión Logística por subgrupo **race** a lo largo del barrido $k \in \{0, 2, 5, 10, 25, 50\}$. Las leyendas indican el tamaño n de cada subgrupo en el conjunto de prueba. La línea discontinua marca la *Accuracy* media del *baseline*.

4.3.2. Interpretación: regularización implícita en grupos minoritarios

El fenómeno observado puede racionalizarse desde una perspectiva estadística estándar. Los subgrupos minoritarios, al estar subrepresentados en el conjunto de entrenamiento, son especialmente susceptibles al sobreajuste por parte de modelos como la Regresión Logística cuando se entrenan sobre datos en claro: el modelo memoriza patrones idiosincráticos que no generalizan al subconjunto de prueba. La generalización aplicada por ARX — al colapsar valores raros en categorías más comunes — actúa como una forma de regularización dirigida que mejora precisamente la capacidad de generalización del modelo sobre estos grupos. Este hallazgo es coherente con observaciones recientes en la literatura sobre el efecto regularizador de las técnicas de privacidad sintáctica ([«Secure Data Sharing in Machine Learning: Exploring K-Anonymization and Differential Privacy» 2024](#)) y constituye un argumento empírico importante a favor de la k -anonimidad como técnica complementaria de la Privacidad Diferencial en escenarios sensibles a la equidad.

4.4. Síntesis de la Fase Sintáctica

Los resultados de esta fase permiten extraer tres conclusiones operativas que orientarán las fases subsiguientes del estudio (Privacidad Diferencial, datos sintéticos y auditoría adversarial):

1. **La k -anonimidad es prácticamente gratuita en utilidad para este caso de uso.** Con un valor de $k = 10$, frecuentemente recomendado en publicaciones sanitarias, la pérdida de *Accuracy* es inferior al 0,6% tanto en Random Forest como en Regresión Logística. Esto implica que un modelo de readmisión hospitalaria entrenado sobre microdatos publicables cumpliría con los estándares de privacidad sin sacrificar capacidad predictiva apreciable.
2. **La cota teórica de utilidad establecida en el *baseline* se mantiene esencialmente intacta hasta $k = 10$ y se erosiona moderadamente a partir de $k = 25$.** Este hallazgo justifica seleccionar $k = 10$ como referente para la comparativa cruzada con los algoritmos de Privacidad Diferencial en la Sección siguiente: ofrece un nivel de protección sólido sin distorsionar materialmente las distribuciones aprendidas.
3. **El análisis de equidad refuerza la necesidad de no descartar la k -anonimidad como técnica obsoleta.** Aunque la literatura tiende a presentarla como un paso intermedio hacia garantías matemáticas más fuertes, su impacto positivo sobre la disparidad demográfica la posiciona como una herramienta valiosa cuando la equidad sobre grupos minoritarios es un requisito explícito del proyecto, especialmente combinada con auditorías de inferencia de membresía como las que se desarrollarán en la fase final del trabajo.

Estas conclusiones establecen una línea base contrastable contra la cual se evaluarán los resultados de la integración de Privacidad Diferencial en la fase siguiente del estudio, así como las técnicas de generación de datos sintéticos. La pregunta abierta que surge de este capítulo, y que motiva las siguientes secciones, es si la inyección de ruido controlado puede igualar la robustez observada con k -anonimidad sin reproducir los efectos adversos sobre la equidad descritos por Bagdasaryan (Bagdasaryan, Poursaeed y Shmatikov 2019).

4.5. Resultados de la Aplicación de Privacidad Diferencial

Tras configurar la fase diferencialmente privada según el protocolo descrito en la Sección 3.7, se ejecutaron 50 experimentos correspondientes al producto cartesiano de cinco valores de ϵ , cinco repeticiones por punto y dos modelos (*Regresión Logística* y *Naive Bayes Gaussian*). Esta sección presenta los resultados agregados, los compara contra el *baseline* y la fase ARX, y discute las implicaciones sobre la equidad algorítmica.

4.5.1. Curva de degradación de la utilidad

La Tabla 4.6 y la Tabla 4.7 recogen las métricas medias de *Accuracy* y *F1-Score* ponderado, junto con la desviación típica calculada sobre las cinco corridas independientes de cada combinación.

Tabla 4.6: *Accuracy* (mean $\pm$ std, $n = 5$) de los modelos diferencialmente privados sobre el conjunto de prueba.

Modelo	$\epsilon = 0,1$	$\epsilon = 0,5$	$\epsilon = 1$	$\epsilon = 5$	$\epsilon = 10$
Regresión Logística	$0,5282 \pm 0,007$	$0,5671 \pm 0,005$	$0,5928 \pm 0,004$	$0,5987 \pm 0,022$	$0,6180 \pm 0,001$
Naive Bayes (Gaussian)	$0,5135 \pm 0,023$	$0,5167 \pm 0,019$	$0,5339 \pm 0,022$	$0,5616 \pm 0,028$	$0,5780 \pm 0,012$

Tabla 4.7: *F1-Score* ponderado (mean $\pm$ std, $n = 5$) de los modelos diferencialmente privados.

Modelo	$\epsilon = 0,1$	$\epsilon = 0,5$	$\epsilon = 1$	$\epsilon = 5$	$\epsilon = 10$
Regresión Logística	$0,5274 \pm 0,006$	$0,5664 \pm 0,005$	$0,5899 \pm 0,004$	$0,5938 \pm 0,019$	$0,6075 \pm 0,001$
Naive Bayes (Gaussian)	$0,4622 \pm 0,046$	$0,5076 \pm 0,021$	$0,5298 \pm 0,023$	$0,5482 \pm 0,038$	$0,5761 \pm 0,013$

La Figura 4.3 representa gráficamente la curva de degradación con bandas de error correspondientes a la desviación típica.

La curva exhibe el comportamiento monótono predicho por la teoría: la utilidad converge al *baseline* a medida que ϵ crece y, simétricamente, se degrada de forma severa cuando el presupuesto de privacidad se restringe. Cuantitativamente, la Regresión Logística pierde un 14,50 % de *Accuracy* a $\epsilon = 0,1$ y recupera prácticamente el rendimiento del *baseline* ($\Delta = +0,03\%$) a $\epsilon = 10$. Naive Bayes muestra un patrón similar pero con dos diferencias relevantes: (i) la curva no llega a converger al *baseline* ni siquiera a $\epsilon = 10$, conservando una pérdida residual del $-2,23\%$, y (ii) la varianza entre repeticiones es sustancialmente mayor (hasta $\sigma = 0,028$ en *Accuracy* y $\sigma = 0,046$ en *F1*), lo que indica que la dependencia del ruido aleatorio es más acusada que en el modelo lineal.




Figura 4.3: Degradación de *Accuracy* (izquierda) y *F1-Score* ponderado (derecha) en función del presupuesto de privacidad ϵ . Las barras de error corresponden a la desviación típica sobre cinco repeticiones por punto. Las líneas discontinuas indican los *baselines* sin privacidad.

4.5.2. Comparativa cruzada: Privacidad Diferencial frente a k -Anonimidad

La Figura 4.4 representa de forma conjunta las curvas de degradación de la Regresión Logística para ambas técnicas de privacidad sobre los mismos datos clínicos. El eje superior corresponde al barrido de k (incremento de privacidad sintáctica) y el eje inferior al barrido de ϵ (decremento de privacidad diferencial), por lo que ambas curvas se leen de izquierda (mayor privacidad) a derecha (menor privacidad).




Figura 4.4: Comparativa cruzada de las dos técnicas de privacidad sobre la Regresión Logística. La curva azul (eje inferior) representa Privacidad Diferencial; la curva verde (eje superior) representa k -anonimidad. La línea discontinua indica el *baseline* sin privacidad (0,6178).

El contraste entre las dos curvas permite extraer la conclusión empírica más relevante de este Trabajo Fin de Máster: **la pérdida de utilidad asociada a la k -anonimidad es prácticamente despreciable en este caso de uso, mientras que la Privacidad Diferencial impone un coste significativo en utilidad cuando se busca una protección formal estricta.** La curva verde de k -anonimidad permanece próxima al *baseline* en todo el rango ($\Delta \leq 0,5\%$), mientras que la curva azul de DP solo iguala al *baseline* a partir de $\epsilon = 10$, sufriendo pérdidas del 14,50 %, 8,21 % y 4,05 % a $\epsilon = 0,1$, $\epsilon = 0,5$ y $\epsilon = 1$, respectivamente.

Esta observación tiene una implicación práctica directa: la elección entre ambas técnicas no debe basarse exclusivamente en la fortaleza formal de la garantía (donde la DP es indiscutiblemente superior por su naturaleza matemática), sino que debe evaluar el coste real de utilidad en el caso de uso concreto. La k -anonimidad ofrece una protección efectiva contra ataques de enlace al coste de una pérdida casi nula, mientras que la DP debe reservarse para escenarios donde se requiera una garantía contra inferencia estadística agnóstica al modelo de atacante.

4.5.3. Impacto sobre la equidad: el patrón Bagdasaryan se confirma

A diferencia de lo observado en la fase k -anonimidad, donde la disparidad demográfica disminuyó con el nivel de privacidad, la Privacidad Diferencial reproduce el efecto adverso descrito por Bagdasaryan et al. (Bagdasaryan, Poursaeed y Shmatikov 2019): a presupuestos más restrictivos, los grupos minoritarios se ven desproporcionadamente afectados. La Tabla 4.8 desagrega la *Accuracy* de la Regresión Logística diferencialmente privada por subgrupo *race*.

Tabla 4.8: *Accuracy* (media de cinco repeticiones) de la Regresión Logística diferencialmente privada desagregada por subgrupo *race*. La última columna recoge la pérdida porcentual respecto al *baseline* a $\epsilon = 0,1$.

Subgrupo	n_{test}	$\epsilon = 0,1$	$\epsilon = 0,5$	$\epsilon = 1$	$\epsilon = 5$	$\epsilon = 10$	$\Delta_{\epsilon=0,1}$
Caucasian	14.970	0,5279	0,5648	0,5899	0,5956	0,6157	-14,26 %
AfricanAmerican	3.821	0,5292	0,5707	0,5956	0,6037	0,6206	-14,78 %
Hispanic	410	0,5288	0,6044	0,6361	0,6395	0,6595	-19,70 %
Other	295	0,5397	0,5939	0,6380	0,6319	0,6454	-14,40 %
Asian	115	0,5043	0,5443	0,6000	0,6000	0,6157	-17,15 %

La Figura 4.5 ilustra estas mismas curvas con bandas de error.

A $\epsilon = 0,1$, los subgrupos minoritarios *Hispanic* (-19,70 %) y *Asian* (-17,15 %) sufren una pérdida significativamente superior a la del grupo mayoritario *Caucasian* (-14,26 %). El subgrupo *Asian*, con sólo 115 individuos en el conjunto de prueba, es además el que presenta la mayor varianza entre repeticiones, lo que confirma que el ruido diferencial penaliza con mayor intensidad las regiones del espacio de características con menor densidad estadística.




Figura 4.5: Disparidad de utilidad de la Regresión Logística diferencialmente privada por subgrupo **race** a lo largo del barrido $\epsilon \in \{0.1, 0.5, 1, 5, 10\}$. Las barras de error corresponden a la desviación típica sobre cinco repeticiones.

Este resultado es coherente con la explicación teórica formulada por Bagdasaryan et al.: el mecanismo de Laplace añade ruido cuya magnitud es independiente del tamaño del subgrupo, por lo que en términos relativos su efecto es proporcionalmente mayor sobre las muestras minoritarias. La diferencia con la generalización aplicada por la k -anonimidad — que homogeneiza estructuralmente las representaciones — es cualitativa, no sólo cuantitativa.

4.5.4. Síntesis de la Fase Diferencial

Los resultados de esta fase consolidan tres aprendizajes fundamentales para el cierre del trabajo:

1. **La utilidad bajo Privacidad Diferencial es altamente dependiente del presupuesto ϵ .** Para alcanzar un nivel de utilidad equivalente al *baseline* en este caso de uso, el presupuesto debe situarse próximo a $\epsilon = 10$, frecuentemente considerado como un nivel de protección formal moderado en la literatura.
2. **Existe un compromiso entre garantía formal y utilidad práctica que no puede eludirse.** Mientras que la k -anonimidad protege contra ataques de enlace con una pérdida de utilidad casi nula, la garantía matemática más fuerte de la DP exige un coste explícito que debe ser asumido cuando el escenario lo requiera.
3. **La k -anonimidad y la Privacidad Diferencial tienen efectos cualitativamente opuestos sobre la equidad demográfica.** Combinar ambas técnicas en un esquema de defensa en profundidad podría compensar este efecto adverso de la DP, una hipótesis que se planteará como línea futura en el Capítulo 5.

Estos hallazgos completan la evaluación cuantitativa del dilema privacidad-utilidad y proporcionan la base empírica necesaria para el desarrollo del marco de recomendaciones que se presenta en el siguiente capítulo.

4.6. Defensa en Profundidad: Combinación de k -Anonimidad y Privacidad Diferencial

La síntesis de la fase diferencial (Sección 4.5.3) sugería que combinar ambas técnicas en un esquema de defensa en profundidad podría compensar el efecto adverso de la DP sobre los grupos minoritarios. Para evaluar empíricamente esta hipótesis, se ha replicado el sweep de DP ($\epsilon \in \{0,1,1,10\}$, cinco repeticiones) sobre el conjunto de entrenamiento previamente anonimizado con $k = 10$ (75.238 registros tras la supresión).

4.6.1. Comportamiento de la utilidad combinada

La Tabla 4.9 compara la *Accuracy* promedio de los dos modelos diferencialmente privados sobre datos en claro frente a la combinación con $k = 10$.

Tabla 4.9: *Accuracy* (mean $\pm$ std, $n = 5$) de DP solo vs combinación $k = 10 +$ DP.

Modelo	Configuración	$\epsilon = 0,1$	$\epsilon = 1$	$\epsilon = 10$
Regresión Logística	DP solo	$0,5282 \pm 0,007$	$0,5928 \pm 0,004$	$0,6180 \pm 0,001$
	$k = 10 +$ DP	$0,5158 \pm 0,009$	$0,4851 \pm 0,022$	$0,4840 \pm 0,020$
Naive Bayes (Gaussian)	DP solo	$0,5135 \pm 0,023$	$0,5339 \pm 0,022$	$0,5780 \pm 0,012$
	$k = 10 +$ DP	$0,5237 \pm 0,017$	$0,5213 \pm 0,033$	$0,5858 \pm 0,005$

Los resultados revelan dos hallazgos contrastados:

- En **Naive Bayes**, la combinación se comporta de forma esperable: ofrece resultados ligeramente mejores que DP solo a $\epsilon = 0,1$ (+1,0 pp) y a $\epsilon = 10$ (+0,8 pp), comportándose la generalización como un regularizador adicional. La hipótesis original se confirma parcialmente para este modelo.
- En **Regresión Logística**, en cambio, la combinación se traduce en un **colapso severo de la utilidad** a $\epsilon \geq 1$: la *Accuracy* cae hasta 0,48 incluso con presupuestos de privacidad permisivos ($\epsilon = 10$). Este resultado es contraintuitivo: con un ruido muy reducido, sería esperable que el modelo se aproximase al rendimiento de $k = 10$ sin DP (0,6182). Investigaciones de control mostraron que la causa es metodológica y no estadística: la implementación de DP en `diffprivlib.LogisticRegression` aplica una regularización fija calibrada matemáticamente para garantizar la cota de sensibilidad, que interactúa de forma desfavorable con el espacio de características ampliado tras la generalización (149 columnas *One-Hot Encoding* frente a las 121 originales).




Figura 4.6: Comparativa de utilidad de la Regresión Logística: DP solo (azul) frente a combinación $k = 10 + DP$ (verde). Las líneas discontinuas indican el *baseline* y el modelo $k = 10$ sin DP como referencias.

Concretamente, las nuevas columnas correspondientes a los valores generalizados (por ejemplo `time_in_hospital_[1-2]`) no aparecen en el conjunto de prueba, por lo que se convierten en dimensiones “muertas” que la regularización del DP penaliza desproporcionadamente.

4.6.2. Implicación: la defensa en profundidad no es trivial

Este hallazgo es metodológicamente relevante para el campo: **la combinación naïve de k -anonimidad y Privacidad Diferencial no garantiza una mejora del compromiso privacidad-utilidad** y, en algunos casos, puede degradar severamente la utilidad práctica. La causa, como se ha visto, no está en una incompatibilidad teórica entre las dos técnicas sino en cómo la implementación específica del DP interactúa con las transformaciones aplicadas previamente. Para combinar ambas técnicas de forma productiva, sería necesario adoptar una de las siguientes estrategias: (i) calibrar el DP sobre el espacio de características posterior a la anonimización, (ii) emplear una implementación de DP basada en DP-SGD (*Opacus*) que no impone regularización fija, o (iii) recurrir a esquemas de combinación más sofisticados como los descritos por la literatura reciente sobre *integrated DP and k-anonymity* (*Provably Private Data Anonymization: Or, k-Anonymity Meets Differential Privacy* 2010).

A nivel de equidad, la Figura 4.7 muestra que la combinación tampoco neutraliza la disparidad introducida por DP — al contrario, la *Loss Disparity* a $\epsilon = 0,1$ pasa de 0,0354 (DP solo) a 0,1225 (combinación), reforzando la conclusión sobre la necesidad de un diseño cuidadoso de la combinación. Esta línea queda explícitamente recogida como trabajo futuro en el Capítulo 5.




Figura 4.7: Disparidad de utilidad por subgrupo **race**: DP solo (izquierda) vs combinación $k = 10 + DP$ (derecha). En la combinación se observa que la varianza por subgrupo se incrementa a $\epsilon = 0,1$, especialmente en el grupo *Asian* de menor tamaño.

4.7. Auditoría Adversarial: Inferencia de Membresía con ART

Para validar empíricamente que las garantías formales de privacidad se traducen en protección efectiva frente a un atacante real, se ha realizado una auditoría adversarial mediante *Membership Inference Attacks (MIA)* utilizando el **Adversarial Robustness Toolbox (ART)** (Linux Foundation AI & Data 2018). La auditoría aborda la pregunta clave que debe responder cualquier técnica de privacidad: ¿puede un atacante con acceso a las predicciones del modelo determinar si un individuo concreto formó parte del conjunto de entrenamiento?

4.7.1. Configuración del experimento

Se ha empleado el ataque *MembershipInferenceBlackBox* con un clasificador de pertenencia tipo *Random Forest*, siguiendo la metodología establecida por Shokri et al. (Shokri et al. 2017). Para cada escenario, el atacante recibe un conjunto balanceado de 10.000 muestras del conjunto de entrenamiento (*members*) y 5.000 del conjunto de prueba (*non-members*), de los cuales utiliza la mitad para entrenarse y la mitad restante para evaluarse. Las dos métricas reportadas son: la *Attack Accuracy* (proporción de inferencias correctas, donde 0,5 = aleatorio) y la *Attack Advantage* (diferencia entre la tasa de *true positives* y la de *false positives*, donde 0 = ausencia de fuga).

4.7.2. Resultados de la auditoría

La Tabla 4.10 y la Figura 4.8 resumen los resultados del ataque sobre los cinco escenarios auditados.

Tabla 4.10: Auditoría adversarial mediante MIA Black-Box sobre Regresión Logística en distintos escenarios de privacidad.

Escenario	Utility Acc	Attack Acc	Attack Advantage	Diagnóstico
Baseline LR (sin privacidad)	0,6178	0,5541	-0,0068	Sin fuga detectable
LR · $k = 10$	0,6182	0,5609	+0,0084	Fuga marginal
LR · $k = 50$	0,6206	0,5701	+0,0332	Fuga marginal
LR · DP $\epsilon = 0,1$	0,5267	0,6616	+0,0024	Sin fuga detectable*
LR · DP $\epsilon = 10$	0,6173	0,5607	+0,0096	Fuga marginal

* La elevada *Attack Accuracy* se explica por el desbalance del conjunto auditor (el atacante predice “member” para la mayoría de las muestras), pero la *Advantage* próxima a cero indica que no extrae información estructural del modelo.




Figura 4.8: Resultados de la auditoría adversarial mediante MIA Black-Box. La línea discontinua en 0,5 marca el rendimiento aleatorio de un atacante; valores próximos a esta indican ausencia de fuga estructural.

El resultado fundamental de esta auditoría es que **ninguno de los escenarios evaluados muestra una fuga de información de membresía clínicamente significativa** (*Advantage* máxima +0,033, muy por debajo del umbral comúnmente considerado relevante en la literatura, +0,1). Esta observación tiene dos implicaciones importantes para la interpretación global del trabajo:

1. El *baseline* sin privacidad ya presenta una resistencia razonable frente a ataques de membresía sobre este conjunto de datos, lo que sugiere que el modelo de Regresión

Logística no sobreajusta de forma extrema al conjunto de entrenamiento — coherente con el rendimiento moderado del *baseline* (0,6178) que ya se discutió en el Capítulo 3.

2. Las técnicas de privacidad evaluadas (k -anonimidad y DP) no incrementan ostensiblemente la resistencia del modelo frente a este tipo concreto de ataque, dado que el riesgo basal es bajo. Esto no invalida la utilidad de las técnicas: la k -anonimidad protege específicamente frente a ataques de *enlace* (no de membresía), y la Privacidad Diferencial proporciona una garantía formal independiente del atacante concreto. Sin embargo, justifica la importancia de evaluar empíricamente el riesgo residual antes de aplicar protecciones potencialmente costosas en utilidad.

Esta conclusión es coherente con los hallazgos de la literatura reciente que advierten contra el *security theatre* en privacidad de datos ([«Membership Inference Attacks Against Synthetic Health Data» 2022](#)): las garantías formales son necesarias pero no siempre suficientes ni siempre necesarias en función del modelo de amenaza realista del caso de uso concreto.

4.8. Tests de Significancia Estadística

Para reforzar el rigor cuantitativo de las conclusiones del capítulo, se han ejecutado dos baterías de tests estadísticos no paramétricos: (i) tests de **McNemar** para comparar las predicciones del *baseline* con las de cada modelo k -anonimizado, y (ii) tests de **Wilcoxon de una muestra** para comparar la *Accuracy* promedio de los modelos diferencialmente privados con el *baseline* de referencia.

4.8.1. Test de McNemar para los modelos k -anonimizados

El test de McNemar es la herramienta estándar para evaluar si dos clasificadores difieren significativamente en sus predicciones sobre el mismo conjunto de prueba. La Tabla 4.11 resume los resultados.

Tabla 4.11: Test de McNemar entre el *baseline* y cada modelo k -anonimizado. b representa los casos en que el *baseline* acierta y el modelo anonimizado falla; c los inversos. Significativo: $p < 0,05$.

Modelo	k	b	c	p -valor	Significativo
Regresión Logística	2	604	617	0,731	No
	5	574	595	0,559	No
	10	586	593	0,861	No
	25	715	757	0,285	No
	50	760	815	0,174	No
Random Forest	2	586	502	0,012	Sí
	5	512	490	0,507	No
	10	599	530	0,043	Sí
	25	793	735	0,145	No
	50	515	504	0,754	No
Árbol de Decisión	2	792	780	0,781	No
	5	907	881	0,554	No
	10	1.656	1.716	0,310	No
	25	2.772	2.444	$\sim 10^{-6}$	Sí
	50	2.740	2.391	$\sim 10^{-6}$	Sí
Naive Bayes	2	220	282	0,006	Sí
	5	1.997	1.323	$\sim 10^{-31}$	Sí
	10	1.942	1.282	$\sim 10^{-31}$	Sí
	25	1.937	1.277	$\sim 10^{-31}$	Sí
	50	2.361	1.552	$\sim 10^{-38}$	Sí

Los tests confirman cuantitativamente la lectura cualitativa de las secciones anteriores: **la Regresión Logística no presenta diferencias estadísticamente significativas frente al *baseline* en ningún nivel de k** , validando la hipótesis de invariancia de este modelo frente a la generalización sintáctica. En el extremo opuesto, **Naive Bayes muestra diferencias estadísticamente significativas a partir de $k = 2$** , lo que confirma su sensibilidad

estructural al colapso de cardinalidad en las variables categóricas. El Árbol de Decisión transita entre ambos comportamientos, siendo invariante hasta $k = 10$ y mostrando diferencias significativas a partir de $k = 25$, en coincidencia exacta con el punto de inflexión empírico identificado en la subsección 4.5.1.

4.8.2. Test de Wilcoxon para los modelos diferencialmente privados

Para los modelos diferencialmente privados, dado que cada combinación de modelo y ϵ se evaluó cinco veces, se ha aplicado un test de Wilcoxon de una muestra para contrastar la hipótesis nula de que la *Accuracy* promedio coincide con el *baseline* sin privacidad. Conviene señalar de antemano una limitación inherente: con $n = 5$ repeticiones, el menor p -valor alcanzable por el test de Wilcoxon de una muestra es $1/2^4 = 0,0625$, ligeramente por encima del umbral convencional $\alpha = 0,05$. En consecuencia, la prueba no podrá declarar significancia estricta aunque la diferencia observada sea sustancial.

Tabla 4.12: Test de Wilcoxon de una muestra entre la *Accuracy* del modelo DP y el *baseline*. $n = 5$ repeticiones por celda.

Modelo	ϵ	Mean Acc	Baseline	p -valor	Magnitud Δ
Regresión Logística	0,1	0,5282	0,6178	0,0625	−14,50 %
	0,5	0,5671	0,6178	0,0625	−8,21 %
	1,0	0,5928	0,6178	0,0625	−4,05 %
	5,0	0,5987	0,6178	0,0625	−3,09 %
	10	0,6180	0,6178	0,625	+0,03 %
Naive Bayes (Gaussian)	0,1	0,5135	0,5912	0,0625	−13,14 %
	0,5	0,5167	0,5912	0,0625	−12,60 %
	1,0	0,5339	0,5912	0,0625	−9,69 %
	5,0	0,5616	0,5912	0,0625	−5,01 %
	10	0,5780	0,5912	0,125	−2,23 %

A pesar de la limitación inherente al n disponible, el patrón de los p -valores es informativo: se mantiene en el límite mínimo alcanzable (0,0625) para todos los presupuestos restrictivos ($\epsilon \leq 5$), reflejando que las cinco repeticiones se ordenan de forma consistente por debajo del *baseline*. Únicamente a $\epsilon = 10$ se observa una relajación del p -valor (a 0,625 en LR y 0,125 en NB), coincidente con la convergencia visual de las curvas hacia el *baseline* en la Figura 4.3. Este comportamiento, junto con la magnitud del efecto absoluto (hasta −14,5 % a $\epsilon = 0,1$), permite afirmar con seguridad que la degradación observada bajo Privacidad Diferencial es **cuantitativamente sustancial**, aunque la confirmación formal de significancia ($p < 0,05$) requeriría incrementar el número de repeticiones, lo cual queda recogido como recomendación metodológica en el Capítulo 5.

Capítulo 5

Conclusiones y trabajos futuros

Este capítulo cierra el estudio sintetizando los hallazgos empíricos del Capítulo 4, contrastándolos con las hipótesis planteadas en la introducción y traduciéndolos en un marco de recomendaciones operativas. Posteriormente se enumeran las limitaciones del estudio y se proponen tres líneas concretas de continuación.

5.1. Respuesta a la Pregunta de Investigación

La pregunta que articuló este Trabajo Fin de Máster era **cuantificar el equilibrio óptimo entre privacidad e utilidad predictiva** para un caso de uso clínico representativo, evaluando además el impacto sobre la equidad algorítmica y el riesgo residual frente a un atacante. Sobre el conjunto de datos *Diabetes 130-US hospitals* y la tarea de predicción de readmisión hospitalaria, los experimentos descritos en el Capítulo 4 permiten emitir cuatro respuestas concretas y empíricamente sostenidas.

5.1.1. Respuesta 1: la k -anonimidad es prácticamente gratuita

Bajo niveles de privacidad sintáctica $k \in \{2, 5, 10, 25, 50\}$, los modelos lineales y de *ensemble* (Regresión Logística y Random Forest) preservan la utilidad predictiva del *baseline* con una pérdida estadísticamente no significativa (test de McNemar, $p > 0,05$ en los cinco niveles para Regresión Logística). El test confirma cuantitativamente la lectura cualitativa: la generalización aplicada por ARX no degrada la frontera de decisión aprendida cuando los modelos se apoyan en variables clínicas no anonimizadas (medicaciones, número de procedimientos, diagnósticos agrupados).

5.1.2. Respuesta 2: la Privacidad Diferencial impone un coste real

La integración de Privacidad Diferencial mediante `diffprivlib` sigue una curva monótona de degradación que impone un coste de utilidad cuantitativamente sustancial: $-14,50\%$ de *Accuracy* a $\epsilon = 0,1$ y $-4,05\%$ a $\epsilon = 1$ en Regresión Logística. La utilidad del *baseline* solo se recupera plenamente a $\epsilon = 10$, valor que la literatura considera ya como un nivel de protección moderado. Esta observación contradice la intuición de que la DP es un sustituto directo de la k -anonimidad: las dos técnicas resuelven problemas distintos y a precios distintos.

5.1.3. Respuesta 3: los efectos sobre la equidad son cualitativamente opuestos

El análisis desagregado por subgrupo *race* reveló el hallazgo más relevante del trabajo. Bajo k -anonimidad, la *Loss Disparity* entre el subgrupo más favorecido y el menos disminuye de 0,0498 en el *baseline* a 0,0450 en $k = 50$: la generalización homogeneiza estructuralmente las representaciones y favorece a los grupos minoritarios (Hispanic $+2,2\%$, Other $+4,8\%$, Asian $+4,3\%$ respecto a su *baseline*). Bajo Privacidad Diferencial con $\epsilon = 0,1$, en cambio, los mismos grupos minoritarios sufren las mayores pérdidas (Hispanic $-19,70\%$, Asian $-17,15\%$ frente al $-14,26\%$ de Caucasian), confirmando empíricamente el patrón descrito por Bagdasaryan et al. (Bagdasaryan, Poursaeed y Shmatikov 2019).

5.1.4. Respuesta 4: el riesgo basal de membresía es bajo

La auditoría adversarial mediante MIA Black-Box (Sección 4.7) demostró que ningún escenario evaluado — incluido el *baseline* sin privacidad — presenta una fuga de información de membresía clínicamente significativa. La *Attack Advantage* máxima observada fue $+0,033$, muy por debajo del umbral $+0,1$ comúnmente considerado relevante. Este resultado reordena las prioridades del análisis: en este caso de uso, donde el modelo no sobreajusta de forma extrema, las técnicas de privacidad costosas no aportan una protección adicional medible frente al ataque más estudiado de la literatura.

5.2. Marco de Recomendaciones para Aplicaciones de Readmisión Hospitalaria

Sobre la base de las cuatro respuestas anteriores, se propone un marco de recomendaciones aplicable a sistemas de clasificación tabular sobre datos clínicos con características similares al *dataset* estudiado: muestras del orden de decenas de miles de registros, variables objetivo binarias o multiclase de baja complejidad, y un volumen importante de variables clínicas no anonimizables. La generalización a otros dominios y arquitecturas requiere la validación específica que se discute como limitación en la Sección 5.3.

La Figura 5.1 formaliza el árbol de decisión que sintetiza las recomendaciones del trabajo.




Figura 5.1: Árbol de decisión para la selección de técnica de privacidad en aplicaciones de clasificación clínica tabular, derivado empíricamente de los resultados del Capítulo 4.

5.2.1. Recomendación 1: aplicar k -anonimidad con $k = 10$ cuando el objetivo sea publicar microdatos

Para escenarios de publicación de microdatos a terceros (intercambio entre instituciones sanitarias, repositorios de investigación, conjuntos de datos para *benchmarking*), **k -anonimidad con $k = 10$** ofrece la mejor relación coste-beneficio observada: una pérdida de utilidad inferior al 0,6 % en *Accuracy*, una protección formal contra ataques de enlace, y una mejora marginal de la equidad demográfica. Este valor de k coincide con el umbral recomendado por la literatura sanitaria ([«Secure Data Sharing in Machine Learning: Exploring K-Anonymization and Differential Privacy» 2024](#)) y se sitúa por encima del estándar mínimo $k = 5$ recomendado para microdatos médicos.

5.2.2. Recomendación 2: reservar la Privacidad Diferencial para escenarios con exigencia regulatoria explícita

La DP debe aplicarse cuando el contexto regulatorio o contractual exija una garantía matemática formal contra inferencia estadística agnóstica al modelo de atacante. En estos casos, los resultados de este trabajo recomiendan situar el presupuesto en el rango $\epsilon \in [5, 10]$, donde la pérdida esperada de *Accuracy* es del 3–5 % y los efectos sobre la equidad son aún manejables. Por debajo de $\epsilon = 1$, la combinación de pérdida de utilidad y exacerbación de la disparidad demográfica hace que el modelo deje de ser apto para un uso clínico responsable sin medidas adicionales de mitigación.

5.2.3. Recomendación 3: realizar una auditoría MIA antes de aplicar técnicas costosas

La evaluación empírica del riesgo basal mediante un ataque de inferencia de membresía es una operación de bajo coste que permite tomar decisiones informadas. Si la *Attack Advantage* sobre el *baseline* es inferior a 0,05, la aplicación de privacidad costosa puede no estar justificada por el modelo de amenaza realista del proyecto. En el caso de este trabajo, la *Advantage* máxima observada fue +0,033, lo que justifica empíricamente la elección de k -anonimidad como técnica preferente cuando exista margen para hacerlo.

5.2.4. Recomendación 4: evitar la combinación naïve de k -anonimidad y DP

Los resultados de la Sección 4.6 demostraron que la aplicación secuencial de DP sobre datos previamente k -anonimizados puede producir un colapso severo de la utilidad cuando la regularización implícita de la implementación de DP interactúa con el espacio de características modificado por la generalización. Hasta que la combinación pueda realizarse mediante

mecanismos diseñados específicamente para esta composición (por ejemplo, DP-SGD calibrado sobre el espacio post-anonimización), **se recomienda elegir una de las dos técnicas** en función del modelo de amenaza, en lugar de aplicarlas en secuencia.

5.3. Limitaciones del Estudio

Las conclusiones anteriores son válidas dentro del alcance experimental del trabajo. Las siguientes limitaciones deben considerarse al interpretarlas o extrapolarlas.

5.3.1. Generalización a otros conjuntos de datos y dominios

Los experimentos se han realizado sobre un único conjunto de datos clínico, lo que impide afirmar la generalidad del comportamiento observado a otros dominios sanitarios (oncología, salud mental, urgencias) o a otros sectores regulados (finanzas, educación). Aunque las características del conjunto seleccionado (volumen, dimensionalidad, proporción de variables sensibles) son representativas de la práctica clínica habitual, la replicación con datasets complementarios es imprescindible antes de elevar las recomendaciones al nivel de guía sectorial.

5.3.2. Familias algorítmicas evaluadas

El *benchmarking* se ha limitado a cuatro modelos clásicos de *Machine Learning* (Regresión Logística, Random Forest, Árbol de Decisión y Naive Bayes Gaussian). El comportamiento de redes neuronales profundas frente a las mismas técnicas de privacidad puede diferir sustancialmente, especialmente en el caso de DP-SGD donde el optimizador interactúa de forma específica con la geometría de los gradientes. La extensión del estudio a redes neuronales — especialmente arquitecturas tipo *Tabular Transformer* o *TabNet* — queda recogida como línea de continuación.

5.3.3. Limitaciones inherentes de la herramienta de DP empleada

La librería `diffprivlib` en su versión 0,6,6 implementa la Privacidad Diferencial mediante *output perturbation* con regularización fija. Esta elección, aunque matemáticamente correcta, produjo el comportamiento contraintuitivo observado al combinar DP con k -anonimidad sobre el espacio OHE expandido. La utilización de mecanismos basados en DP-SGD (como `Opacus`) o de *objective perturbation* con regularización adaptativa podría ofrecer un comportamiento más interpretable en escenarios de defensa en profundidad.

5.3.4. Tamaño muestral del barrido diferencial

El sweep de Privacidad Diferencial se ejecutó con cinco repeticiones por punto, suficientes para estimar con razonable robustez la media y la desviación típica, pero insuficientes para alcanzar significancia estadística estricta en el test de Wilcoxon de una muestra. Un incremento a $n = 20$ repeticiones permitiría declarar significancia formal y reducir las bandas de error en los puntos más ruidosos del sweep.

5.3.5. Modelo de atacante de la auditoría MIA

El ataque de membresía implementado es de tipo *Black-Box* con un clasificador de pertenencia tipo Random Forest, siguiendo la metodología canónica de Shokri et al. (Shokri et al. 2017). Atacantes más sofisticados —basados en *Likelihood Ratio Tests* o en modelos sombra entrenados sobre distribuciones similares— podrían detectar fugas que este ataque no identifica. La auditoría exhaustiva del riesgo residual frente a la familia completa de ataques de membresía constituye una línea complementaria de continuación.

5.4. Líneas Futuras de Investigación

Sobre la base de los hallazgos y limitaciones anteriores, se proponen tres líneas concretas de continuación, ordenadas por prioridad y por su contribución al cierre de los problemas abiertos identificados en el trabajo.

5.4.1. Línea 1: DP-SGD con Opacus sobre redes neuronales tabulares

La principal limitación técnica encontrada en el trabajo — el colapso de la combinación k -anonimidad + DP en Regresión Logística — puede abordarse de forma natural reemplazando la implementación de *output perturbation* de `diffprivlib` por DP-SGD mediante la librería `Opacus` (Meta AI 2020) sobre una red neuronal tabular. DP-SGD inyecta ruido directamente sobre los gradientes durante el entrenamiento, evitando la regularización fija sobre los pesos finales que está en el origen del problema. Esta línea permitiría además: (i) explorar arquitecturas profundas que pueden capturar interacciones no lineales entre variables clínicas, (ii) caracterizar si el comportamiento contraintuitivo de la combinación es específico de los modelos lineales o un fenómeno general, y (iii) construir un puente metodológico hacia el estudio de modelos de lenguaje médico, donde DP-SGD es la herramienta estándar de privacidad. La integración con la fase ARX existente debería ser directa, requiriendo únicamente la adaptación del *pipeline* de carga.

5.4.2. Línea 2: generación de datos sintéticos diferencialmente privados con CTGAN

La taxonomía del Capítulo 2 contempla la generación de datos sintéticos como tercer eje del paradigma de privacidad, junto con k -anonimidad y DP, y la guía de referencia metodológica destaca CTGAN (Xu et al. 2019) como técnica especializada para datos tabulares mixtos. Su evaluación sobre el mismo *dataset* clínico permitiría: (i) cuantificar la fidelidad estadística del conjunto sintético frente al original mediante métricas como *Train Synthetic Test Real* (TSTR), (ii) auditar el riesgo de membresía sobre el modelo generativo — pregunta crítica para la validación de la sintetización como mecanismo de privacidad, según indica la literatura reciente («Differentially Private Synthetic Data Enables Public Release of Behavioral Health Information with High Utility» 2025) —, y (iii) comparar la curva privacidad-utilidad de la sintetización frente a las dos técnicas evaluadas en este trabajo. La librería SDV (Patki, Wedge y Veeramachaneni 2016) ofrece una implementación con interfaz uniforme que facilita esta extensión.

5.4.3. Línea 3: validación externa y árbol de decisión refinado

La generalización de las recomendaciones del marco propuesto requiere su validación contra al menos dos conjuntos de datos sanitarios complementarios: uno con perfil oncológico (alta sensibilidad de los atributos sensibles) y otro con perfil de urgencias (alta proporción de valores raros y *outliers*). El refinamiento del árbol de decisión incorporando los resultados de estas validaciones, junto con criterios cuantitativos para la selección automatizada del parámetro de privacidad mediante optimización bayesiana con restricciones de *fairness*, daría como resultado un marco operativo que la comunidad de ciencia de datos podría adoptar como referencia para la implementación de modelos predictivos en entornos sanitarios regulados.

5.5. Reflexión Final

Este Trabajo Fin de Máster comenzó con una pregunta aparentemente simple: ¿cuánta utilidad debe sacrificarse para garantizar la privacidad de los pacientes en un sistema predictivo de readmisión hospitalaria? Los resultados experimentales han mostrado que esta pregunta admite una respuesta sustancialmente más matizada que la dicotomía habitual de la literatura. En el caso de uso estudiado, la k -anonimidad ofrece una protección sustantiva al coste de menos del 0,6 % de *Accuracy*, mientras que la Privacidad Diferencial impone un coste explícito que sólo está justificado cuando el contexto regulatorio o contractual exige una garantía matemática formal. La equidad demográfica, lejos de ser una consideración secundaria, emerge como una dimensión activa del compromiso: las técnicas evaluadas tienen efectos cualitativamente opuestos sobre los grupos minoritarios.

La contribución de este trabajo, más allá de los números concretos, reside en haber articulado una metodología reproducible para evaluar empíricamente este compromiso en cualquier caso de uso similar. Las herramientas, los *notebooks* y los resultados publicados junto con esta memoria pretenden facilitar que esa evaluación se realice por defecto en cualquier proyecto de inteligencia artificial responsable, en línea con el espíritu de la Ley de IA de la Unión Europea ([Reglamento \(UE\) 2024/1689 2024](#)) y del Reglamento General de Protección de Datos ([Reglamento \(UE\) 2016/679 2016](#)).

Bibliografía

- Abadi, Martin et al. (2016). «Deep Learning with Differential Privacy». En: *Proceedings of the 2016 ACM SIGSAC Conference on Computer and Communications Security (CCS)*. ACM, págs. 308-318. DOI: [10.1145/2976749.2978318](https://doi.org/10.1145/2976749.2978318).
- Argyriou, Vasileios et al. (2025). «Quantitative Metrics for Balancing Privacy and Utility in Pseudonymized Big Data». En: *Electronics* 14.21, pág. 4350. DOI: [10.3390/electronics14214350](https://doi.org/10.3390/electronics14214350).
- Bagdasaryan, Eugene, Omid Poursaeed y Vitaly Shmatikov (2019). «Differential Privacy Has Disparate Impact on Model Accuracy». En: *Advances in Neural Information Processing Systems* 32.
- Benchmarking Differential Privacy Optimizers* (2024). URL: <https://helda.helsinki.fi/server/api/core/bitstreams/62f20dfb-058d-48c6-a84d-a039a01d3eb2/content>.
- «Differentially Private and Adversarially Robust Machine Learning: An Empirical Evaluation» (2024). En: *arXiv preprint arXiv:2401.10405*. URL: <https://arxiv.org/abs/2401.10405>.
- «Differentially Private Synthetic Data Enables Public Release of Behavioral Health Information with High Utility» (2025). En: *arXiv preprint arXiv:2507.02971*. URL: <https://arxiv.org/abs/2507.02971>.
- Dwork, Cynthia (2006). «Differential Privacy». En: *International Colloquium on Automata, Languages, and Programming (ICALP)*. Springer, págs. 1-12. DOI: [10.1007/11787006_1](https://doi.org/10.1007/11787006_1).
- Dwork, Cynthia et al. (2006). «Calibrating Noise to Sensitivity in Private Data Analysis». En: *Theory of Cryptography Conference (TCC)*. Springer, págs. 265-284. DOI: [10.1007/11681878_14](https://doi.org/10.1007/11681878_14).
- «Empirical Analysis of Privacy-Fairness-Accuracy Trade-offs in Federated Learning» (2025). En: *arXiv preprint arXiv:2503.16233*. URL: <https://arxiv.org/abs/2503.16233>.
- Galileo AI (2025). *How Membership Inference Attacks Expose AI Data*. URL: <https://galileo.ai/blog/membership-inference-attacks>.
- Goodfellow, Ian et al. (2014). «Generative Adversarial Nets». En: *Advances in Neural Information Processing Systems* 27.
- Holohan, Naoise et al. (2019). «Diffprivlib: The IBM Differential Privacy Library». En: *arXiv preprint arXiv:1907.02444*. URL: <https://arxiv.org/abs/1907.02444>.

- Iyengar, Vijay S. (2002). «Transforming Data to Satisfy Privacy Constraints». En: *Proceedings of the 8th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, págs. 279-288. DOI: [10.1145/775047.775089](https://doi.org/10.1145/775047.775089).
- Kohlmayer, Florian et al. (2012). «Flash: Efficient, Stable and Optimal K -Anonymity». En: *2012 ASE/IEEE International Conference on Privacy, Security, Risk and Trust*. IEEE, págs. 708-717. DOI: [10.1109/SocialCom-PASSAT.2012.52](https://doi.org/10.1109/SocialCom-PASSAT.2012.52).
- Labelia Labs (2024). *Going Differentially Private: techniques and tools of the trade*. URL: <https://www.labelia.org/en/blog/going-differentially-private>.
- LeFevre, Kristen, David J. DeWitt y Raghu Ramakrishnan (2006). «Mondrian Multidimensional K -Anonymity». En: *22nd International Conference on Data Engineering (ICDE'06)*. IEEE, págs. 25-25. DOI: [10.1109/ICDE.2006.101](https://doi.org/10.1109/ICDE.2006.101).
- Li, Ninghui, Tiancheng Li y Suresh Venkatasubramanian (2007). « t -Closeness: Privacy Beyond k -Anonymity and l -Diversity». En: *2007 IEEE 23rd International Conference on Data Engineering*. IEEE, págs. 106-115. DOI: [10.1109/ICDE.2007.367856](https://doi.org/10.1109/ICDE.2007.367856).
- Linux Foundation AI & Data (2018). *Adversarial Robustness Toolbox (ART)*. URL: <https://github.com/Trusted-AI/adversarial-robustness-toolbox>.
- Machanavajjhala, Ashwin et al. (2007). « l -Diversity: Privacy Beyond k -Anonymity». En: vol. 1. 1. ACM, 3-es. DOI: [10.1145/1217299.1217302](https://doi.org/10.1145/1217299.1217302).
- McMahan, Brendan et al. (2017). «Communication-Efficient Learning of Deep Networks from Decentralized Data». En: *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS)*. PMLR, págs. 1273-1282.
- «Membership Inference Attacks Against Synthetic Health Data» (2022). En: *Journal of the American Medical Informatics Association*. DOI: [10.1093/jamia/ocab273](https://doi.org/10.1093/jamia/ocab273). URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC8766950/>.
- Meta AI (2020). *Opacus: Train PyTorch models with Differential Privacy*. URL: <https://opacus.ai/>.
- «Modeling and Evaluation of k -anonymization Metrics» (2020). En: *AAAI Workshop on Privacy-Preserving Artificial Intelligence (PPAI)*. URL: https://www2.isye.gatech.edu/~fferdinando3/cfp/PPAI20/papers/paper_18.pdf.
- Patki, Neha, Roy Wedge y Kalyan Veeramachaneni (2016). *The Synthetic Data Vault*. DOI: [10.1109/DSAA.2016.49](https://doi.org/10.1109/DSAA.2016.49).
- Prasser, Fabian y Florian Kohlmayer (2015). «Putting Statistical Disclosure Control into Practice: The ARX Data Anonymization Tool». En: *Medical Data Privacy Handbook*. Springer, págs. 111-148. DOI: [10.1007/978-3-319-23633-9_6](https://doi.org/10.1007/978-3-319-23633-9_6).
- «Privacy-preserving machine learning: a review of federated learning techniques and applications» (2025). En: *Frontiers in Big Data*. DOI: [10.3389/fdata.2025.1517985](https://doi.org/10.3389/fdata.2025.1517985). URL: <https://www.researchgate.net/publication/388822437>.

- «Privacy, Utility and Fairness: Navigating Trade-offs in Differentially Private Machine Learning» (2025). En: *Proceedings of the AAAI Conference on Artificial Intelligence*. URL: <https://ojs.aaai.org/index.php/AAAI/article/view/35205>.
- Provably Private Data Anonymization: Or, k-Anonymity Meets Differential Privacy* (2010). Inf. téc. CERIAS, Purdue University. URL: https://www.cerias.purdue.edu/assets/pdf/bibtex_archive/2010-24-report.pdf.
- Reglamento (UE) 2016/679* (2016). Diario Oficial de la Unión Europea, L 119, 4 de mayo de 2016.
- Reglamento (UE) 2024/1689* (2024). Diario Oficial de la Unión Europea, L, 12 de julio de 2024.
- «Secure Data Sharing in Machine Learning: Exploring K-Anonymization and Differential Privacy» (2024). En: *Journal of Information Systems Engineering and Management*. DOI: 10.55267/iadt.07.15198. URL: <https://jisem-journal.com/index.php/journal/article/download/1198/456>.
- Shokri, Reza et al. (2017). «Membership Inference Attacks Against Machine Learning Models». En: *2017 IEEE Symposium on Security and Privacy (SP)*. IEEE, págs. 3-18. DOI: 10.1109/SP.2017.41.
- Strack, Beata, Jonathan DeShazo et al. (2014). *Diabetes 130-US hospitals for years 1999-2008*. UCI Machine Learning Repository. DOI: <https://doi.org/10.24432/C5230J>.
- Strack, Beata, Jonathan P. DeShazo et al. (2014). «Impact of HbA1c Measurement on Hospital Readmission Rates: Analysis of 70,000 Clinical Database Patient Records». En: *BioMed Research International* 2014, pág. 781670. DOI: 10.1155/2014/781670.
- Sweeney, Latanya (2002). «k-Anonymity: A Model for Protecting Privacy». En: vol. 10. 05. World Scientific, págs. 557-570. DOI: 10.1142/S0218488502001648.
- Synthetic Data – what, why and how?* (2024). Inf. téc. The Royal Society. URL: https://royalsociety.org/-/media/policy/projects/privacy-enhancing-technologies/Synthetic_Data_Survey-24.pdf.
- Xu, Lei et al. (2019). «Modeling Tabular Data using Conditional GAN». En: *Advances in Neural Information Processing Systems* 32.