



UNIVERSIDAD NACIONAL  
DE EDUCACIÓN A DISTANCIA

Escuela Técnica Superior de Ingeniería Informática

# ANÁLISIS COMPARATIVO DE TÉCNICAS DE ANONIMIZACIÓN DE DATOS Y SU IMPACTO EN EL RENDIMIENTO Y LA ROBUSTEZ DE MODELOS DE INTELIGENCIA ARTIFICIAL

Alex Herrerías Ramírez

Director/a: Maria de los Llanos Tobarra

Trabajo de Fin de Máster

Máster Universitario  
en Ingeniería y Ciencia de Datos

[Fecha de presentación/Convocatoria]



# Agradecimientos

[Quisiera dedicar ...]



# Resumen

El presente Trabajo Fin de Máster investiga el impacto de las técnicas de anonimización de datos sobre el rendimiento predictivo de modelos de inteligencia artificial en el ámbito sanitario. Partiendo de un conjunto de datos clínicos reales de más de 98.000 registros hospitalarios de pacientes diabéticos, se implementa un marco experimental que permite cuantificar el equilibrio entre la protección de la identidad del paciente y la utilidad analítica del dato.

El estudio aborda tres ejes fundamentales: la aplicación de privacidad sintáctica ( $k$ -anonimidad) mediante la herramienta ARX, la integración de Privacidad Diferencial en algoritmos clásicos de aprendizaje automático a través de la librería Diffprivlib, y la evaluación de la robustez de los modelos resultantes frente a ataques de inferencia de membresía utilizando el Adversarial Robustness Toolbox. Los resultados se analizan tanto términos de precisión global, sino también desde la perspectiva de la equidad algorítmica, evaluando si la degradación del rendimiento afecta de forma desproporcionada a grupos demográficos minoritarios. El trabajo concluye con un marco de recomendaciones para la selección de técnicas de anonimización en función del contexto regulatorio y el nivel de protección deseado.

**Palabras clave:** anonimización, privacidad diferencial,  $k$ -anonimidad, aprendizaje automático, equidad algorítmica, datos sanitarios



# Abstract

This Master's Thesis investigates the impact of data anonymization techniques on the predictive performance of artificial intelligence models in the healthcare domain. Using a real clinical dataset comprising over 98,000 hospital records of diabetic patients, an experimental framework is implemented to quantify the trade-off between patient identity protection and analytical data utility.

The study addresses three fundamental axes: the application of syntactic privacy ( $k$ -anonymity) through the ARX tool, the integration of Differential Privacy into classical machine learning algorithms via the Diffprivlib library, and the evaluation of the robustness of the resulting models against membership inference attacks using the Adversarial Robustness Toolbox. The results are analyzed not only in terms of overall accuracy but also from the perspective of algorithmic fairness, assessing whether performance degradation disproportionately affects minority demographic groups. The work concludes with a recommendation framework for the selection of anonymization techniques based on the regulatory context and the desired level of protection.

**Keywords:** anonymization, differential privacy,  $k$ -anonymity, machine learning, algorithmic fairness, healthcare data





# Índice general

|                                                                                                         |           |
|---------------------------------------------------------------------------------------------------------|-----------|
| <b>1. Introducción</b>                                                                                  | <b>1</b>  |
| 1.1. Motivación . . . . .                                                                               | 1         |
| 1.2. Propuesta y objetivos . . . . .                                                                    | 2         |
| 1.3. Estructura de la memoria . . . . .                                                                 | 3         |
| <b>2. Estado del Arte</b>                                                                               | <b>5</b>  |
| 2.1. El Paradigma de la Privacidad en la Ciencia de Datos . . . . .                                     | 5         |
| 2.1.1. Privacidad / Anonimización . . . . .                                                             | 5         |
| 2.1.2. El Dilema Privacidad frente a Utilidad . . . . .                                                 | 6         |
| 2.2. Privacidad Sintáctica y sus variantes. . . . .                                                     | 7         |
| 2.2.1. El modelo de $k$ -anonimato. . . . .                                                             | 7         |
| 2.2.2. Vulnerabilidades y extensiones: el concepto de $l$ -diversidad y el de $t$ -cercanía . . . . .   | 7         |
| 2.3. Privacidad Semántica: Privacidad Diferencial . . . . .                                             | 8         |
| 2.3.1. Paradigmas de aplicación: DP Local y DP Global . . . . .                                         | 9         |
| 2.3.2. Privacidad Diferencial en el Aprendizaje Automático . . . . .                                    | 9         |
| 2.4. Generación de Datos Sintéticos . . . . .                                                           | 10        |
| 2.5. Paradigmas Colaborativos: Aprendizaje Federado (FL) . . . . .                                      | 10        |
| 2.6. Evaluación de Riesgos y Auditoría Algorítmica . . . . .                                            | 11        |
| 2.6.1. Ataques a Modelos de Inteligencia Artificial . . . . .                                           | 11        |
| 2.6.2. Influencia en la Equidad e Igualdad Algorítmica . . . . .                                        | 12        |
| <b>3. Materiales y Métodos</b>                                                                          | <b>13</b> |
| 3.1. Entorno Experimental y Selección de los Datos . . . . .                                            | 13        |
| 3.1.1. Selección y Justificación del Conjunto de Datos . . . . .                                        | 14        |
| 3.2. Ingesta y Preprocesamiento . . . . .                                                               | 15        |
| 3.3. Perfilado de Privacidad y Análisis de Riesgo Basal . . . . .                                       | 16        |
| 3.3.1. Evaluación del modelo de atacante y expansión de QIDs . . . . .                                  | 17        |
| 3.3.2. Resultados del Riesgo Basal Definitivo . . . . .                                                 | 17        |
| 3.4. Transformación Específica para la Privacidad (Reducción del Conjunto de Características) . . . . . | 18        |

|           |                                                                                           |           |
|-----------|-------------------------------------------------------------------------------------------|-----------|
| 3.4.1.    | El problema de la dimensionalidad en Privacidad Diferencial . . . . .                     | 18        |
| 3.4.2.    | Agrupación semántica de códigos CIE-9 . . . . .                                           | 19        |
| 3.5.      | Modelado de Referencia (Baseline) . . . . .                                               | 20        |
| 3.5.1.    | Preparación y escalado de los datos . . . . .                                             | 20        |
| 3.5.2.    | Entrenamiento y métricas de utilidad base . . . . .                                       | 21        |
| 3.6.      | Aplicación de Privacidad Sintáctica mediante ARX . . . . .                                | 22        |
| 3.6.1.    | Configuración de atributos . . . . .                                                      | 22        |
| 3.6.2.    | Jerarquías de Generalización . . . . .                                                    | 23        |
| 3.6.3.    | Modelo de supresión y métrica de utilidad . . . . .                                       | 24        |
| 3.6.4.    | Barrido de parámetros y exportación . . . . .                                             | 24        |
| 3.6.5.    | Reentrenamiento y métrica de comparación . . . . .                                        | 25        |
| 3.7.      | Implementación de la Privacidad Diferencial mediante <code>diffprivlib</code> . . . . .   | 25        |
| 3.7.1.    | Elección de la librería y de los modelos privados . . . . .                               | 26        |
| 3.7.2.    | Calibración de sensibilidad y modelo de ruido . . . . .                                   | 27        |
| 3.7.3.    | Barrido del presupuesto de privacidad . . . . .                                           | 28        |
| 3.7.4.    | Réplica y métricas de estabilidad . . . . .                                               | 28        |
| <b>4.</b> | <b>Resultados</b>                                                                         | <b>29</b> |
| 4.1.      | Resultados de $k$ -Anonimidad con ARX . . . . .                                           | 29        |
| 4.2.      | Impacto sobre la Utilidad Predictiva de los Modelos . . . . .                             | 30        |
| 4.2.1.    | Robustez de los modelos lineales y de <i>ensemble</i> . . . . .                           | 32        |
| 4.2.2.    | Sensibilidad diferencial entre familias algorítmicas . . . . .                            | 32        |
| 4.2.3.    | Implicaciones sobre la selección de modelos en contextos de privacidad . . . . .          | 33        |
| 4.3.      | Análisis de Equidad Algorítmica . . . . .                                                 | 33        |
| 4.3.1.    | La $k$ -anonimidad no exacerba la disparidad demográfica . . . . .                        | 34        |
| 4.3.2.    | Interpretación: regularización implícita en grupos minoritarios . . . . .                 | 35        |
| 4.4.      | Síntesis de la Fase Sintáctica . . . . .                                                  | 35        |
| 4.5.      | Resultados de la Aplicación de Privacidad Diferencial . . . . .                           | 36        |
| 4.5.1.    | Curva de degradación de la utilidad . . . . .                                             | 37        |
| 4.5.2.    | Comparativa cruzada: Privacidad Diferencial frente a $k$ -Anonimidad . . . . .            | 38        |
| 4.5.3.    | Impacto sobre la equidad: el patrón Bagdasaryan se confirma . . . . .                     | 39        |
| 4.5.4.    | Síntesis de la Fase Diferencial . . . . .                                                 | 40        |
| 4.6.      | Defensa en Profundidad: Combinación de $k$ -Anonimidad y Privacidad Diferencial . . . . . | 41        |
| 4.6.1.    | Comportamiento de la utilidad combinada . . . . .                                         | 41        |
| 4.6.2.    | Implicación: la defensa en profundidad no es trivial . . . . .                            | 42        |
| 4.7.      | Auditoría adversarial: inferencia de pertenencia con el ART . . . . .                     | 44        |
| 4.7.1.    | Configuración del experimento . . . . .                                                   | 44        |
| 4.7.2.    | Resultados de la auditoría . . . . .                                                      | 44        |

|           |                                                                                                                   |           |
|-----------|-------------------------------------------------------------------------------------------------------------------|-----------|
| 4.8.      | Tests de Significancia Estadística . . . . .                                                                      | 46        |
| 4.8.1.    | Test de McNemar para los modelos $k$ -anonimizados . . . . .                                                      | 46        |
| 4.8.2.    | Test de Wilcoxon para los modelos diferencialmente privados . . . . .                                             | 47        |
| <b>5.</b> | <b>Conclusiones y futuros trabajos</b>                                                                            | <b>49</b> |
| 5.1.      | Contestación a la Pregunta de Investigación . . . . .                                                             | 49        |
| 5.1.1.    | Respuesta 1: la $k$ -anonimidad es casi gratuita . . . . .                                                        | 49        |
| 5.1.2.    | Respuesta 2: la Privacidad Diferencial impone un coste real . . . . .                                             | 50        |
| 5.1.3.    | Respuesta 3: los efectos sobre equidad a la vez son cualitativamente opuestos . . . . .                           | 50        |
| 5.1.4.    | Respuesta 4: el riesgo basal de membresía es muy bajo . . . . .                                                   | 50        |
| 5.2.      | Marco de Recomendaciones para Aplicaciones de Readmisión Hospitalaria . .                                         | 51        |
| 5.2.1.    | Recomendación 1: aplicar $k$ -anonimidad con $k = 10$ para la publicación de microdatos . . . . .                 | 52        |
| 5.2.2.    | Recomendación 2: reservar la Privacidad Diferencial para escenarios con exigencia regulatoria explícita . . . . . | 52        |
| 5.2.3.    | Recomendación 3: hacer una auditoría MIA antes de aplicar técnicas costosas . . . . .                             | 52        |
| 5.2.4.    | Recomendación 4: no combinar de forma naïve $k$ -anonimidad con DP . . . . .                                      | 53        |
| 5.3.      | Limitaciones del Estudio . . . . .                                                                                | 53        |
| 5.3.1.    | Alcance de las técnicas evaluadas . . . . .                                                                       | 53        |
| 5.3.2.    | Generalización a otros conjuntos de datos y dominios . . . . .                                                    | 53        |
| 5.3.3.    | Familias algorítmicas analizadas . . . . .                                                                        | 54        |
| 5.3.4.    | Limitaciones de la herramienta de DP utilizada . . . . .                                                          | 54        |
| 5.3.5.    | Tamaño muestral del análisis diferencial . . . . .                                                                | 54        |
| 5.3.6.    | Modelo de atacante en la auditoría MIA . . . . .                                                                  | 54        |
| 5.4.      | Líneas Futuras de Investigación . . . . .                                                                         | 55        |
| 5.4.1.    | Línea 1: DP-SGD con Opacus sobre redes neuronales tabulares . . . . .                                             | 55        |
| 5.4.2.    | Línea 2: generación de datos sintéticos diferencialmente privados utilizando CTGAN . . . . .                      | 55        |
| 5.4.3.    | Línea 3: validación externa y árbol de decisión refinado . . . . .                                                | 56        |
| 5.5.      | Reflexión Final . . . . .                                                                                         | 56        |
|           | <b>Bibliografía y referencias</b>                                                                                 | <b>59</b> |



# Índice de figuras

|                                                                                                                                                                                                                                                                                                              |    |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 4.1. Degradación de <i>Accuracy</i> (izquierda) y <i>F1-Score</i> ponderado (derecha) de los cuatro modelos a lo largo del barrido $k \in \{0, 2, 5, 10, 25, 50\}$ . El eje de abscisas se representa en escala simétrica logarítmica para resaltar la zona de transición.                                   | 31 |
| 4.2. Disparidad de utilidad de la Regresión Logística por subgrupo <b>race</b> a lo largo del barrido $k \in \{0, 2, 5, 10, 25, 50\}$ . Las leyendas indican el tamaño $n$ de cada subgrupo en el conjunto de prueba. La línea discontinua marca la <i>Accuracy</i> media del <i>baseline</i> .              | 34 |
| 4.3. Degradación de <i>Accuracy</i> (izquierda) y <i>F1-Score</i> ponderado (derecha) en función del presupuesto de privacidad $\epsilon$ . Las barras de error corresponden a la desviación típica sobre cinco repeticiones por punto. Las líneas discontinuas indican los <i>baselines</i> sin privacidad. | 37 |
| 4.4. Comparativa cruzada de las dos técnicas de privacidad sobre la Regresión Logística. La curva azul representa Privacidad Diferencial; la curva verde representa $k$ -anonimidad. La línea discontinua representa el <i>baseline</i> -sin privacidad- (0,6178).                                           | 38 |
| 4.5. Disparidad de utilidad de la Regresión Logística diferencialmente privada por subgrupo <b>race</b> a lo largo del barrido $\epsilon \in \{0,1, 0,5, 1, 5, 10\}$ . Las barras de error corresponden a la desviación típica sobre cinco repeticiones.                                                     | 39 |
| 4.6. Comparativa de utilidad de la Regresión Logística: DP solo (azul) frente a combinación $k = 10 + DP$ (verde). Las líneas discontinuas indican el <i>baseline</i> y el modelo $k = 10$ sin DP como referencias.                                                                                          | 41 |
| 4.7. Disparidad de utilidad por subgrupo <b>race</b> : DP solo (izquierda) vs combinación $k = 10 + DP$ (derecha). En la combinación se observa que la varianza por subgrupo se incrementa a $\epsilon = 0,1$ , especialmente en el grupo <i>Asian</i> de menor tamaño.                                      | 43 |
| 4.8. Resultados de la auditoría adversarial mediante MIA Black-Box. La línea discontinua en 0,5 marca el rendimiento aleatorio de un atacante; valores próximos a esta indican ausencia de fuga estructural.                                                                                                 | 45 |

|                                                                                                                                                                                      |    |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 5.1. Árbol de decisión para la selección de técnica de privacidad en aplicaciones de clasificación clínica tabular, derivado empíricamente de los resultados del Capítulo 4. . . . . | 51 |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|

# Índice de tablas

|                                                                                                                                                                                                                                                                                            |    |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 2.1. Dimensiones del impacto de la anonimización sobre modelos de IA. . . . .                                                                                                                                                                                                              | 6  |
| 3.1. Rendimiento de los modelos Baseline sobre el conjunto de datos reducido. . .                                                                                                                                                                                                          | 21 |
| 3.2. Jerarquías de generalización empleadas en ARX. . . . .                                                                                                                                                                                                                                | 23 |
| 4.1. Efectos estructurales de la aplicación del $k$ -anonimato sobre el conjunto de<br>entrenamiento (78.442 registros). . . . .                                                                                                                                                           | 29 |
| 4.2. Niveles de generalización que finalmente aplica ARX para cada cuasi-<br>identificador. Un valor igual a 0 indica que el atributo conserva su<br>granularidad original; las anotaciones entre paréntesis indican cómo se ha<br>aplicado esta abstracción para el primer nivel. . . . . | 30 |
| 4.3. <i>Accuracy</i> de los modelos sobre el conjunto de prueba en función del nivel de<br>privacidad sintáctica. . . . .                                                                                                                                                                  | 30 |
| 4.4. <i>F1-Score</i> ponderado de los modelos sobre el conjunto de prueba en función<br>del nivel de privacidad sintáctica. . . . .                                                                                                                                                        | 31 |
| 4.5. <i>Accuracy</i> de la Regresión Logística sobre el conjunto de prueba desagregada<br>por subgrupo <b>race</b> . . . . .                                                                                                                                                               | 33 |
| 4.6. <i>Accuracy</i> (mean $\pm$ std, $n = 5$ ) de los modelos diferencialmente privados sobre<br>el conjunto de prueba. . . . .                                                                                                                                                           | 37 |
| 4.7. <i>F1-Score</i> ponderado (mean $\pm$ std, $n = 5$ ) de los modelos diferencialmente<br>privados. . . . .                                                                                                                                                                             | 37 |
| 4.8. <i>Accuracy</i> (media de cinco repeticiones) de la Regresión Logística diferencial-<br>mente privada desagregada por subgrupo <b>race</b> . La última columna recoge la<br>pérdida porcentual respecto al <i>baseline</i> a $\epsilon = 0,1$ . . . . .                               | 39 |
| 4.9. <i>Accuracy</i> (mean $\pm$ std, $n = 5$ ) de DP solo vs combinación $k = 10 + DP$ . . .                                                                                                                                                                                              | 41 |
| 4.10. Auditoría adversarial mediante MIA Black-Box sobre Regresión Logística en<br>distintos escenarios de privacidad. . . . .                                                                                                                                                             | 44 |
| 4.11. Test de McNemar entre el <i>baseline</i> y cada modelo $k$ -anonimizado. $b$ representa<br>los casos en que el <i>baseline</i> acierta y el modelo anonimizado falla; $c$ los inversos.<br>Significativo: $p < 0,05$ . . . . .                                                       | 46 |
| 4.12. Test de Wilcoxon de una muestra entre la <i>Accuracy</i> del modelo DP y el<br><i>baseline</i> . $n = 5$ repeticiones por celda. . . . .                                                                                                                                             | 47 |





# Capítulo 1

## Introducción

### 1.1. Motivación

La privacidad de los datos ya no es una preocupación lateral del desarrollo tecnológico, sino que se ha convertido en el núcleo de toda discusión seria sobre el campo de la inteligencia artificial y por una razón concreta: la última ola de IA depende del dato a una escala que hace tan sólo unos años resultaba impensable. Cuanto más datos utilizamos, más compleja se hace la pregunta de qué es lo que se puede compartir, de qué es lo que hay que poner bajo la protección y en qué condiciones.

La colisión entre las dos exigencias es real, de un lado se encuentra una exigencia técnica clara: entrenar modelos competitivos requiere grandes volúmenes de datos representativos. Por el otro lado una exigencia legal que cada día cobra más importancia: proteger la misma identidad de los sujetos sobre los cuales se realiza el análisis, y más aún si estamos hablando de datos sensibles. Esta última exigencia la formalizan el Reglamento General de Protección de Datos ([Reglamento \(UE\) 2016/679 2016](#)) en Europa y la reciente Ley de IA de la Unión Europea ([Reglamento \(UE\) 2024/1689 2024](#)), dos códigos legislativos que ya no piden el cumplimiento formal sino que exigen lo que algunas guías denominan *confianza digital* en los sistemas que se ponen en producción.

El problema es más notorio cuando lo planteamos en sectores como la salud o las finanzas. Compartir datos clínicos resulta fundamental para el avance de la medicina personalizada, pero es justo aquí donde el riesgo de reidentificación es mayor. Un atacante que tiene acceso a las salidas del modelo puede intentar inferir si un individuo concreto tuvo parte en el modelo — lo que se denomina ataque de membresía — o bien puede intentar deducir directamente atributos sensibles. Esa amenaza no es solamente teórica, está documentada en la literatura (Shokri et al. [2017](#)), y representa una frontera que los equipos de ingeniería de datos tienen que responder al diseñar sus *pipelines*.

## 1.2. Propuesta y objetivos

El presente TFM se produce como un trabajo técnico-práctico. La pregunta de fondo es directa: ¿cuánto de la utilidad predictiva hay que sacrificar para proteger al sujeto? El objetivo central vendría a ser el de medir de manera comparativa el efecto sobre el rendimiento de los modelos de IA, su estabilidad y su capacidad predictiva, de varias técnicas de anonimización en un caso de uso del ámbito de la sanidad. Para alcanzar ese objetivo, y ya de paso demostrar que puedo lidiar con el ciclo completo de un proyecto de ciencia de datos restringido en materia de privacidad, establezco seis objetivos específicos:

- **Revisión y sistematización del estado del arte.** Estudiar las técnicas de privacidad sintáctica (k-anonimidad, l-diversidad), de privacidad semántica (privacidad diferencial), generación de datos sintéticos y marcos de aprendizaje federados.
- **Implementación de un entorno experimental.** Escoger un dominio crítico representativo y un conjunto de datos real con atributos sensibles y cuasi-identificadores.
- **Aplicación parametrizada de las técnicas.** Crear diversas versiones del dataset original variando entre algoritmos distintos para los niveles de anonimización, de forma que se pueda analizar la sensibilidad a cada uno de los parámetros de privacidad.
- **Benchmarking de modelos de IA.** Entrenar y validar diversas arquitecturas sobre los conjuntos originales, sintéticos y anonimizados, y comparar así el rendimiento (*Benchmarking Differential Privacy Optimizers 2024*).
- **Análisis de vulnerabilidades y riesgo residual.** Evaluar la solidez de los modelos frente a ataques de reidentificación e inferencia de membresía para poder medir la protección efectivamente obtenida.
- **Desarrollo de un marco de recomendaciones.** Sintetizar los hallazgos en una guía práctica que oriente sobre qué técnica y qué parámetros convenía aplicar dependiendo del equilibrio privacidad-utilidad buscado.

## 1.3. Estructura de la memoria

La memoria presenta un argumento desde el problema hasta su validación empírica.

El **Capítulo 1** plantea el dilema privacidad-utilidad, define la pregunta de investigación y dedica un apartado a enumerar objetivos.

El **Capítulo 2** presenta el estado del arte referido a una taxonomía de las técnicas de privacidad —sintáctica y diferencial, datos sintéticos, federated learning.

El **Capítulo 3** se centra en la metodología y el entorno experimental: cómo se ingieren los datos, cómo se perfila el riesgo de privacidad inicial, qué herramientas se utilizan (IBM Diffprivlib, ARX, Adversarial Robustness Toolbox) y por qué.

El **Capítulo 4** aborda el análisis de resultados. Métricas de rendimiento, impacto positivo en la equidad (*fairness*) algorítmica y robustez de los modelos en función de las distintas configuraciones de anonimización ([«Privacy, Utility and Fairness: Navigating Trade-offs in Differentially Private Machine Learning» 2025](#)).

Y finalmente, el **Capítulo 5** cierra la memoria. Recoge las conclusiones referidas al equilibrio privacidad-utilidad y ofrece un marco de recomendaciones prácticas, así como unas líneas futuras de investigación que se abren a raíz de los hallazgos.



# Capítulo 2

## Estado del Arte

### 2.1. El Paradigma de la Privacidad en la Ciencia de Datos

En primer lugar y como condición básica es necesario establecer los conceptos básicos de la investigación en privacidad aplicada a la ciencia de datos; que empieza con una idea bastante sencilla, pero con profundas consecuencias: los datos no son objetos estáticos. Los datos son activos que cambian a lo largo del *pipeline* y cada vez que se transforman, por efecto de la transformación, los datos cambian la propia estructura estadística.

#### 2.1.1. Privacidad / Anonimización

En el marco del ámbito regulatorio europeo; la anonimización, es decir, hacer que los individuos no se puedan identificar ni directa ni indirectamente ([\*Reglamento \(UE\) 2016/679\*](#) 2016). La transformación nunca es gratuita. Cualquier técnica de anonimización introduce algo de distorsión o pérdida de detalle, y ese coste se paga después, al ser utilizados para entrenar un modelo de *Machine Learning* sobre el dataset ya anonimizados, es decir, a menudo se pierden patrones finos, baja la precisión y aumenta el sesgo (en ocasiones). Por este motivo, la anonimización no es posible que sea un botón de “todo o nada”, sino que la anonimización ha de ser un espectro de decisiones técnicas que dependen del riesgo que estemos dispuestos a asumir en cada caso (Argyriou et al. 2025). Esa idea es la que da sentido y orienta las decisiones metodológicas que da lugar al estudio del proceso en el Capítulo 3.

### 2.1.2. El Dilema Privacidad frente a Utilidad

La investigación existente en el ámbito gira en torno al mismo equilibrio: proteger el individuo sin arrojar la información por la borda. La *utilidad* que puede tener un dato consiste en la capacidad de que el mismo sirva al propósito analítico para el cual fue recogido. En *Machine Learning* esto se traduce en una cuestión de aplicación: ¿generaliza igual el modelo con datos anonimizados que con datos en claro?

La respuesta a esa pregunta quien demuestra es empíricamente mala. Cuando se aprietan las proyecciones las consecuencias en la analítica pueden ser muy duras. Un caso típico: aplicar privacidad diferencial con un presupuesto  $\epsilon$  muy pequeño puede degradar tanto el modelo que al final no merece la pena ([«Differentially Private and Adversarially Robust Machine Learning: An Empirical Evaluation» 2024](#)).

La Tabla 2.1 recoge las dimensiones principales de las cuales la anonimización se hace notar en los modelos de inteligencia artificial.

| Tabla 2.1: Dimensiones del impacto de la anonimización sobre modelos de IA. |                                                                                |                                                                                                                                                                                                   |
|-----------------------------------------------------------------------------|--------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Dimensión                                                                   | Impacto de la Anonimización                                                    | Consecuencia en el Modelo                                                                                                                                                                         |
| Estructura Estadística                                                      | Alteración de medias, varianzas y correlaciones.                               | Desplazamiento de la frontera de decisión y pérdida de precisión (Dwork et al. <a href="#">2006</a> ).                                                                                            |
| Granularidad                                                                | Generalización de valores (ej. rangos de edad en lugar de años exactos).       | Dificultad para capturar patrones sutiles o nichos específicos (Sweeney <a href="#">2002</a> ).                                                                                                   |
| Representatividad                                                           | Supresión de valores atípicos ( <i>outliers</i> ) para evitar singularización. | Aumento del error en casos raros y posibles problemas de equidad ( <i>fairness</i> ) (Bagdasaryan, Poursaeed y Shmatikov <a href="#">2019</a> ).                                                  |
| Robustez                                                                    | Inyección de ruido aleatorio (Laplace/Gauss).                                  | Puede actuar como regularizador o, en exceso, impedir la convergencia ( <a href="#">«Privacy, Utility and Fairness: Navigating Trade-offs in Differentially Private Machine Learning» 2025</a> ). |

## 2.2. Privacidad Sintáctica y sus variantes.

Los modelos de privacidad sintáctica transforman la estructura de los datos para que cumplan con reglas significativamente distintas a su forma original antes de ser publicados o de ser usados como fuente de información para entrenar un modelo. Ese tratamiento se reduce en la práctica a dos operaciones: generalizar y suprimir atributos.

### 2.2.1. El modelo de $k$ -anonimato.

Sweeney (Sweeney 2002) formalizó el  $k$ -anonimato como una vía de defensa ante los ataques de enlazamientos. La idea es clara: a la hora de publicar el conjunto, cada registro debe llegar a ser indistinguible al menos con otros  $k - 1$  registros con respecto a los denominados **cuasi-identificadores** (QID). Los cuasi-identificadores son las variables que no pueden por sí solas identificar a una persona, pero que permiten mediante el enriquecimiento con otras fuentes externas reidentificar a la persona.

Dado que los individuos se agrupan en “clases de equivalencia” con cardinalidad  $k$  o mayor, la probabilidad de conseguir identificar a un sujeto concreto a partir de sus QID queda reducida de forma significativa, y pasa a ser  $1/k$ . Para tal fin se han propuesto diferentes algoritmos. El más relevante para este trabajo es el método **Mondrian** (LeFevre, DeWitt y Ramakrishnan 2006), un método *top-down* que divide de forma recursiva el espacio multidimensional para construir esas clases a la hora de generalizar la información tratando de perder la mínima información posible ([«Modeling and Evaluation of k-anonymization Metrics» 2020](#)).

### 2.2.2. Vulnerabilidades y extensiones: el concepto de $l$ -diversidad y el de $t$ -cercanía

La garantía de  $k$ -anonimato frente a la reidentificación es muy fuerte, pero no es total. Trabajos posteriores han mostrado que el modelo es vulnerable a dos tipos de ataque, en concreto, ataques de homogeneidad y ataques de conocimiento previo, o, lo que es lo mismo, ataques de *background knowledge* (ver ([Provably Private Data Anonymization: Or, k-Anonymity Meets Differential Privacy 2010](#))). El caso más sencillo de visualizar sería aquel en que todos los registros de una clase de equivalencia presentan el mismo valor en el atributo sensible —por ejemplo, tienen el diagnóstico de “cáncer”— y que, por tanto, con saber que la víctima pertenece a dicha clase ya se puede inferir su atributo sin necesidad de la identificación.

Como respuesta a estas debilidades surgen dos ampliaciones:

- ***l*-diversidad**, de Machanavajjhala (Machanavajjhala et al. 2007), le añade un requerimiento al atributo sensible: cada clase de equivalencia debe contener al menos *l* valores distintos “bien representados”. De este modo, se reduce la confianza con la que un atacante puede inferir el atributo y se corta de raíz los ataques de homogeneidad.
- ***t*-cercanía** (*t-closeness*), de Li (N. Li, T. Li y Venkatasubramanian 2007), va todavía más allá y atiende a las distribuciones: la distribución del atributo sensible dentro de cada clase debe ser parecida a la distribución global. Es una garantía semántica que apaga los ataques que se basan en la asimetría o similitud entre las distribuciones local y global a los que la *l*-diversidad sigue siendo vulnerable.

Pero estas restricciones tienen, por otro lado, un precio. Cuanta más exigente sea la sintaxis (*k*, *l* o *t*), más granularidad pierde la medida. Esa pérdida no perdona a los modelos de *Machine Learning* en lo que se refiere a “captar patrones sutiles” ya que desplaza la frontera de decisión y hace caer la precisión de la predicción («Secure Data Sharing in Machine Learning: Exploring K-Anonymization and Differential Privacy» 2024).

## 2.3. Privacidad Semántica: Privacidad Diferencial

Mientras que los enfoques sintácticos se hayan encargado de transformar directamente el dato a partir de generalizaciones o de eliminaciones, la Privacidad Diferencial intenta abordar el problema desde otro tipo de perspectiva, más bien semántica. Dwork (Dwork 2006) la formalizó hace ya cerca de dos décadas y, hoy por hoy, es la base más consistente en el tema de la privacidad estadística, ya que ofrece garantías matemáticas demostrables que nos permitirán saber cuánta información es capaz de revelar un análisis sobre un determinado individuo concreto.

La mecánica es sencilla: se inyecta ruido aleatorio ajustado a nivel matemático para ocultar la aportación de cualquier sujeto del conjunto (Dwork et al. 2006). La consecuencia es que cualquier consulta o cualquier modelo construido sobre los datos devuelve un resultado estadísticamente indistinguible con y sin la existencia de un determinado registro en el entrenamiento. El nivel de esa garantía se controla por el *presupuesto de privacidad*, representado como  $\epsilon$ : cuanto menor sea, mayor será la protección pero también la cantidad de ruido inyectado y, con ello, el riesgo de dañar el modelo hasta hacerlo inoperante en la práctica («Privacy, Utility and Fairness: Navigating Trade-offs in Differentially Private Machine Learning» 2025).



### 2.3.1. Paradigmas de aplicación: DP Local y DP Global

Existen fundamentalmente dos estrategias para realizar la DP y se diferencian en el punto de inyección del ruido en el flujo del dato:

- **Privacidad diferencial local (LDP):** el ruido se inyecta en el propio dispositivo del usuario, antes de que el dato salga (Labelia Labs 2024). El agregador nunca llega a observar los datos ya que los mismos no aparecen desvelados, lo que permite realizar la protección más fuerte frente a los servidores no confiables. A pesar de lo anterior, a menudo se requiere cantidad de datos muy alta para que la señal estadística sobreviva al ruido.
- **Privacidad diferencial global o centralizada:** el dato es capturado en claro y, a posteriori, se inyecta ruido, ya sea a la salida de la consulta o durante el entrenamiento del modelo («Differentially Private and Adversarially Robust Machine Learning: An Empirical Evaluation» 2024). Supongamos que hay un curador de confianza que, con el mismo presupuesto de privacidad  $\epsilon$ , puede ofrecer una utilidad analítica considerablemente mayor que la implementación local

### 2.3.2. Privacidad Diferencial en el Aprendizaje Automático

La incorporación de la Privacidad Diferencial (DP) en el ámbito del aprendizaje automático ha requerido ajustes en la fase de optimización. Para las redes neuronales profundas, el enfoque más reconocido es el **Descenso de Gradiente Estocástico Privado (DP-SGD)** propuesto por Abadi (Abadi et al. 2016). En cada ciclo de entrenamiento, DP-SGD lleva a cabo dos operaciones fundamentales que es útil entender por separado. En primer lugar, recorta los gradientes (a veces referido como *clipping*) para asegurarse de que la influencia de ningún individuo sobre el modelo esté limitada a un umbral predefinido. Posteriormente, añade ruido a los gradientes que ya han sido agregados antes de proceder a actualizar los pesos del modelo.

En la actualidad, existen bibliotecas que simplifican considerablemente todo este proceso. Para las redes neuronales, destaca *Opacus* (Meta AI 2020), que permite entrenar modelos con DP y lleva un registro preciso del presupuesto de privacidad utilizado a lo largo de las épocas de entrenamiento. En el ámbito de los modelos clásicos de *Machine Learning*, *IBM Diffprivlib* (Holohan et al. 2019) combina mecanismos de DP con una API que es compatible con *scikit-learn*, facilitando así la transición de un modelo estándar a una versión que respeta la privacidad con mínimos cambios.

## 2.4. Generación de Datos Sintéticos

En los últimos años, la producción de datos artificiales que respetan las propiedades estadísticas del original se ha convertido en uno de los campos más activos en la intersección entre la privacidad y el *Machine Learning* (*Synthetic Data – what, why and how?* 2024). La hipótesis es conseguir un nuevo conjunto en el que no sea posible hacer una correspondencia uno a uno con los individuos del original, pero que persista la correlación y la estructura multidimensional del dato real.

Las dos familias de arquitecturas que dominan el campo son las Redes Generativas Adversarias (GANs) (Goodfellow et al. 2014) y los Autoencoders Variacionales (VAEs). Para datos tabulares con columnas mixtas, variaciones como las CTGAN (Xu et al. 2019) dan unos resultados especialmente buenos. La manera habitual de medir hasta qué punto estos pasos han dado valor de verdad es preguntando si el conjunto sintético sirve para sustituir al real en tareas *downstream* sin perder rendimiento.

Hay un debate activo en la comunidad ¿Los datos sintéticos son privativos por sí mismos? («Differentially Private Synthetic Data Enables Public Release of Behavioral Health Information with High Utility» 2025). Varios estudios han mostrado que los modelos generativos potentes tienden a memorizar hasta el punto de conseguir reproducir con alta fidelidad registros atípicos del aprendizaje («Membership Inference Attacks Against Synthetic Health Data» 2022). La conclusión práctica es que para evitar ataques de inferencia de membresía la generación sintética se combinará normalmente con garantías matemáticas adicionales como la Privacidad Diferencial.

## 2.5. Paradigmas Colaborativos: Aprendizaje Federado (FL)

El Aprendizaje Federado, según McMahan (McMahan et al. 2017), va en sentido contrario al paradigma clásico que consiste en centralizar los datos en un único servidor. Los datos residen en el dispositivo origen o en “silos” locales protegidos, lo que viaja a través de la red son las actualizaciones de pesos o los gradientes que cada nodo localmente computa al entrenar localmente. Un servidor central añade esas actualizaciones con el fin de construir el modelo global («Privacy-preserving machine learning: a review of federated learning techniques and applications» 2025).

Esto representa una vía especialmente útil en el ámbito del sanitario, donde la movilidad de datos sensibles entre instituciones suele aparecer restringida por ley («Empirical Analysis of Privacy-Fairness-Accuracy Trade-offs in Federated Learning» 2025).

Sin embargo, aunque el FL evita compartir los microdatos, los gradientes pueden seguirse filtrando: un atacante puede usarlos para reconstruir parte del dato original a través de ataques de inversión. La línea de investigación más activa que se hace en este punto consiste en estudiar cómo combinar FL con otras tecnologías de mejora de la privacidad (PETs). Las combinaciones más estudiadas son FL + DP y FL + Computación Segura Multiparte (SMPC), las cuales permiten añadir capas extra de protección y permiten una colaboración efectiva entre instituciones sin comprometer la confidencialidad ([«Privacy-preserving machine learning: a review of federated learning techniques and applications» 2025](#)).

## 2.6. Evaluación de Riesgos y Auditoría Algorítmica

Antes de finalizar el estado del arte, a partir de la lectura de él, conviene hacer un repaso de las amenazas concretas a las que están expuestos estos sistemas y cómo es posible medir empíricamente las protecciones aplicadas durante la ejecución del uso del modelo. La auditoría algorítmica moderna comienza a basarse más en evaluaciones de riesgo que en garantías formales aisladas.

### 2.6.1. Ataques a Modelos de Inteligencia Artificial

Una forma clásica de la medida de la robustez de un modelo frente a la re-identificación consiste en la simulación del comportamiento de un adversario. La amenaza más estudiada al respecto son los **ataques de inferencia de membresía** — formalizados por Shokri (Shokri et al. [2017](#)) — donde un atacante ajeno al modelo interactúa con él, en modo *caja negra*, tratando de deducir si un individuo determinado fue entrenado en la arquitectura del modelo.

La fisura aprovechada por los ataques adversariales es bien conocida. Los modelos, y en particular, las redes profundas propensas al overfitting, suelen ser más confiados con las predicciones de ejemplos que provienen del conjunto de entrenamiento que con ejemplos que no lo son. Esta distancia en las distribuciones de confianza es precisamente lo que un MIA explota en su ataque para violar la privacidad. Por este motivo, en la práctica, las auditorías *red teaming* y herramientas de simulación adversarial como el Adversarial Robustness Toolbox (Linux Foundation AI & Data [2018](#)) se han vuelto esenciales para cuantificar el riesgo real (Galileo AI [2025](#)).

### 2.6.2. Influencia en la Equidad e Igualdad Algorítmica

Un ámbito que ha ido ganando peso muy rápidamente es el relativo a la influencia de la privacidad sobre la equidad algorítmica. La evaluación de las técnicas de ocultamiento (anonimización) históricamente ha estado centrado en el trade-off entre privacidad y precisión y rara vez se encontraba que la degradación afecta de igual forma a todos los ficheros demográficos. Trabajos como el que hacen Bagdasaryan (Bagdasaryan, Poursaeed y Shmatikov 2019) apuntan a una respuesta incómoda: técnicas robustas como la Privacidad Diferencial pueden amplificar sesgos presentes en el dataset. El ruido y el trimming de gradientes penalizan de manera más intensa a las minorías o a grupos infrarrepresentados que al grupo mayoritario. Para medir y, en la medida de lo posible, mitigar ese impacto desproporcionado, la comunidad científica ha adoptado dos métricas muy concretas de equidad algorítmica. La **Paridad Demográfica** sirve para comprobar si las tasas de predicción positiva son independientes del atributo sensible (raza, género, etc.). La **Disparidad de Pérdida** mide directamente la diferencia en la tasa de error entre subgrupos ([«Privacy, Utility and Fairness: Navigating Trade-offs in Differentially Private Machine Learning» 2025](#)). Sin estas métricas, cualquier discusión sobre IA responsable se queda corta tanto ética como técnicamente.

# Capítulo 3

## Materiales y Métodos

En este capítulo se explica la forma de trabajo para cumplir con los objetivos de la investigación. Se describe el entorno tecnológico, el conjunto de datos y el flujo de ejecución, que va desde la limpieza y el perfilado de riesgo de privacidad a la anonimización y la evaluación de los modelos de IA.

### 3.1. Entorno Experimental y Selección de los Datos

Para garantizar la reproducibilidad de los experimentos y al mismo tiempo para alinear el trabajo con las buenas prácticas actuales de la industria, el desarrollo práctico de la investigación se ha realizado en un entorno basado en *cloud computing* proveniente de **Google Colab**, que proporciona los recursos computacionales necesarios para entrenar de forma eficiente modelos analíticos y ejecutar algoritmos de inyección de ruido estadístico. El lenguaje de programación principal utilizado ha sido **Python 3**, orquestando un ecosistema de librerías definido en dos categorías funcionales principales:

- **Librerías de base de Ciencia de Datos:** Para la manipulación y limpieza de los datos se ha utilizado `pandas` y `numpy`. Para la estructuración de los datos en matrices, la estandarización de características, la división de conjuntos y la puesta a punto de modelos de referencia hemos incorporado `scikit-learn`.
- **Librerías de Privacidad y Seguridad:** El entorno incluye `diffprivlib` para la implementación nativa de la Privacidad Diferencial en algoritmos de Machine Learning clásicos; `opacus` para las redes neuronales; `sdv` (*Synthetic Data Vault*) para la posterior generación de datos sintéticos; `adversarial-robustness-toolbox` (o ART) para la auditoría de riesgo adversarial mediante ataques de membresía. También se prevé el uso de herramientas externas de escritorio tipo **ARX** para aplicar de forma estricta las métricas de privacidad sintáctica ( $k$ -anonimidad) sobre los registros tabulares.

### 3.1.1. Selección y Justificación del Conjunto de Datos

Uno de los criterios fundamentales de esta investigación es determinar el impacto de las técnicas de anonimización en un dominio crítico que contenga información altamente sensible (por la normativa que lo regula en determinado contexto normativo, como el RGPD (*Reglamento (UE) 2016/679* 2016)); por ello, se ha decidido conducir el estudio en un dominio crítico como es el ámbito sanitario.

El conjunto de datos seleccionado es el *Diabetes 130-US hospitals for years 1999-2008 Data Set* (Strack, J. DeShazo et al. 2014), directamente importado de la interfaz oficial del repositorio UCI Machine Learning (ucimlrepo, ID 296). Este dataset consiste en registros clínicos reales, y contiene información detallada de los encuentros hospitalarios de pacientes diagnosticados con diabetes, cuya publicación original era paralela a un estudio sobre el impacto de la hemoglobina glicosilada (HbA1c) en las tasas de reingreso hospitalario (Strack, J. P. DeShazo et al. 2014). La selección de este dataset responde a 3 importantes razones metodológicas:

1. **Volumen de la muestra:** El conjunto tiene una ingesta original de 101.766 registros. Este elevado volumen constituye un prerequisite ineludible para la aplicación de algoritmos de Privacidad Diferencial, dado que conjuntos excesivamente pequeños sufren un efecto de eliminación de la señal predictiva ante la inyección de ruido matemático (Dwork et al. 2006).
2. **Riqueza dimensional:** Compone 48 características originales, que constan de atributos demográficos, historial de admisiones, resultados de pruebas de laboratorio y medicación administrada.
3. **Naturaleza de las variables:** Permite una segmentación correcta que exige la teoría de la anonimización, presentando de manera natural *cuasi-identificadores* (como raza, género o edad), *atributos sensibles* (diagnósticos primarios y secundarios organizados en códigos CIE-9, o tratamientos con insulina) y una *variable objetivo* explícita: predecir si el paciente será readmitido en el hospital en un período definido (*readmitted*).

Cabe destacar que, en esta base de datos, la variable **age** (edad) no se recopila de forma exacta y numérica sino que ya puede encontrarse agrupada a intervalos de décadas poblacionales  $[0-10)$ ,  $[10-20)$ , ...,  $[90-100)$ . Esta reagrupación de datos previos ya reduce intrínsecamente todo riesgo de re-identificación y así se abordará en la fase de perfilado de privacidad y también se plasmará como una limitación del estudio en el apartado de conclusiones. Conjugado dicho contexto tecnológico estandarizado y una base de datos clínico de alta dimensionalidad establece la condición empírica necesaria para cuantificar el dilema de la protección de la identidad del paciente y de la utilidad analítica del dato (Argyriou et al. 2025).

## 3.2. Ingesta y Preprocesamiento

La primera etapa se centra en la preparación y en la limpieza de la colección original para su futura aplicabilidad a los procesos algorítmicos correspondientes. Para esta fase de lectura y de limpieza, se ha implementado la librería **pandas** incorporada en el lenguaje de programación Python.

Una vez se ha cargado el *dataset* clínico (inicialmente formado por 101.766 filas y 48 atributos), se ha realizado un exhaustivo análisis exploratorio. El *dataset* contenía los valores perdidos codificados como el carácter ?, que fueron transformados a NaN, un formato estándar de nulo para proceder a su posterior tratamiento estadístico.

El análisis de completitud nos condujo a la detección de una notable variabilidad en la distribución de valores nulos, hasta el punto de obligarnos a emplear tres diferentes estrategias de preprocesamiento para evitar la aparición del sesgo algorítmico:

- **Supresión de las características no recuperables:** Se observó que la variable **weight** (peso del paciente) poseía un porcentaje de valores nulos del 96,85%. Ante la imposibilidad de realizar una imputación que respetase la distribución de los datos válida en algunas muestras tan exigente, esta columna fue eliminada del espacio de las características.
- **Imputación semántica de la ausencia de dato:** Las variables clínicas no recuperables vinculadas a pruebas de laboratorio presentaban unos elevados índices de valores nulos (ej. **max\_glu\_serum**=94,74%, **A1Cresult**=83,27% y **medical\_specialty**=49,08%). Desde una práctica médica poco convencional, la ausencia de la prueba clínica no se concebía como un error en la recogida, sino como información médica de alto valor semántico (por cuanto indicaban que el facultativo no consideró realizar dicha prueba). De este modo, los valores nulos se imputaron mediante la creación de una nueva categoría unificada de prueba médica no recuperable denominada "No\_Registrado".
- **Eliminación de registros (*Listwise Deletion*):** Finalmente, para aquellas columnas que presentaban un porcentaje de nulos residual (inferior al 3% como **race**, **diag\_1**, **diag\_2** o **diag\_3**) se procedía a la eliminación de las filas correspondientes. Esta práctica se asemejaba bastante a la política habitual de usar dicha técnica para preservar la integridad de los registros de la variable **race** (raza), ya que esta columna está designada como un *cuasi-identificador* troncal para la correcta ejecución matemática de las técnicas de *k*-anonimidad en las fases posteriores (Sweeney 2002).

Como resultado de esta fase correspondiente a la depuración de datos, el conjunto reducido de datos se conformó de una matriz de **98.053 registros completamente limpios y 47 características**.

Posteriormente a su eliminación se comprobó que la distribución de la variable **race** no había generado sesgos significativos en este ajuste, comprobación que es relevante para los análisis de equidad algorítmica (*fairness*) en etapas posteriores. La distribución final presentó la representatividad mayoritaria de pacientes caucásicos (76,6 %) frente al número de afro-americanos (19,3 %), hispanos (2,0 %), otros (1,5 %) y asiáticos (0,6 %), un desbalanceo que resulta de un interés considerar a la hora de evaluar el impacto diferencial de las técnicas de privacidad a grupos minoritarios (Bagdasaryan, Poursaeed y Shmatikov 2019). Por último, se ejecutó la primera acción de anonimización directa, la verificación de que no existían identificadores explícitos. La interfaz `fetch_ucirepo` del UCI repository limita automáticamente los identificadores directos (`encounter_id` y `patient_nbr`) del espacio de *features*, de modo que el conjunto de datos importado no contenía variables con capacidad de identificación unívoca directa antes de acudir al perfilado algorítmico del riesgo de reidentificación.

### 3.3. Perfilado de Privacidad y Análisis de Riesgo Basal

Una vez asegurada la inalteración estructural del conjunto de datos y constatada la inexistencia de mínimos identificadores, la siguiente fase metodológica consistió en ejecutar un perfilado de privacidad. Se persigue cuantificar empíricamente el riesgo que presenta la base de datos frente a posibles ataques de enlace (*linkage attacks*), incluso antes de haber implementado la antes mencionada técnica algorítmica de la protección de datos.

Para ello, se llevó a cabo una formalización de los atributos restantes de acuerdo con la clasificación de la privacidad de datos anotada:

- **Variable Objetivo (*Target*):** `readmitted`, que denota si el paciente fue readmitido dentro de los márgenes del hospital. Es un requisito indispensable para valorar la utilidad posterior de los modelos de clasificación.
- **Sensitive Attributes (SA):** La información clínica que es sensible y confidencial con relación a los diagnósticos médicos y a las pautas de medicación (ej. administración de insulina, administración de metformina, etc.).
- **Cuasi-identificadores (QID):** Atributos que, aunque no identifican a un individuo, por sí mismos, pueden agruparse con otros para permitir la posterior reidentificación si el atacante tiene conocimiento previo (*background knowledge*) (Sweeney 2002).

Para la evaluación de la reidentificación basal, se ejecutó un agrupamiento de todos aquellos registros en *equivalence classes* —subconjuntos de pacientes que comparten exactamente la misma combinación de cuasi-identificadores—. Esta investigación se realizó de manera iterativa para poder modelar diferentes capacidades del atacante.



### 3.3.1. Evaluación del modelo de atacante y expansión de QIDs

En una primera iteración, se asumió un modelo de atacante por defecto, con conocimiento de cuatro quisi-identificadores: raza (`race`), género (`gender`), edad (`age`) y tiempo de estancia en el hospital (`time_in_hospital`).

El cálculo de las clases de equivalencia generó un riesgo reidentificativo muy bajo: solamente 133 pacientes eran únicos en la base de datos (vulnerabilidad extrema correspondiente a  $k = 1$ , es decir, 0,14% del total del conjunto de datos) y solo 662 pacientes (0,68%) eran grupos inferiores al umbral de seguridad médico recomendado de  $k = 5$ . Este escaso riesgo reidentificativo se debe en buena medida a que la variable bajo la que se realizó la generalización (`age`), una variable continua, era agrupada en intervalos por década, lo que acortó el modelo a un total de únicamente 1.009 combinaciones de combinaciones únicas de QIDs.

Aunque estos resultados indican que el conjunto de datos tiene cierta protección inherente con cuatro quisi-identificadores, un riesgo basal de bajo potencial re-identificativo dificultaría justificar y cuantificar la aplicabilidad de las técnicas de anonimización avanzadas que constituyen el objetivo central de esta investigación. Por lo tanto, se procedió a ampliar el modelo de ataque asumiendo un atacante que tuviese el escenario más realista posible, o que tuviese acceso a registros administrativos complementarios, como una factura de hospitalización. Para ello se incorporó un quinto quisi-identificador, el tipo de ingreso hospitalario (`admission_type_id`).

### 3.3.2. Resultados del Riesgo Basal Definitivo

La incorporación de este quinto cuasi-identificador fragmentó significativamente las clases equivalentes, mostrando la vulnerabilidad real intrínseca subyacente al conjunto de datos. Sobre el total de 98.053 registros examinados, se encontraron 3.516 combinaciones únicas de QIDs y se arrojan las siguientes métricas de riesgo basal:

- **Vulnerabilidad extrema ( $k = 1$ ):** 920 pacientes presentaban una combinación totalmente exclusiva de características, lo que corresponde a un riesgo de re-identificación directa del 0,94%. La persona atacante que conociera estos 5 datos demográficos y administrativos de uno de los pacientes de este subgrupo podría enlazar explícitamente su identidad con los registros de atributos médicos sensibles.
- **Vulnerabilidad estándar ( $k < 5$ ):** 3.448 pacientes (el 3,52% del total del conjunto) se encuentran expuestos en grupos inferiores a 5. Este umbral  $k = 5$  es el recomendado en la literatura sobre privacidad en el ámbito sanitario ([«Secure Data Sharing in Machine Learning: Exploring K-Anonymization and Differential Privacy» 2024](#)).

El hallazgo de estos más de 3.400 registros vulnerables valida la premisa teórica de la investigación: la simple supresión de identificadores directos (*seudonimización*) es claramente una insuficiencia en términos de medidas de seguridad. Además, estos resultados justifican formalmente la necesidad de aplicar esquemas de privacidad sintáctica más sofisticados (a través de herramientas como ARX) y de aplicar técnicas de inyección de ruido (Privacidad Diferencial) en las siguientes fases del proyecto.

### 3.4. Transformación Específica para la Privacidad (Reducción del Conjunto de Características)

La preparación de datos categóricos para el entrenamiento de modelos de *Machine Learning* requiere, por norma general, la aplicación de técnicas de codificación como el *One-Hot Encoding* (OHE). La aplicación de este proceso sobre el pequeño conjunto de datos limpio evidenció un problema de alta cardinalidad: el de obtener un espacio de características que podría ser el de las 47 columnas a las que se les solicitan 2.405 dimensiones. La explosión de dimensionalidad para este conjunto de datos tuvo su origen en las variables de los diagnósticos médicos principales y secundarios (*diag\_1*, *diag\_2* y *diag\_3*) donde cada una de ellas atesoraba cientos de códigos distintos basados en la Clasificación Internacional de Enfermedades (CIE-9). Un primer modelo exploratorio de Regresión Logística entrenado por este espacio de 2.405 dimensiones resultó en un *Accuracy* de 0,6260, lo que hace ver que el conjunto de datos realmente tiene el potencial predictivo inherente que se esperaba y lo que también permite atestiguar que la explosión de dimensionalidad no llega a mostrar una ganancia suficientemente significativa frente a los inconvenientes que se introducen para las técnicas de privacidad.

#### 3.4.1. El problema de la dimensionalidad en Privacidad Diferencial

En un contexto analítico clásico, los modelos como la Regresión Logística regularizada pueden lidiar con espacios de alta dimensionalidad. En cambio, el marco de la Privacidad Diferencial reduce drásticamente la posibilidad de participar.

Los algoritmos de *Machine Learning* diferencialmente privados (por ejemplo, los que implementa la librería `diffprivlib`) garantizan la privacidad mediante la inyección de ruido matemático —normalmente mediante mecanismos de Laplace o Gauss— en la función de coste o en los gradientes del proceso de entrenamiento (Dwork et al. 2006). La cantidad de ruido que se introduce es proporcional a la sensibilidad de la función y se reparte entre todos los pesos del modelo. Por lo tanto, inyectar ruido en 2.405 pesos *sen/estid* puede exagerarse lo suficiente como para hacer que la señal estadística legítima raramente sea suficiente, provocando un colapso de la capacidad predictiva del modelo y aproximando la utilidad del modelo a un azar (Abadi et al. 2016).

### 3.4.2. Agrupación semántica de códigos CIE-9

A fin de poder experimentar con Privacidad Diferencial a la vez que se garantiza un *trade-off* aceptable entre privacidad y utilidad, se realizó previamente una reducción de la dimensionalidad mediante conocimiento del dominio clínico.

En lugar de llevar a cabo técnicas de naturaleza puramente matemática (como el PCA) que incurriría en el riesgo de perder la interpretabilidad de las características sensibles, se optó por la agrupación clínica estandarizada propuesta por Strack et al. (Strack, J. P. DeShazo et al. 2014) contenida en la Tabla 2 del estudio que acompaña a la publicación del conjunto de datos original. Esta agrupación consolida los códigos CIE-9 en nueve macrocategorías médicas generalmente reutilizadas en la literatura posterior sobre este *dataset*:

- **Diabetes:** Códigos 250.x.
- **Sistema Circulatorio (*Circulatory*):** Códigos 390-459 y 785.
- **Sistema Respiratorio (*Respiratory*):** Códigos 460-519 y 786.
- **Sistema Digestivo (*Digestive*):** Códigos 520-579 y 787.
- **Sistema Genitourinario (*Genitourinary*):** Códigos 580-629 y 788.
- **Sistema Musculoesquelético (*Musculoskeletal*):** Códigos 710-739.
- **Lesiones (*Injury*):** Códigos 800-999.
- **Neoplasias (*Neoplasms*):** Códigos 140-239.
- **Otras/No clasificadas (*Other*):** Códigos restantes, suplementarios (V o E) y valores faltantes arrastrados.

Después de aplicar este mapeo semántico a las tres variables de diagnóstico y eliminar la variable `medical_specialty` (la cual, como se demuestra en el próximo apartado, también generaba redundancia tras la agrupación), se llevó a cabo el procedimiento de codificación OHE nuevamente.

El resultado fue la fuerte reducción del espacio de características, pasando de **2.405 a 121 dimensiones**. Este ajuste del conjunto de datos es capaz de conservar la señal médica subyacente, a la vez que permite tener una base computacionalmente estable y matemáticamente adecuada para la convergencia de los algoritmos de Privacidad Diferencial en las fases posteriores.

### 3.5. Modelado de Referencia (Baseline)

Para ser capaces de cuantificar siguiendo el rigor científico la pérdida de utilidad *utility loss* que introducen los mecanismos de anonimización y de Privacidad Diferencial, debemos, primero, definir un escenario de referencia o *Baseline*; esto es, el modelo base que identifica el "techo de rendimiento" predictivo, el cual es entrenado usando los datos originales en claro tras realizar su limpieza y reducción de dimensionalidad, pero sin aplicar ningún tipo de perturbación de la información procedente de la privacidad.

#### 3.5.1. Preparación y escalado de los datos

Antes del entrenamiento algorítmico, el conjunto de datos reducido (121 dimensiones) recibió una etapa final de adaptación matemática:

1. **Binarización de la variable dependiente:** La variable independiente `readmitted` tenía tres clases (*NO*, *<30 días*, *>30 días*); para facilitar la evaluación de la degradación del modelo y enmarcar el problema dentro de un contexto de clasificación binaria típica, se realizó la transformación siguiendo la cual el valor *NO* se identifica como la clase negativa (0, no readmitido) y cualquier otro valor es tomado como la clase positiva (1, readmitido).
2. **Partición del conjunto de los datos:** Se decidió dividir el conjunto en un conjunto de entrenamiento (80%, 78.442 registros) y un conjunto de test (20%, 19.611 registros); sin embargo, para garantizar la representatividad de las clases, se aplica un muestreo estratificado (`stratify`) asociado a la variable dependiente.
3. **Estandarización (*Scaling*):** La transformación `StandardScaler` de *scikit-learn* se aplicó sobre el conjunto de entrenamiento, ajustando las características numéricas de forma que presenten una media de 0 y una varianza de 1 ( $\mu = 0, \sigma = 1$ ); más allá de considerarse una buena práctica garantizar la convergencia de modelos lineales, éste es un **requisito matemático muy estricto** para que se pueda realizar en el futuro la aplicación de la Privacidad Diferencial, ya que los algoritmos de `diffprivlib` requieren que se conozca o se acote la norma máxima de los vectores de entrada para adecuar correctamente la inyección de ruido (Holohan et al. 2019).

### 3.5.2. Entrenamiento y métricas de utilidad base

A fin de colocar una línea de referencia completa, se entrenaron 4 modelos de clasificación que representan diferentes paradigmas de algoritmos de aprendizaje. La elección de estos modelos se debe a un doble criterio. Por un lado, se intenta cubrir familias algorítmicas que tengan distintos mecanismos de aprendizaje (lineales, basados en árboles y probabilistas); y, por otro lado, se priorizan aquellos para los que existen implementaciones homólogas con Privacidad Diferencial en la hilo `diffprivlib`, lo que permitirá una comparación simétrica en posteriores fases.

Los 4 modelos entrenados y los resultados obtenidos sobre el conjunto de prueba aislado se pueden consultar en la Tabla 3.1.

Tabla 3.1: Rendimiento de los modelos Baseline sobre el conjunto de datos reducido.

| Modelo                 | <i>Accuracy</i> | <i>F1-Score (Pond.)</i> |
|------------------------|-----------------|-------------------------|
| Random Forest          | 0,6300          | 0,6277                  |
| Regresión Logística    | 0,6178          | 0,6159                  |
| Árbol de Decisión      | 0,6138          | 0,6138                  |
| Naive Bayes (Gaussian) | 0,5912          | 0,5599                  |

Los resultados muestran un rendimiento constante entre los modelos, ya que los valores de *Accuracy* están entre 0.59-0.63. Estos valores es necesario matizarlos: el *dataset* de diabetes 130-US hospitals se trata un problema de clasificación difícil de resolver, ya que la readmisión depende de múltiples factores clínicos y socioeconómicos que no están incluidos en las variables disponibles (Strack, J. P. DeShazo et al. 2014). Estos resultados corroboran los indicios encontrados en trabajos previos sobre este mismo *dataset*.

El rendimiento moderado del *baseline* es favorable para los objetivos de esta investigación, ya que si un modelo tiene un techo de rendimiento muy elevado (por encima de 0.95), será complicado poder analizar la degradación de la misma, ya que lo que podamos ver será en fases muy avanzadas de su degradación. Habiendo un *baseline* que ronda el 0.63, sí que hay un lugar para observar y cuantificar las degradaciones que permiten las distintas técnicas de anonimización, de forma que no se colapse el rendimiento de entrada.

El modelo de Naive Bayes (Gaussian) presenta un rendimiento muy inferior al resto. Este hecho se explica parcialmente porque, a diferencia de los otros tres modelos entrenados, los `class_weight='balanced'` se configura para compensar así el desbalanceo de clases, el clasificador `GaussianNB` de *scikit-learn* no dispone de este parámetro para hacerlo de forma nativa, así que tiene más sensibilidad con la distribución asimétrica de la variable objetivo.

Estos valores, en este sentido, son formalmente los **cotas máximas de utilidad** que nos permiten establecer que cualquier modelo entrenado más adelante sobre datos perturbados sintácticamente (mediante ARX) u o bien mediante ruido algorítmico (por medio de Privacidad Diferencial) se comparará con ellos para poder detallar el *trade-off* exacto entre privacidad y utilidad sólo de esta investigación.

### 3.6. Aplicación de Privacidad Sintáctica mediante ARX

Una vez que se ha instaurado la cima de la utilidad acerca de los datos, la siguiente etapa es aplicar las garantías de privacidad sintáctica formalizadas en el capítulo 2. Para ello se ha utilizado la herramienta **ARX Data Anonymization Tool** (Prasser y Kohlmayer 2015), una solución de código abierto que ha sido desarrollada en la Technische Universität München y la cual se ha erigido como la implementada de manera más didáctica en la literatura de privacidad de los datos sanitarios. ARX implementa de forma nativa el algoritmo **Flash** (Kohlmayer et al. 2012), la variante de los métodos clásicos de búsqueda del retículo de generalizaciones optimizada, junto con garantías heurísticas que permitan dar soluciones globalmente óptimas para los criterios de privacidad seleccionados.

La propuesta de ARX al usarse en lugar de alternativas como **Amnesia** o implementaciones en Mondrian sobre Python responde a tres razones, (i) porque ofrece una interfaz gráfica que permite la auditoría visual del retículo de generalizaciones así como de las clases de equivalencia resultantes; (ii) porque permite la combinación de múltiples criterios de privacidad a la vez, sobre todo  $k$ -anonimidad,  $l$ -diversidad,  $t$ -ceranía, y porque (iii) es la herramienta que se encuentra presente en los numerosos estudios reproducibles en el ámbito sanitario favoreciendo de este modo la comparación de resultados de los mismos con el de la literatura existente.

#### 3.6.1. Configuración de atributos

De acuerdo con la taxonomía de privacidad establecida en la parte de perfilado, los atributos del dataset en ARX fueron implantados en su versión correspondiente a los cuatro tipos canónicos que admite la herramienta, tal y como se expone a continuación:

##### Quasi-identifying

###### Atributos:

`race`, `gender`, `age`, `time_in_hospital`, `admission_type_id`.

**Justificación:** combinación de cinco atributos identificada en el perfilado de riesgo basal como vector de re-identificación legítima.

##### Insensitive

**Atributos:** 41 atributos restantes (incluida `readmitted`).

**Justificación:** son variables clínicas y de medicación que se mantienen sin transformación, con objeto de conservar su utilidad analítica en el modelo. Por la misma razón, `readmitted` se clasifica como *Insensitive* en esta fase; la preocupación por protegerla forma parte del análisis de la phase posterior correspondiente a la Privacidad Diferencial; aplicar sobre ella la  $l$ -diversidad en este experimento mezclaría dos efectos y dificultaría la atribución de la pérdida de utilidad a una técnica concreta.

La decisión de no marcar `readmitted` como *Sensitive* en ARX requiere un apunte metodológico: de marcarla como tal obligaría a definir un criterio de privacidad adicional (*l*-diversidad o *t*-cercanía) que actuaría y modificaría la distribución de la variable objetivo en la que se encuentran las diferentes clases de equivalencia. Esto significaría incluir un segundo eje de variación no deseado en este experimento, cuya pregunta de investigación se centra exclusivamente en cuantificar el impacto de la generalización sobre los cuasi-identificadores. La protección frente a la inferencia de la variable objetivo se estudia en la fase correspondiente a la Privacidad Diferencial y se realiza añadiendo ruido controlado. La aplicación combinada de *l*-diversidad y *t*-cercanía sobre `readmitted` queda recogida como línea de trabajo futura en el Capítulo 5.

### 3.6.2. Jerarquías de Generalización

Para cada cuasi-identificador se ha elaborado una jerarquía de generalización que define los niveles de abstracción que puede aplicar ARX para construir las clases de equivalencia. El principio rector ha sido conservar la semántica clínica y demográfica en los niveles de abstracción intermedios, evitando gaps artificiales que sacrifiquen la interpretabilidad. La Tabla 3.2 resume las jerarquías que se han elaborado.

Tabla 3.2: Jerarquías de generalización empleadas en ARX.

| QID                            | Niveles | Estrategia de generalización                                                                                                                                      |
|--------------------------------|---------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <code>race</code>              | 3       | Original $\rightarrow$ binario <i>White/NonWhite</i> $\rightarrow$ supresión total (*).                                                                           |
| <code>gender</code>            | 1       | Supresión directa cuando sea necesario; incluye la categoría <i>Unknown/Invalid</i> presente en el dataset original.                                              |
| <code>age</code>               | 3       | Deciles originales $\rightarrow$ tramos de 20 años $\rightarrow$ tramos de 40 años $\rightarrow$ *.                                                               |
| <code>time_in_hospital</code>  | 3       | Días individuales $\rightarrow$ bins de 2–3 días $\rightarrow$ bins de 7 días $\rightarrow$ *.                                                                    |
| <code>admission_type_id</code> | 3       | Códigos UCI $\rightarrow$ etiquetas semánticas ( <i>Urgente/Electivo/Newborn/Desconocido</i> ) $\rightarrow$ binario <i>Conocido/Desconocido</i> $\rightarrow$ *. |

El diseño de tres niveles permite a ARX seleccionar dinámicamente el grado de generalización óptimo para cada clase de equivalencia, minimizando la pérdida de información mientras se cumple el criterio de privacidad solicitado.



### 3.6.3. Modelo de supresión y métrica de utilidad

ARX permite utilizar una aproximación combinada de generalización y supresión local, para registros que no tengan cabida en ninguna de las clases equivalencias que resultan válidas para este experimento. En este trabajo nos hemos decantado por el criterio por defecto que proporciona la herramienta, que permite una supresión de hasta el 100 % de registros, en caso de ser necesario desde un punto de vista matemático, para permitir al optimizador encontrar el equilibrio entre supresión y generalización. La métrica de utilidad empleada es la *Loss metric* (Iyengar 2002), que concretamente mide con carácter general la pérdida de información mediante la adición, en cada celda, de la fracción del rango de valores que la generalización incluye. Esta métrica es continua, monótona y permite comparar los diferentes niveles de  $k$  de forma backtracking.

### 3.6.4. Barrido de parámetros y exportación

Con el propósito de caracterizar la curva de la pérdida de utilidad conforme a la certeza de la garantía de privacidad, se ha llevado a cabo un barrido parametrando cinco valores de  $k$ :  $k \in \{2, 5, 10, 25, 50\}$ .

- Ante todo,  $k = 2$  representa el mínimo umbral de la privacidad sintáctica (cada registro indistinguible de, al menos, otro) y permite calibrar la sensibilidad de los modelos a una protección débil.
- $k = 5$  representa el umbral recomendado de la literatura de privacidad sanitaria («Secure Data Sharing in Machine Learning: Exploring K-Anonymization and Differential Privacy» 2024) y es ampliamente adoptado como referencia regulatoria.
- $k = 10$  refuerza la garantía a un nivel comúnmente exigido en publicaciones de micro-datos.
- $k = 25$  y  $k = 50$  exploran el extremo de máxima protección, de manera que la pérdida de utilidad es esperable que sea severa pero proporciona un punto de comparación frente a la Privacidad Diferencial con  $\epsilon$  bajos.

Por cada valor de  $k$ , se ha exportado el conjunto anonimizado en formato CSV (separador ;) bajo el patrón `arx_output_k<k>.csv`. El conjunto de prueba (20 % del total, 19.611 registros) se mantiene sin anonimizar, y conserva los valores originales de los cuasi-identificadores; esta decisión es acorde con un contexto perfectamente realista donde el modelo se entrena sobre datos protegidos y en producción recibe consultas con información en claro.



### 3.6.5. Reentrenamiento y métrica de comparación

Una vez efectuada la anonimización, cada conjunto `arx_output_k<k>.csv` vuelve a ser integrado en el pipeline de *Machine Learning* nuevamente codificándose a través de la misma transformación a *One-Hot Encoding* y estandarización del *baseline*. Un aspecto básico a destacar de esta parte del framework es el que garantiza que el espacio de características (i.e., column space) sea equivalente al que existe entre el conjunto de entrenamiento anonimizado y el conjunto de prueba en claro. Para asegurarlo, se aplica el OHE de forma *joint* considerando la concatenación de ambos subconjuntos, lo que, a su vez, preserva lo necesario en las dimensiones que deben existir entre los diferentes espacios para poder transferir el modelo entrenado al espacio de evaluación.

Sobre cada versión anonimizada se entrena nuevamente cada uno de los cuatro modelos de referencia (Regresión Logística, Random Forest, Árbol de Decisión y Naive Bayes Gaussian) de forma idéntica a los hiperparámetros del *baseline*, se extraen las métricas globales del *Accuracy* y del *F1-Score* ponderado, junto con dos métricas de diagnóstico de la privacidad: la cantidad de filas eliminadas por ARX y el número total de filas efectivas tras la supresión. Por otro lado, para poder cuantificar el efecto de la generalización en la equidad algorítmica, en este caso se desagregan las métricas por subgrupo de la variable `race` en el conjunto de prueba, calculándose la *Loss Disparity* respecto al *baseline* (Bagdasaryan, Poursaeed y Shmatikov 2019) la cual permite enfocar la pregunta de investigación sobre si la generalización afectará a los grupos menores de forma desproporcionada, tal y como se recomienda en el docx guía y se observa en la literatura reciente sobre justicia algorítmica ([«Privacy, Utility and Fairness: Navigating Trade-offs in Differentially Private Machine Learning» 2025](#)).

## 3.7. Implementación de la Privacidad Diferencial mediante `diffprivlib`

Una vez caracterizada la fase sintáctica, comienza la integración de **Privacidad Diferencial (DP)** en el ciclo de entrenamiento de los modelos de aprendizaje automático. Contrariamente a la *k*-anonimidad, la cual actúa sobre los microdatos antes de que se inicie el entrenamiento mediante el proceso de generalización y supresión, la privacidad diferencial proporciona ruido matemáticamente calibrado en la etapa de estimación de los parámetros del modelo, de tal manera que la presencia o ausencia de un único registro tiene un efecto acotado por el presupuesto de privacidad  $\epsilon$  (Dwork et al. 2006; Dwork 2006).

### 3.7.1. Elección de la librería y de los modelos privados

Se ha empleado la librería **IBM Diffprivlib**, ya que tiene una API que es compatible de manera directa con `scikit-learn` y porque incorpora una implementación nativa de los mecanismos de Laplace y Gauss para la inyección de ruido en algoritmos clásicos de *Machine Learning*. Asimismo, la elección está justificada porque la coherencia metodológica que proporciona se puede reutilizar el mismo *pipeline* de codificación, estandarización y evaluación que se ha trabajado en el *baseline* y en la fase ARX.

La selección de los modelos para ser privatizados ha sido realizada a partir de la lectura de los resultados generados en la fase sintáctica, que se pueden encontrar en el Capítulo 4. De entre los cuatro algoritmos de *baseline*, aquellos que mejor justifican la comparativa simétrica son **Regresión Logística** y **Naive Bayes Gaussian**, por tres motivos:

- Constituyen los **dos extremos de los puntos de vista del espectro de robustez** observado bajo  $k$ -anonimidad: la Regresión Logística conservó una variabilidad casi total ( $\Delta_{\text{Accuracy}} \in [-0,07\%, +0,45\%]$ ) mientras que Naive Bayes fue el más sensible ( $\Delta_{\text{F1}} = -25\%$  a  $k = 50$ ). La réplica del experimento a través de DP permite contrastar si esa polaridad se mantiene una vez que la perturbación es como ruido en lugar de generalización.
- Tanto la Regresión Logística como Naive Bayes cuentan con **implementación nativa** en `diffprivlib` (`diffprivlib.models.LogisticRegression` y `diffprivlib.models.GaussianNB`) con la misma firma de API que las de *scikit-learn*, lo que permite garantizar que la comparativa es simétrica en cuanto a su metodología.
- Los Random Forest y Decision Tree también existen en `diffprivlib` pero con parámetros internos diferentes a las de *scikit-learn* (el Random Forest diferencialmente privado aplica divisiones aleatorias sin *bootstrap*), de modo que su inclusión estos dos últimos introduciría ruido metodológico a la comparación cruzada con el *baseline*.

### 3.7.2. Calibración de sensibilidad y modelo de ruido

La inyección de ruido de `diffprivlib` requiere especificar el valor de la cota de sensibilidad de las funciones de coste, la cual es parametrizada de forma distinta, dependiendo del algoritmo:

- **Regresión logística diferencialmente privada:** requiere del parámetro `data_norm`, el cual representa la cota de sensibilidad. Este valor indica la norma  $L_2$  máxima esperada de los vectores de entrada. La librería utiliza este valor para acotar la sensibilidad de la función de pérdida y calibrar el ruido de Laplace inyectado en el optimizador. En los datos de entrenamiento estandarizados ( $\mu = 0$ ,  $\sigma = 1$ ), el percentil 99 de una norma se sitúa en valores bastante superiores a la mediana debido a la cola larga de registros para las variables clínicas como `num_lab_procedures`. Para evitar que los datos extremos supusieran la sobrecalibración del ruido, se ha adoptado el **percentil 95 de la norma  $L_2$  del conjunto de entrenamiento escalado** (`data_norm`  $\approx 16,04$ ), apoyando el mecanismo interno de `diffprivlib` que recorta a esta cota aquellas filas que la superen. Este criterio de *clipping* percentilar justifica la adopción de este valor, de acuerdo con la práctica recomendada para algoritmos diferencialmente privados por Abadi et al. (Abadi et al. 2016).
- **Naive Bayes Gaussian diferencialmente privado:** requiere del parámetro `bounds`, el cual limita el rango sobre cada característica para acotar sus estimaciones de media y varianza por clase. En este caso, siguiendo los mismos criterios de la función anterior se han adoptado los **percentiles 1 y 99** de cada característica del conjunto de entrenamiento escalado como cotas inferiores y superiores *en lugar* de los valores extremos absolutos, para evitar que un único registro atípico inflara artificialmente el ruido inyectado.

### 3.7.3. Barrido del presupuesto de privacidad

Para caracterizar la curva de la degradación de la utilidad en función de la fortaleza de la garantía de la privacidad se ha realizado un barrido sobre cinco valores de  $\epsilon$ , cubriendo de forma logarítmica el intervalo recomendado por la literatura del campo, es decir,  $\epsilon \in \{0,1, 0,5, 1, 5, 10\}$ ; la elección del rango sigue las recomendaciones del docx guía y se justifica como sigue:

- $\epsilon = 0,1$  representa una protección **muy fuerte** que se encuentra próxima al límite operativo de la DP en escenarios donde los datos son de alta dimensionalidad.
- $\epsilon = 0,5$  y  $\epsilon = 1$  son los **valores canónicos** más utilizados en aplicaciones de privacidad estadística.
- $\epsilon = 5$  y  $\epsilon = 10$  caracterizan el extremo **moderado**, donde la protección formal está presente, pero el ruido es sumamente escaso como para tener una utilidad que converge con el *baseline*.

### 3.7.4. Réplica y métricas de estabilidad

A diferencia de los métodos sintácticos, la Privacidad Diferencial es un procedimiento **estocástico**: cada entrenamiento da lugar a un modelo distinto, ya que se inyecta ruido aleatorio. Para realizar estimaciones estadísticamente robustas cada combinación modelo  $\epsilon$  ha sido entrenada y evaluada **cinco veces** utilizando semillas diferentes, (`random_state`  $\in \{42, 43, 44, 45, 46\}$ ) reportándose la media y la desviación típica de *Accuracy* y *F1-Score*. Adicionalmente, en el caso de la Regresión Logística diferencialmente privado se ha fijado `max_iter`= 100, valor que en pruebas preliminares garantizaba la convergencia sin castigar el rendimiento del optimizador L-BFGS en presencia de ruido.

El número de experimentos en esta fase es de 5 valores de  $\epsilon \times 5$  réplicas  $\times 2$  modelos = 50 entrenamientos, sobre los cuales se realizan dos análisis: (i) un análisis de la curva de degradación promedio con respecto al *baseline*, y (ii) un análisis de equidad por subgrupos *race* con la misma metodología que la utilizada en la fase ARX. Esta segunda dimensión es muy relevante en el caso de la DP, ya que la literatura ha señalado que el ruido puede agravar las disparidades demográficas preexistentes (Bagdasaryan, Poursaeed y Shmatikov 2019; «Privacy, Utility and Fairness: Navigating Trade-offs in Differentially Private Machine Learning» 2025).

# Capítulo 4

## Resultados

Este capítulo presenta el análisis cuantitativo del impacto de las técnicas de anonimización aplicadas a los datos clínicos. De acuerdo con la estrategia diseñada en el Capítulo 3, los resultados aquí expuestos se organizan en base a tres ejes: a la degradación global de las métricas de utilidad de los modelos, la cuantificación del riesgo residual que se determina a partir de las propiedades estructurales del conjunto anonimizado y el análisis de la equidad algorítmica segmentada por subgrupos demográficos. La interpretación de cada uno de los bloques aquí expuestos es contrapuesta en cada caso con las predicciones teóricas de los contenidos de la literatura recopilados en el Capítulo 2.

### 4.1. Resultados de $k$ -Anonimidad con ARX

Se ejecutó la herramienta ARX con las configuraciones definidas en la Sección 3.6 y se ejecutó un barrido para  $k \in \{2, 5, 10, 25, 50\}$  a partir de lo cual se realizaron cinco ejecuciones de generación de datos anónimos del conjunto de entrenamiento. En la Tabla 4.1 se muestran los efectos estructurales obtenidos en función de los diferentes niveles de privacidad seleccionados.

Tabla 4.1: Efectos estructurales de la aplicación del  $k$ -anonimato sobre el conjunto de entrenamiento (78.442 registros).

| $k$ | Filas suprimidas | % Supresión | Clases de equiv. | $k_{\text{mín}}$ | $k_{\text{máx}}$ |
|-----|------------------|-------------|------------------|------------------|------------------|
| 2   | 918              | 1,17 %      | 2.388            | 2                | 757              |
| 5   | 1.467            | 1,87 %      | 888              | 5                | 1.412            |
| 10  | 3.204            | 4,08 %      | 630              | 10               | 1.412            |
| 25  | 4.079            | 5,20 %      | 292              | 25               | 2.396            |
| 50  | 3.972            | 5,06 %      | 220              | 50               | 2.396            |

El comportamiento del optimizador de ARX muestra un patrón que se ciñe con la teoría: para valores bajos de  $k$ , la herramienta tiende a realizar la **supresión local** de los registros individuales en lugar de la generalización global, dado que la métrica *Loss* penaliza a las celdas para que un pequeño porcentaje de las filas dispares se elimine. Sin embargo, cuando el umbral de privacidad aumenta, este equilibrio cambia gradualmente hacia la generalización, como se puede ver en la Tabla 4.2.

Tabla 4.2: Niveles de generalización que finalmente aplica ARX para cada cuasi-identificador. Un valor igual a 0 indica que el atributo conserva su granularidad original; las anotaciones entre paréntesis indican cómo se ha aplicado esta abstracción para el primer nivel.

| Cuasi-identificador | $k = 2$ | $k = 5$           | $k = 10$ | $k = 25$           | $k = 50$                    |
|---------------------|---------|-------------------|----------|--------------------|-----------------------------|
| race                | 0       | 0                 | 0        | 0                  | 1 ( <i>White/NonWhite</i> ) |
| gender              | 0       | 0                 | 0        | 0                  | 0                           |
| age                 | 0       | 0                 | 0        | 1 (tramos 20 años) | 1                           |
| time_in_hospital    | 0       | 1 (bins 2–3 días) | 1        | 1                  | 1                           |
| admission_type_id   | 0       | 0                 | 0        | 0                  | 0                           |

Este escalonamiento empírico tiene su significado en el contexto clínico: establece que ARX preserva la granularidad de los atributos demográficos (**race**, **gender**, **age**) hasta el umbral más extremo, generalizando las variables de tipo operativo (**time\_in\_hospital**) solo antes de emplear el umbral mayor. **gender** y **admission\_type\_id** se conservan al margen de dicho proceso de generalización a lo largo de todo el barrido, que se puede interpretar en el sentido de que la cardinalidad baja de estos atributos era ya compatible con los requerimientos de privacidad gracias a la supresión de los outliers (como **Unknown/Invalid** para **gender** en el caso de **admission\_type\_id**, el código 4 *Newborn*).

## 4.2. Impacto sobre la Utilidad Predictiva de los Modelos

Sobre cada uno de los conjuntos anonimizados se reentrenaron los cuatro modelos de referencia descritos en el Capítulo 3 y se evaluaron contra el conjunto de prueba inalterado (19.611 registros). La Tabla 4.3 y la Tabla 4.4 recogen las métricas de *Accuracy* y *F1-Score* ponderado, respectivamente, comparando el escenario *baseline* ( $k = 0$ ) con cada nivel de anonimización.

Tabla 4.3: *Accuracy* de los modelos sobre el conjunto de prueba en función del nivel de privacidad sintáctica.

| Modelo                 | $k = 0$ | $k = 2$ | $k = 5$ | $k = 10$ | $k = 25$ | $k = 50$ |
|------------------------|---------|---------|---------|----------|----------|----------|
| Random Forest          | 0,6300  | 0,6257  | 0,6288  | 0,6264   | 0,6270   | 0,6294   |
| Regresión Logística    | 0,6178  | 0,6185  | 0,6189  | 0,6182   | 0,6200   | 0,6206   |
| Árbol de Decisión      | 0,6138  | 0,6132  | 0,6125  | 0,6168   | 0,5971   | 0,5960   |
| Naive Bayes (Gaussian) | 0,5912  | 0,5944  | 0,5568  | 0,5575   | 0,5575   | 0,5499   |

Tabla 4.4:  $F1$ -Score ponderado de los modelos sobre el conjunto de prueba en función del nivel de privacidad sintáctica.

| Modelo                 | $k = 0$ | $k = 2$ | $k = 5$ | $k = 10$ | $k = 25$ | $k = 50$ |
|------------------------|---------|---------|---------|----------|----------|----------|
| Random Forest          | 0,6277  | 0,6250  | 0,6280  | 0,6258   | 0,6268   | 0,6278   |
| Regresión Logística    | 0,6159  | 0,6166  | 0,6169  | 0,6159   | 0,6167   | 0,6157   |
| Árbol de Decisión      | 0,6138  | 0,6136  | 0,6129  | 0,6139   | 0,5975   | 0,5965   |
| Naive Bayes (Gaussian) | 0,5599  | 0,5689  | 0,4497  | 0,4536   | 0,4543   | 0,4207   |

Estos resultados son compatibles con los que se reflejan en la bibliografía revisada de los mismos datos. Liu et al. (Liu et al. 2024) obtenían valores alrededor de  $AUC \approx 0,630$  para Random Forest y  $AUC \approx 0,642$  para la Regresión Logística sobre un *pipeline* equivalente, y Hu et al. (Hu et al. 2020) inician las precisiones en un rango de 0,57–0,62 manteniendo las tres clases originales. El límite del estado del arte para modelos clásicos y sin buscar los hiperparámetros se sitúa en  $AUC \approx 0,67$  mediante *gradient boosting* (XGBoost). La distancia del *baseline* de este trabajo a estos resultados publicados respalda la idoneidad del *pipeline* previo a la inyección de técnicas de privacidad y permite atribuir cualquier tipo de degradación observada en las fases posteriores a la inyección de privacidad, no a errores estructurales en el modelo base.

La Figura 4.1 presenta la curva de degradación obtenida de forma gráfica, lo que permite percibir de forma instantánea el comportamiento diferencial que toma el conjunto de sobre la familia algorítmica que usamos al aumentar la garantía de privacidad.




Figura 4.1: Degradación de *Accuracy* (izquierda) y  $F1$ -Score ponderado (derecha) de los cuatro modelos a lo largo del barrido  $k \in \{0, 2, 5, 10, 25, 50\}$ . El eje de abscisas se representa en escala simétrica logarítmica para resaltar la zona de transición.

### 4.2.1. Robustez de los modelos lineales y de *ensemble*

Random Forest y Regresión Logística soportan la anonimización sintáctica de forma destacablemente robusta: incluso en el escenario más restrictivo ( $k = 50$ ), la pérdida absoluta de *Accuracy* corre por debajo del 0,7% (Random Forest) y llega a ser perfectamente insignificante para Regresión Logística, que mejora, incluso, en +0,28 puntos con respecto al *baseline*. Este comportamiento contradice el sentido común establecido de que toda generalización reduce la utilidad, y la explicación se repartiría entre dos mecanismos. El primero, la propia generalización funciona como una regularización implícita que viene a reducir la varianza del modelo porque elimina variación espuria de los cuasi-identificadores. El segundo, los modelos lineales y los *ensembles* de árboles copan la mayor parte de la señal predictiva en las variables clínicas (medicaciones, número de procedimientos, diagnósticos) que al final no forman parte de esta, así que el deterioro de los QID demográficos apenas llegan a afectar a la frontera de decisión que se ha aprendido.

### 4.2.2. Sensibilidad diferencial entre familias algorítmicas

Naive Bayes Gaussian se distingue con claridad respecto al resto: a  $k = 5$  ya pierden un 5,8% de *Accuracy* y un 19,7% de *F1-Score* ponderado, y a partir de  $k = 50$  la pérdida en *F1* es del -25%. El hundimiento tiene una razón estructural: el algoritmo asume independencia condicional entre características. La generalización categóricamente de ARX junta en una única celda valores que previamente eran independientes — los catorce días individuales de `time_in_hospital` juntos en cinco *bins* ordinales por ejemplo —, interrumpiendo esa asunción y desplazando las distribuciones gaussianas estimadas en el entrenamiento. A ello se agrega un segundo factor: el modelo no admite el parámetro `class_weight=balanced`, y eso acentúa su sensibilidad al desbalanceo (Strack, J. P. DeShazo et al. 2014).

El Árbol de Decisión muestra un patrón intermedio muy atractivo. Su valor se mantiene estable hasta  $k = 10$  — incluso aumenta +0,3% en *Accuracy* a  $k = 10$ , en parte por el efecto regularizador que produce el efecto de supresión de *outliers* — y disminuye repentinamente entre -2,7% y -2,9% a partir de  $k = 25$ . Ese punto de inflexión corresponde al instante a partir del cual ARX pasa a generalizar la variable `age`, que se aglutina en deciles, a tramos de 20 años, apretando drásticamente la cardinalidad para los *splits* del árbol. Sus resultados concuerdan con el análisis de Sweeney (Sweeney 2002) en cuanto a cómo la cardinalidad afecta a los algoritmos basados en *partitions* recursivas.



### 4.2.3. Implicaciones sobre la selección de modelos en contextos de privacidad

Los hallazgos previos sugieren una consideración para la fase de *benchmarking* entre la privacidad y la utilidad en un proyecto de ciencia de datos: la función de costo utilizada al elegir un *learner* es tan crucial como el ajuste del parámetro de privacidad. En este sentido, los modelos lineales y los *ensembles* experimentan una reducción mínima en su capacidad de utilidad al aplicar técnicas de anonimización sintáctica, lo que los convierte en candidatos ideales para implementaciones donde la regulación exige la publicación de microdatos, como ocurre en repositorios de datos sanitarios. En contraste, modelos como Naive Bayes y otros enfoques generativos paramétricos son considerablemente más efectivos en situaciones donde el conjunto de entrenamiento conserva su nivel original de especificidad.

## 4.3. Análisis de Equidad Algorítmica

Estudios recientes sobre privacidad y aprendizaje automático han señalado que las garantías formales de privacidad pueden afectar de manera desproporcionada a grupos demográficos minoritarios (Bagdasaryan, Poursaeed y Shmatikov 2019; «Privacy, Utility and Fairness: Navigating Trade-offs in Differentially Private Machine Learning» 2025). Para investigar esta hipótesis en el contexto de la anonimización sintáctica, se desglosaron las métricas de utilidad del modelo de Regresión Logística (considerado el modelo más fiable durante el análisis) según subgrupos de la variable **race** en el conjunto de pruebas. Los resultados se muestran en la Tabla 4.5.

Tabla 4.5: *Accuracy* de la Regresión Logística sobre el conjunto de prueba desagregada por subgrupo **race**.

| Subgrupo               | $n_{\text{test}}$ | $k = 0$ | $k = 2$ | $k = 5$ | $k = 10$ | $k = 25$ | $k = 50$ |
|------------------------|-------------------|---------|---------|---------|----------|----------|----------|
| Caucasian              | 14.970            | 0,6157  | 0,6156  | 0,6159  | 0,6150   | 0,6176   | 0,6184   |
| AfricanAmerican        | 3.821             | 0,6210  | 0,6218  | 0,6229  | 0,6231   | 0,6208   | 0,6210   |
| Hispanic               | 410               | 0,6585  | 0,6732  | 0,6707  | 0,6707   | 0,6683   | 0,6634   |
| Other                  | 295               | 0,6305  | 0,6475  | 0,6508  | 0,6441   | 0,6542   | 0,6610   |
| Asian                  | 115               | 0,6087  | 0,6174  | 0,6087  | 0,6174   | 0,6435   | 0,6348   |
| <b>Loss Disparity*</b> | —                 | 0,0498  | 0,0576  | 0,0620  | 0,0557   | 0,0507   | 0,0450   |

\* Diferencia entre el subgrupo con mayor y menor *Accuracy* en cada nivel de  $k$ . Valores menores indican mayor equidad.

La Figura 4.2 muestra la evolución de la *Accuracy* por subgrupo a lo largo del barrido, junto con la línea media del *baseline* como referencia.




Figura 4.2: Disparidad de utilidad de la Regresión Logística por subgrupo *race* a lo largo del barrido  $k \in \{0, 2, 5, 10, 25, 50\}$ . Las leyendas indican el tamaño  $n$  de cada subgrupo en el conjunto de prueba. La línea discontinua marca la *Accuracy* media del *baseline*.

#### 4.3.1. La $k$ -anonimidad no exacerba la disparidad demográfica

La conclusión más notable de este análisis es que la métrica *Loss Disparity* **no crece de forma monótona con el nivel de privacidad**, en oposición a lo que sería de esperar a partir de la extrapolación lineal de los resultados de Bagdasaryan et al. (Bagdasaryan, Poursaeed y Shmatikov 2019) sobre Privacidad Diferencial. La disparidad empieza en 0,0498 en el *baseline*, alcanza un máximo de 0,0620 en  $k = 5$  y va decreciendo hasta alcanzar un mínimo de 0,0450 en  $k = 50$ , por debajo del punto inicial.

Este comportamiento viene asociado a un mecanismo cualitativamente diferente al del ruido diferencial: mientras que la inyección de ruido de Laplace o Gauss penaliza desproporcionadamente a las muestras minoritarias por amplificar el error en regiones de baja densidad estadística, la generalización sintáctica **homogeneiza** la representación de los grupos al colapsar valores demográficos en categorías más amplias. El efecto neto es que los tres subgrupos minoritarios experimentan una mejora en la *Accuracy* respecto a su *baseline* en todo el barrido con patrones cuantitativamente heterogéneos:

- **Hispanic** alcanza su máximo a  $k = 2$  (+2,2%) y la mejora decrece de forma gradual hasta alcanzar +0,7% a  $k = 50$ .

- **Other** y **Asian** presentan incrementos relativamente más altas a niveles altos de privacidad sintáctica: +4,8% y +4,3% respectivamente a  $k = 50$ . El subgrupo *Asian* alcanza incluso +5,7% en  $k = 25$ , el incremento puntual más elevado del análisis.

Mientras que el grupo mayoritario (Caucasian) muestra incrementos marginales que no superan el +0,4% en el conjunto del barrido. La conclusión cualitativa queda intacta—la  $k$ -anonimidad favorece a los subgrupos minoritarios a expensas de los grupos mayoritarios desde una perspectiva relativa—pero el patrón concreto es heterogéneo y no monótono para cada uno de los subgrupos, esto refuerza, aún más, la importancia de auditar la equidad de forma desagregada por el nivel de  $k$  frente al de establecer un umbral único y asumir que el comportamiento es homogéneo entre grupos.

#### 4.3.2. Interpretación: regularización implícita en grupos minoritarios

El fenómeno tiene una clara justificación estadística. Los subgrupos minoritarios, al estar muy poco sujetos a un conjunto de entrenamiento, son especialmente susceptibles a que modelos como la Regresión Logística puedan llegar a sobreajustarse cuando se entrenan sobre datos en claro: el modelo memoriza patrones idiosincrásicos no generalizables a un subconjunto de pruebas. La generalización que plantea ARX *al colapsar valores raros en categorías comunes* actúa de hecho como una forma de regularización dirigida que reacciona exclusivamente sobre la capacidad de generalización de los modelos de estos grupos. Esto coincide con trabajos recientes sobre el efecto de regularización de las técnicas de privacidad sintáctica ([«Secure Data Sharing in Machine Learning: Exploring K-Anonymization and Differential Privacy» 2024](#)) y proporciona evidencias empíricas que avalan considerar la  $k$ -anonimidad como técnica complementaria a la Privacidad Diferencial en escenarios sensibles a la equidad.

### 4.4. Síntesis de la Fase Sintáctica

De esta fase quedan tres conclusiones operativas que servirán después de partida de referencia en el estudio que queda (Privacidad Diferencial, datos sintéticos y auditoría adversarial):

1. **La  $k$ -anonimidad es prácticamente gratuita en utilidad para este caso de uso.** Con  $k = 10$  — el valor que es habitualmente recomendado en publicaciones sanitarias — la pérdida de *Accuracy* es inferior al 0,6 % en Random Forest y Regresión Logística. Esto significa que un modelo de readmisión hospitalaria entrenado a partir de microdatos publicables no dejaría de ser privado a la espera de seguir cumpliendo en una marco con capacidad predictiva apreciable.

2. El *baseline* se mantiene grosso modo intacto hasta  $k = 10$  y se erosiona de una manera gradual a partir de  $k = 25$ . Por este motivo,  $k = 10$  es la referencia más acorde con la comparativa cruzada con los algoritmos de Privacidad Diferencial de la siguiente sección: protección fuerte sin distorsionar la distribución aprendida de forma que sea apreciable.
3. El análisis de la equidad da razones para no dar  $k$ -anonimidad por una técnica que esta obsoleta. Si bien es cierto que la literatura revisada suele considerarla como una técnica detrás de muchas otras en el camino hacia las garantías matemáticas mucho más fuertes, su impacto positivo sobre la disparidad demográfica la convierten en una técnica útil cuando la equidad respecto a los grupos minoritarios es un requerimiento explícito del proyecto en el que se está trabajando, muy especialmente si se acompaña con auditorías de inferencia de miembros como las que se revisan en la última fase del trabajo.

Estas tres conclusiones sirven como referencia para evaluar en el futuro la combinación entre el enfoque de Privacidad Diferencial y las técnicas de generación de datos sintéticos. La cuestión que queda abierta y que es lo que lleva a las secciones siguientes la pregunta de si en la inyección de ruido controlado puede llegar a igualar la robustez observada en  $k$ -anonimidad sin reproducir los efectos desafortunados en cuanto a influencia sur la equidad que describe Bagdasaryan (Bagdasaryan, Poursaeed y Shmatikov 2019).

## 4.5. Resultados de la Aplicación de Privacidad Diferencial

Después de haber configurado la fase diferencialmente privada siguiendo el protocolo indicado en la Sección 3.7, se realizaron 50 experimentos que corresponden al producto cartesiano de cinco valores de  $\epsilon$ , cinco repeticiones por punto y dos modelos (*Logistic Regression* y *Gaussian Naive Bayes*). En esta sección se presentan resultados de tipo agregado, y se los contrasta con el *baseline* y la fase ARX, así como se analizan sus implicaciones a la hora de abordar la equidad algorítmica.

### 4.5.1. Curva de degradación de la utilidad

Tabla 4.6: *Accuracy* (mean  $\pm$  std,  $n = 5$ ) de los modelos diferencialmente privados sobre el conjunto de prueba.

| Modelo                 | $\epsilon = 0,1$   | $\epsilon = 0,5$   | $\epsilon = 1$     | $\epsilon = 5$     | $\epsilon = 10$    |
|------------------------|--------------------|--------------------|--------------------|--------------------|--------------------|
| Regresión Logística    | $0,5282 \pm 0,007$ | $0,5671 \pm 0,005$ | $0,5928 \pm 0,004$ | $0,5987 \pm 0,022$ | $0,6180 \pm 0,001$ |
| Naive Bayes (Gaussian) | $0,5135 \pm 0,023$ | $0,5167 \pm 0,019$ | $0,5339 \pm 0,022$ | $0,5616 \pm 0,028$ | $0,5780 \pm 0,012$ |

Tabla 4.7: *F1-Score* ponderado (mean  $\pm$  std,  $n = 5$ ) de los modelos diferencialmente privados.

| Modelo                 | $\epsilon = 0,1$   | $\epsilon = 0,5$   | $\epsilon = 1$     | $\epsilon = 5$     | $\epsilon = 10$    |
|------------------------|--------------------|--------------------|--------------------|--------------------|--------------------|
| Regresión Logística    | $0,5274 \pm 0,006$ | $0,5664 \pm 0,005$ | $0,5899 \pm 0,004$ | $0,5938 \pm 0,019$ | $0,6075 \pm 0,001$ |
| Naive Bayes (Gaussian) | $0,4622 \pm 0,046$ | $0,5076 \pm 0,021$ | $0,5298 \pm 0,023$ | $0,5482 \pm 0,038$ | $0,5761 \pm 0,013$ |

La Figura 4.3 representa gráficamente la curva de degradación con bandas de error correspondientes a la desviación típica.




Figura 4.3: Degradación de *Accuracy* (izquierda) y *F1-Score* ponderado (derecha) en función del presupuesto de privacidad  $\epsilon$ . Las barras de error corresponden a la desviación típica sobre cinco repeticiones por punto. Las líneas discontinuas indican los *baselines* sin privacidad.

La curva responde de acuerdo a lo pronosticado por la teoría: la utilidad se acerca al (baseline) conforme  $\epsilon$  aumenta y se degrada de forma importante según vayamos restringiendo el presupuesto. En términos concretos, la Regresión Logística pierde un 14,50 % de (*Accuracy*) a  $\epsilon = 0,1$ , es decir, se ha degenerado al punto de aproximarse por completo a la del baseline ( $\Delta = +0,03\%$ ) a  $\epsilon = 10$ . Naive Bayes presenta un comportamiento parejo pero con dos diferencias relevantes. En primer lugar, su curva no es capaz de aproximarse a la del (baseline) ni siquiera a  $\epsilon = 10$ , manteniendo una pérdida residual de  $-2,23\%$ . En segundo lugar, la varianza entre repeticiones es considerablemente más alta (con una varianza de hasta  $\sigma = 0,028$  en (*Accuracy*) y  $\sigma = 0,046$  en (*F1*)) lo que evidencia que su dependencia del ruido aleatorio es mayor que en el modelo lineal.

#### 4.5.2. Comparativa cruzada: Privacidad Diferencial frente a $k$ -Anonimidad

La Figura 4.4 ajusta de manera conjunta las curvas de degradación de la Regresión Logística para cada una de las técnicas de privacidad, sobre los mismos datos clínicos. El eje de la parte superior corresponde con el barrido de  $k$  (incremento de privacidad sintáctica) y el eje inferior con el barrido de  $\epsilon$  (decremento de privacidad diferencial), por lo que las curvas se leen de izquierda (mayor privacidad) a derecha (menor privacidad).




Figura 4.4: Comparativa cruzada de las dos técnicas de privacidad sobre la Regresión Logística. La curva azul representa Privacidad Diferencial; la curva verde representa  $k$ -anonimidad. La línea discontinua representa el *baseline* -sin privacidad- (0,6178).

El contraste de las dos curvas resume la conclusión empírica central de este TFM: **la pérdida de utilidad atribuible a la  $k$ -anonimidad es prácticamente despreciable en este caso de uso, mientras que la Privacidad Diferencial constituye un coste importante en utilidad si estamos dispuestos a adquirir una protección formal estricta**. La curva verde de la  $k$ -anonimidad está muy próxima a la del *baseline* en todo el rango ( $\Delta \leq 0,5\%$ ), mientras que la curva azul de DP alcanza el *baseline* sólo con valores de  $\epsilon \geq 10$ , en donde se pierden 14,50 %, 8,21 % y 4,05 % a valores de  $\epsilon = 0,1$ ,  $\epsilon = 0,5$  y  $\epsilon = 1$  respectivamente.

La elección entre ambas técnicas no debería basarse sólo en la fortaleza formal de la garantía, donde la DP es claramente superior a raíz de su propia matemática, sino que también debería tener en cuenta el coste de utilidad real que viene dado este caso concreto. La  $k$ -anonimidad constituye una protección efectiva ante ataques de enlace al coste de una pérdida de utilidad casi nula; la DP es más sensata en los escenarios en los que se necesita una garantía ante una inferencia estadística agnósticamente al modelo de atacante.

### 4.5.3. Impacto sobre la equidad: el patrón Bagdasaryan se confirma

A diferencia a lo que sucedía con el nivel de privacidad en la fase de k-anonimidad, donde la disparidad demográfica se volvía menor al aumentar el nivel de privacidad, la Privacidad Diferencial reproduce el efecto perjudicial que han presentado Bagdasaryan et al. (Bagdasaryan, Poursaeed y Shmatikov 2019): a presupuestos más restrictivos, los grupos minoritarios son desproporcionadamente responsables de las decisiones. La Tabla 4.8 presenta para cada subgrupo **race** la *Accuracy* de la Regresión Logística diferencialmente privada.

Tabla 4.8: *Accuracy* (media de cinco repeticiones) de la Regresión Logística diferencialmente privada desagregada por subgrupo **race**. La última columna recoge la pérdida porcentual respecto al *baseline* a  $\epsilon = 0,1$ .

| Subgrupo        | $n_{\text{test}}$ | $\epsilon = 0,1$ | $\epsilon = 0,5$ | $\epsilon = 1$ | $\epsilon = 5$ | $\epsilon = 10$ | $\Delta_{\epsilon=0,1}$ |
|-----------------|-------------------|------------------|------------------|----------------|----------------|-----------------|-------------------------|
| Caucasian       | 14.970            | 0,5279           | 0,5648           | 0,5899         | 0,5956         | 0,6157          | −14,26 %                |
| AfricanAmerican | 3.821             | 0,5292           | 0,5707           | 0,5956         | 0,6037         | 0,6206          | −14,78 %                |
| Hispanic        | 410               | 0,5288           | 0,6044           | 0,6361         | 0,6395         | 0,6595          | −19,70 %                |
| Other           | 295               | 0,5397           | 0,5939           | 0,6380         | 0,6319         | 0,6454          | −14,40 %                |
| Asian           | 115               | 0,5043           | 0,5443           | 0,6000         | 0,6000         | 0,6157          | −17,15 %                |

La Figura 4.5 ilustra estas mismas curvas con bandas de error.




Figura 4.5: Disparidad de utilidad de la Regresión Logística diferencialmente privada por subgrupo **race** a lo largo del barrido  $\epsilon \in \{0,1, 0,5, 1, 5, 10\}$ . Las barras de error corresponden a la desviación típica sobre cinco repeticiones.

A  $\epsilon = 0,1$ , los subgrupos minoritarios *Hispanic* (−19,70 %) y *Asian* (−17,15 %) sufren una pérdida significativamente superior a la del grupo mayoritario *Caucasian* (−14,26 %). El subgrupo *Asian*, con sólo 115 individuos en el conjunto de prueba, es además el que presenta la mayor varianza entre repeticiones, lo que confirma que el ruido diferencial penaliza con mayor intensidad las regiones del espacio de características con menor densidad estadística.

El resultado es completamente acorde con la explicación teórica formulada por Bagdasar-yan: el mecanismo de Laplace añade ruido cuya magnitud es independiente del tamaño del subgrupo, así en términos relativos su efecto es mayor respecto a muestras muy pequeñas. La diferencia con la generalización puesta en marcha por la  $k$ -anonimidad —homogeneizando estructuralmente las representaciones— es cualitativa, no sólo cuantitativa.

#### 4.5.4. Síntesis de la Fase Diferencial

De esta fase salen tres aprendizajes para el cierre del trabajo:

1. **La utilidad bajo Privacidad Diferencial depende mucho del presupuesto  $\epsilon$ .** Para obtener utilidad equivalente al *baseline* en este uso el presupuesto  $\epsilon$  se debe colocar suficientemente alto, cerca del valor  $\epsilon = 10$ , un nivel de protección formal que en la literatura se considera como moderado.
2. **Un compromiso inevitable entre garantía formal y utilidad práctica.** La  $k$ -anonimidad, por su parte, protege de ataques de enlace y deja caer la utilidad de las salidas con una pérdida por debajo del mínimo; en contraposición, la DP, incluso si tiene una garantía formal que permite generar salidas de utilidad aceptable, tiene un coste explícito que sólo vale la pena asumir si realmente el caso de uso lo requiere.
3. **La  $k$ -anonimidad y la Privacidad Diferencial poseen efectos opuestos sobre la equidad demográfica.** Unirlas en un esquema de defensa en profundidad podría compensar el efecto adverso de la DP. La siguiente sección pone esa hipótesis a prueba.

Con esto queda cerrada la evaluación cuantitativa del dilema privacidad-utilidad y armada la base empírica para el marco de recomendaciones del siguiente capítulo.



## 4.6. Defensa en Profundidad: Combinación de $k$ -Anonimidad y Privacidad Diferencial

La síntesis de la fase diferencial (Sección 4.5.3) sugería que si la combinación de ambas técnicas se montara en un esquema de defensa en profundidad contrarrestaría el efecto contraproducente de la DP sobre los grupos minoritarios. Para poder valorar empíricamente la validez de la citada hipótesis, se ha replicado el sweep de DP:  $\epsilon \in \{0,1,1,10\}$  (cinco repeticiones) sobre el criterio de amparo del conjunto de entrenamiento que ya había sido anonimizado con  $k = 10$  (75.238 registros tras la supresión).

### 4.6.1. Comportamiento de la utilidad combinada

La Tabla 4.9 compara la *Accuracy* promedio de los dos modelos diferencialmente privados sobre datos en claro frente a la combinación con  $k = 10$ .

Tabla 4.9: *Accuracy* (mean  $\pm$  std,  $n = 5$ ) de DP solo vs combinación  $k = 10 + DP$ .

| Modelo                 | Configuración | $\epsilon = 0,1$   | $\epsilon = 1$     | $\epsilon = 10$    |
|------------------------|---------------|--------------------|--------------------|--------------------|
| Regresión Logística    | DP solo       | $0,5282 \pm 0,007$ | $0,5928 \pm 0,004$ | $0,6180 \pm 0,001$ |
|                        | $k = 10 + DP$ | $0,5158 \pm 0,009$ | $0,4851 \pm 0,022$ | $0,4840 \pm 0,020$ |
| Naive Bayes (Gaussian) | DP solo       | $0,5135 \pm 0,023$ | $0,5339 \pm 0,022$ | $0,5780 \pm 0,012$ |
|                        | $k = 10 + DP$ | $0,5237 \pm 0,017$ | $0,5213 \pm 0,033$ | $0,5858 \pm 0,005$ |




Figura 4.6: Comparativa de utilidad de la Regresión Logística: DP solo (azul) frente a combinación  $k = 10 + DP$  (verde). Las líneas discontinuas indican el *baseline* y el modelo  $k = 10$  sin DP como referencias.

Los hallazgos nos brindan dos observaciones totalmente diferentes:

- En el **Naive Bayes**, la combinación se comporta como era de esperar; mejora unos pocos puntos con respecto a la DP solamente con  $\epsilon = 0,1$  (+1,0 pp) y a  $\epsilon = 10$  (+0,8 pp) y al igual que con el regularizador, la generalización actúa como un regularizador adicional, así que en este caso se confirma parcialmente la hipótesis original.
- Por el contrario, en la **Regresión Logística**, la combinación atraviesa un **colapso absoluto de la utilidad** para  $\epsilon \geq 1$ : la *Accuracy* se va hasta 0,48 incluso para niveles de inocuidad de los datos ( $\epsilon = 10$ ). El hallazgo resulta contrario a la intuición: con un nivel de ruido tan bajo, parecería lógico que el modelo regresase al desempeño de  $k = 10$  sin DP (0,6182), pero si hacemos tests de control para desestimar la existencia de una causa estadística apuntan hacia una causa metodológica; esto es, la implementación de DP para `diffprivlib.LogisticRegression`, aplica una regularización fija reglada para acotar la sensibilidad y la regularización interfiere muy mal con el espacio de características ampliado tras la generalización (149 columnas *One-Hot Encoding* versus las 121 originales). Como las nuevas columnas de los valores generalizados (p.ej. `time_in_hospital_[1-2]`) no aparecen en el test, se convierten en dimensiones “muertas”, que la regularización de la DP penaliza en exceso.

#### 4.6.2. Implicación: la defensa en profundidad no es trivial

El resultado tiene una lectura clara: aplicar  $k$ -anonimidad y Privacidad Diferencial en cascada no asegura mejorar el compromiso privacidad-utilidad; de hecho, en ciertas ocasiones se puede dar el caso que compromete severamente la utilidad práctica. Esta decepcionante lectura no puede considerarse un resultado sorprendente ya que ésto no es más que la práctica de la combinación en cascada de dos técnicas que operan independientemente en particular respecto del espacio de transformaciones que deben aplicarse previa la aplicación de la técnica. Por lo tanto, para poder combinar adecuadamente ambas técnicas en cascada deberíamos considerar algunas de las siguientes opciones:

- Ajustar el DP sobre el espacio de características correspondiente al espacio de características posterior a la anonimización.
- Considerar una implementación de DP empleando DP-SGD (`Opacus`), donde no se tiene en consideración la típica regularización introducida por el DP.
- Desplegar una combinación más sofisticada de ambas como las descritas en la literatura más reciente sobre *integrated DP and k-anonymity* (*Provably Private Data Anonymization: Or, k-Anonymity Meets Differential Privacy* 2010).




Figura 4.7: Disparidad de utilidad por subgrupo **race**: DP solo (izquierda) vs combinación  $k = 10 + DP$  (derecha). En la combinación se observa que la varianza por subgrupo se incrementa a  $\epsilon = 0,1$ , especialmente en el grupo *Asian* de menor tamaño.

En términos de equidad, la Figura 4.7 muestra que la combinación tampoco neutraliza la disparidad que introduce el DP. Al contrario: la *Loss Disparity* a  $\epsilon = 0,1$  pasa de 0,0354 (DP solo) a 0,1225 (combinación), lo que confirma que combinar las dos técnicas requiere un diseño cuidadoso. Esta línea se recoge como trabajo futuro en el Capítulo 5.

## 4.7. Auditoría adversarial: inferencia de pertenencia con el ART

Para verificar empíricamente que las garantías formales de privacidad realmente se traducen en protección frente a un atacante, se lleva a cabo una auditoría adversarial con el mencionado ataque de inferencia de pertenencia (*Membership Inference Attacks (MIA)*) que hace uso de la **Adversarial Robustness Toolbox (ART)**. La cuestión que debe responder cualquier técnica de privacidad es directa: ¿es posible que un atacante que tenga acceso a las predicciones del modelo obtenga la conclusión de que un individuo concreto formó parte del conjunto de entrenamiento?

### 4.7.1. Configuración del experimento

El ataque usado es `MembershipInferenceBlackBox` con un clasificador de pertenencia del tipo *Random Forest*, siguiendo lo estipulado por la metodología de Shokri et al. (Shokri et al. 2017). En todos los escenarios, el atacante dispone de un conjunto balanceado de 10.000 muestras del conjunto de entrenamiento *members* y 5.000 muestras del conjunto de prueba *non-members*; usa el 50% del conjunto de muestras para entrenarse y el otro 50% para evaluarse. Se reportan dos métricas: la *Attack Accuracy* (proporción de inferencias que son correctas, donde 0,5 es al azar) y la *Attack Advantage* (diferencia entre los valores representan la tasa de *true positives* y la de *false positives*, donde 0 indica que no se produce fuga).

### 4.7.2. Resultados de la auditoría

Tabla 4.10: Auditoría adversarial mediante MIA Black-Box sobre Regresión Logística en distintos escenarios de privacidad.

| Escenario                    | Utility Acc | Attack Acc | Attack Advantage | Diagnóstico          |
|------------------------------|-------------|------------|------------------|----------------------|
| Baseline LR (sin privacidad) | 0,6178      | 0,5541     | -0,0068          | Sin fuga detectable  |
| LR · $k = 10$                | 0,6182      | 0,5609     | +0,0084          | Fuga marginal        |
| LR · $k = 50$                | 0,6206      | 0,5701     | +0,0332          | Fuga marginal        |
| LR · DP $\epsilon = 0,1$     | 0,5267      | 0,6616     | +0,0024          | Sin fuga detectable* |
| LR · DP $\epsilon = 10$      | 0,6173      | 0,5607     | +0,0096          | Fuga marginal        |

\* La elevada *Attack Accuracy* se explica por el desbalance del conjunto auditor (el atacante predice “member” para la mayoría de las muestras), pero la *Advantage* próxima a cero indica que no extrae información estructural del modelo.

De la auditoría se obtiene una conclusión sencilla: **ninguno de los escenarios estudiados muestra ningún tipo de fuga de información de membresía clínicamente significativo** (*Advantage* máxima +0,033, muy por debajo del umbral +0,1 que se solía considerar efectivo en la literatura). Este punto tiene dos consecuencias en la interpretación de la conclusión global del trabajo:




Figura 4.8: Resultados de la auditoría adversarial mediante MIA Black-Box. La línea discontinua en 0,5 marca el rendimiento aleatorio de un atacante; valores próximos a esta indican ausencia de fuga estructural.

1. El *baseline* sin privacidad ya aguanta razonablemente bien los ataques de membresía sobre este conjunto de datos. Esto es indicativo de que la Regresión Logística no sobreajusta en exceso al *training set*, cosa que es consistente con el rendimiento moderado del *baseline* (0,6178), que ya habíamos mencionado en el Capítulo 3.
2. Las técnicas de privacidad que se han puesto a examen (tanto *k*-anonimidad como DP) no mejoran significativamente la resistencia del modelo a este ataque concreto porque ya es de por sí baja. Este hecho no implica que esta forma de protección no sea útil: la *k*-anonimidad protege efectivamente contra ataques de *link* (no de membresía), y la Privacidad Diferencial da formalmente una garantía que no varía en función de los modelos de atacante. Lo que sí que pone de manifiesto es que es mejor medir empíricamente el riesgo residual antes de poner protecciones potencialmente grandes en utilidad.

La conclusión viene a ser la misma que la que sale en trabajos recientes que advierten sobre el *security theatre* en privacidad de datos ([«Membership Inference Attacks Against Synthetic Health Data» 2022](#)): las garantías formales son necesarias, pero no siempre necesarias — depende de cuál sea el modelo de amenaza realista de cada caso de uso.

## 4.8. Tests de Significancia Estadística

A fin de incrementar el rigor cuantitativo de las conclusiones del capítulo, se han aplicado dos baterías de tests estadísticos no paramétricos: (i) tests de **McNemar** para poner a prueba las predicciones del *baseline* con las de cada uno de los modelos *k*-anonimizados, y (ii) tests de **Wilcoxon de una muestra** con la finalidad de comparar la *Accuracy* promedio de los modelos diferencialmente privados con la del *baseline* de referencia.

### 4.8.1. Test de McNemar para los modelos *k*-anonimizados

El test de McNemar es la herramienta estándar para comprobar si dos clasificadores son significativamente distintos en cuanto a sus predicciones sobre el mismo conjunto de test. La Tabla 4.11 recoge los resultados.

Tabla 4.11: Test de McNemar entre el *baseline* y cada modelo *k*-anonimizado. *b* representa los casos en que el *baseline* acierta y el modelo anonimizado falla; *c* los inversos. Significativo:  $p < 0,05$ .

| Modelo              | <i>k</i> | <i>b</i> | <i>c</i> | <i>p</i> -valor | Significativo |
|---------------------|----------|----------|----------|-----------------|---------------|
| Regresión Logística | 2        | 604      | 617      | 0,731           | No            |
|                     | 5        | 574      | 595      | 0,559           | No            |
|                     | 10       | 586      | 593      | 0,861           | No            |
|                     | 25       | 715      | 757      | 0,285           | No            |
|                     | 50       | 760      | 815      | 0,174           | No            |
| Random Forest       | 2        | 586      | 502      | 0,012           | <b>Sí</b>     |
|                     | 5        | 512      | 490      | 0,507           | No            |
|                     | 10       | 599      | 530      | 0,043           | <b>Sí</b>     |
|                     | 25       | 793      | 735      | 0,145           | No            |
|                     | 50       | 515      | 504      | 0,754           | No            |
| Árbol de Decisión   | 2        | 792      | 780      | 0,781           | No            |
|                     | 5        | 907      | 881      | 0,554           | No            |
|                     | 10       | 1.656    | 1.716    | 0,310           | No            |
|                     | 25       | 2.772    | 2.444    | $\sim 10^{-6}$  | <b>Sí</b>     |
|                     | 50       | 2.740    | 2.391    | $\sim 10^{-6}$  | <b>Sí</b>     |
| Naive Bayes         | 2        | 220      | 282      | 0,006           | <b>Sí</b>     |
|                     | 5        | 1.997    | 1.323    | $\sim 10^{-31}$ | <b>Sí</b>     |
|                     | 10       | 1.942    | 1.282    | $\sim 10^{-31}$ | <b>Sí</b>     |
|                     | 25       | 1.937    | 1.277    | $\sim 10^{-31}$ | <b>Sí</b>     |
|                     | 50       | 2.361    | 1.552    | $\sim 10^{-38}$ | <b>Sí</b>     |

Los tests proporcionan peso estadístico a la lectura cualitativa de las secciones que lo preceden. La **Regresión Logística no presenta diferencias significativas en comparación con el *baseline* en ningún nivel de *k***, por la cual se valida su invariancia ante la generalización sintáctica.

En el extremo opuesto, **Naive Bayes muestra diferencias significativas a partir de  $k = 2$** : esto nos permite validar su sensibilidad ante el colapso de cardinalidad en las variables categóricas. El Árbol de Decisión hace el recorrido entre los dos comportamientos: es invariante hasta  $k = 10$  y presenta diferencias significativas a partir de  $k = 25$ , exactamente en el punto de inflexión empírico que se definió en la subsección 4.5.1.

#### 4.8.2. Test de Wilcoxon para los modelos diferencialmente privados

Para los modelos diferencialmente privados se aplica un test de Wilcoxon de una muestra: con  $n = 5$  repeticiones por celda, la hipótesis nula es que la *Accuracy* promedio coincide con el *baseline* sin privacidad de la que se ha realizado, y es de advertir incluso como limitación del propio diseño: con  $n = 5$ , el menor  $p$ -valor alcanzable por este test es  $1/2^4 = 0,0625$  - justo por encima del umbral  $\alpha = 0,05$ . Por tanto en este caso el test no podrá declarar significancia estricta aunque la diferencia observada sea grande.

Tabla 4.12: Test de Wilcoxon de una muestra entre la *Accuracy* del modelo DP y el *baseline*.  $n = 5$  repeticiones por celda.

| Modelo                 | $\epsilon$ | Mean Acc | Baseline | $p$ -valor | Magnitud $\Delta$ |
|------------------------|------------|----------|----------|------------|-------------------|
| Regresión Logística    | 0,1        | 0,5282   | 0,6178   | 0,0625     | -14,50 %          |
|                        | 0,5        | 0,5671   | 0,6178   | 0,0625     | -8,21 %           |
|                        | 1,0        | 0,5928   | 0,6178   | 0,0625     | -4,05 %           |
|                        | 5,0        | 0,5987   | 0,6178   | 0,0625     | -3,09 %           |
|                        | 10         | 0,6180   | 0,6178   | 0,625      | +0,03 %           |
| Naive Bayes (Gaussian) | 0,1        | 0,5135   | 0,5912   | 0,0625     | -13,14 %          |
|                        | 0,5        | 0,5167   | 0,5912   | 0,0625     | -12,60 %          |
|                        | 1,0        | 0,5339   | 0,5912   | 0,0625     | -9,69 %           |
|                        | 5,0        | 0,5616   | 0,5912   | 0,0625     | -5,01 %           |
|                        | 10         | 0,5780   | 0,5912   | 0,125      | -2,23 %           |

A pesar de esta limitación, el patrón de los  $p$ -valores resulta ser informativo. Es el mínimo que se alcanza (0,0625) para todos los presupuestos restrictivos ( $\epsilon \leq 5$ ), lo que significa que las cinco repeticiones son consistentes y se ordenan abajo del *baseline*. Solo para  $\epsilon = 10$  el  $p$ -valor se permite relajarse (a 0,625 a LR y 0,125 a NB), en la línea con la convergencia visual de las curvas hacia el *baseline* de la Figura 4.3. Este patrón, unido a la magnitud del efecto absoluto (hasta -14,5 % a  $\epsilon = 0,1$ ), es suficiente para afirmar que la degradación observada bajo Privacidad Diferencial es **grande en términos prácticos**, si bien la confirmación formal de significancia ( $p < 0,05$ ) requeriría más repeticiones —una recomendación metodológica que se recoge a lo largo del Capítulo 5—.





# Capítulo 5

## Conclusiones y futuros trabajos

Este capítulo cierra el estudio sintetizando los hallazgos empíricos del Capítulo 4 y contrastándolos con las hipótesis formuladas en la parte introductoria y traduciéndolos en un conjunto de recomendaciones operativas. A continuación se ofrecen las limitaciones del estudio y se concretan tres líneas de continuación.

### 5.1. Contestación a la Pregunta de Investigación

La pregunta de partida que se formuló en la especificación del TFM era **cuantificar el equilibrio óptimo entre privacidad y utilidad predictiva** en un caso de uso clínico representativo, sin apartarnos de la repercusión sobre la equidad algorítmica y no sobre el riesgo residual frente un posible atacante. Sobre el conjunto de datos *Diabetes 130-US hospitals* y la tarea de predicción de readmisión hospitalaria, los experimentos del Capítulo 4 dejan cuatro contestaciones concretas, cada una de ellas sustentadas empíricamente.

#### 5.1.1. Respuesta 1: la $k$ -anonimidad es casi gratuita

Para los niveles de privacidad sintáctica  $k \in \{2, 5, 10, 25, 50\}$ , los modelos lineales y de *ensemble* (Regresión Logística y Random Forest) mantienen su utilidad predictiva frente al *baseline* con pérdida estadísticamente no significativa (test de McNemar,  $p > 0,05$  para los cinco niveles en el caso de Regresión Logística). El análisis estadístico corrobora lo que ya había sido supuestamente deducido al observar los números: la generalización que efectúa ARX no rompe la frontera de decisión aprendida cuando los modelos utilizan variables clínicas no anonimizadas (medicaciones, número de procedimientos, diagnósticos agrupados).

### 5.1.2. Respuesta 2: la Privacidad Diferencial impone un coste real

La Privacidad Diferencial que implementa `diffprivlib` lo hace siguiendo una curva monótonamente decreciente y el coste en utilidad es significativo en los términos prácticos:  $-14,50\%$  de *Accuracy* a  $\epsilon = 0,1$  y  $-4,05\%$  a  $\epsilon = 1$  en Regresión Logística. La utilidad del *baseline* se recupera del todo sólo a  $\epsilon = 10$ , un nivel que la literatura empieza a considerar de protección moderada. Se trata de una afirmación en conflicto con el enunciado de que la DP puede ser un sustituto directo de la  $k$ -anonimidad: ambas técnicas se centran en problemas distintos y se pagan a distintas tarifas.

### 5.1.3. Respuesta 3: los efectos sobre equidad a la vez son cualitativamente opuestos

El análisis segmentando el subgrupo **race** es probablemente el hallazgo más interesante del texto. Bajo el concepto de  $k$ -anonimidad, se presenta una *Loss Disparity* del subgrupo más favorecido y el menos favorecido, que baja de 0,0498 en el *baseline* a 0,0450 en  $k = 50$ : la generalización asumida hace que las representaciones se homogenicen, y a la inversa se ocurre un efecto beneficioso para los grupos con menos reales. Los grupos minoritarios obtienen los siguientes resultados referidos a su *baseline*: Hispanic  $+2,2\%$  en  $k = 2$ , Other  $+4,8\%$  en  $k = 50$ , y Asian  $+4,3\%$  en  $k = 50$ . Por el contrario, bajo Privacidad Diferencial donde  $\epsilon = 0,1$ , esos mismos grupos minoritarios sufren las pérdidas más fuertes (Hispanic  $-19,70\%$ , Asian  $-17,15\%$  frente a Caucasian con  $-14,26\%$ ), reproduciendo, empíricamente, el patrón ya descrito por Bagdasaryan et al. (Bagdasaryan, Poursaeed y Shmatikov 2019).

### 5.1.4. Respuesta 4: el riesgo basal de membresía es muy bajo

La auditoría adversarial con MIA Black-Box (Sección 4.7) nos confirma que ningún escenario evaluado, incluido el *baseline* sin privacidad, ha reportado una fuga de información de membresía clínicamente significativa. La *Attack Advantage* máxima observada fue de  $+0,033$ , muy por debajo del umbral  $+0,1$  que la literatura suele tomar como un umbral a partir del cual se producen efectivamente pérdidas. Cambia, por tanto, el orden de prioridades del análisis: en un caso de uso como este, donde el modelo no se sobreajusta a la extrema, no hay donde aplicar técnicas de privacidad costosas para protegerse de un ataque de membresía ya tan estudiado.

## 5.2. Marco de Recomendaciones para Aplicaciones de Readmisión Hospitalaria

A partir de las cuatro respuestas anteriores, se establece un conjunto de recomendaciones elaborado para sistemas de clasificación tabular de datos clínicos de perfil similar al de la base de datos estudiada: muestras de decenas de miles de registros, variables objetivo binarias o multiclase poco complejas y un número elevado de variables clínicas no anonimizables. Cualquier extensión hacia otros ámbitos o arquitecturas diferentes debe ser validada de forma específica, como se comentará en la Sección 5.3.

La Figura 5.1 formaliza el árbol de decisión que sintetiza las recomendaciones del trabajo.




Figura 5.1: Árbol de decisión para la selección de técnica de privacidad en aplicaciones de clasificación clínica tabular, derivado empíricamente de los resultados del Capítulo 4.

### 5.2.1. Recomendación 1: aplicar $k$ -anonimidad con $k = 10$ para la publicación de microdatos

Dado que la publicación de microdatos a terceros (intercambios de información entre instituciones sanitarias, repositorios de investigación, conjuntos de datos para *benchmarking*) corresponde con la mejor relación coste/beneficio, de entre los propuestos en este trabajo se obtiene la conclusión de calificar como la mejor el resultado de  **$k$ -anonimidad con  $k = 10$** : la pérdida de utilidad por debajo de 0,6 % de *Accuracy*, el hecho de poder ofrecer protección formal contra ataques de enlace o mejorar marginalmente la equidad demográfica alcanzan el consenso recomendatorio en la literatura sanitaria ([«Secure Data Sharing in Machine Learning: Exploring K-Anonymization and Differential Privacy» 2024](#)) e incluso se encuentra por encima de la exigencia mínima de la  $k = 5$  normalmente asumida para los microdatos médicos.

### 5.2.2. Recomendación 2: reservar la Privacidad Diferencial para escenarios con exigencia regulatoria explícita

La DP toma más sentido cuando el contexto regulatorio o contractual impone la exigencia de contar con una garantía matemática formal contra la inferencia estadística, sin tomar en consideración el modelo de atacante. Para esos casos, los datos de este trabajo muestran indicar que se debe situar el presupuesto en el rango  $\epsilon \in [5, 10]$ : en tal rango, la pérdida esperada de *Accuracy* ronda el 3–5 % y los efectos sobre la equidad siguen siendo llevaderos. Debajo de  $\epsilon = 1$ , la combinación de la pérdida de utilidad y el incremento de la disparidad demográfica deja el modelo fuera del rango aceptable para un uso clínico responsable a no ser que se incorporen medidas de mitigación.

### 5.2.3. Recomendación 3: hacer una auditoría MIA antes de aplicar técnicas costosas

Medir el riesgo basal con un ataque de inferencia de membresía es barato y muy útil. En el caso de que la *Attack Advantage* respecto el *baseline* se mantenga por debajo de 0,05, es posible que el modelo de amenaza realista de este proyecto no justifique también aplicar técnicas de privacidad costosas. En este trabajo la *Advantage* máxima observada fue de +0,033, lo que avala empíricamente la elección de la técnica preferente de  $k$ -anonimidad cuando queda margen para hacerlo.

#### 5.2.4. Recomendación 4: no combinar de forma naïve $k$ -anonimidad con DP

Los resultados de la Sección 4.6 muestran que aplicar DP en cascada sobre datos previamente  $k$ -anonimizados puede hacer que la utilidad se desplome encajonadamente, porque la regularización implícita de la DP combina poco bien con un espacio de características que ha modificado la generalización. Mientras no podamos contar con mecanismos específicamente diseñados para dicha composición (por ejemplo, DP-SGD calibrado en el espacio post-anonimización), **lo razonable es elegir una de las dos técnicas** en función del modelo de amenaza, no aplicarlas en serie.

### 5.3. Limitaciones del Estudio

Las conclusiones anteriormente expuestas son válidas dentro del ámbito experimental de la investigación realizada. No obstante, han de tomarse en consideración las siguientes limitaciones si uno pretende interpretar o extrapolar dicho contenido.

#### 5.3.1. Alcance de las técnicas evaluadas

El estudio se ha concentrado en las técnicas más representativas de cada eje del paradigma de privacidad:  $k$ -anonimidad con criterio sintáctico, Privacidad Diferencial global con `diffprivlib` y MIA *Black-Box* con ART. El Capítulo 2 introduce además extensiones de la privacidad sintáctica ( $l$ -diversidad,  $t$ -cercanía), paradigmas colaborativos (Aprendizaje Federado, Computación Segura Multiparte) y métricas adicionales de equidad (Paridad Demográfica) que no se han evaluado empíricamente. Esa exclusión obedece a tres motivos. Primero, el alcance temporal acotado del TFM. Segundo, requisitos de datos no satisfechos por este *dataset*: el Aprendizaje Federado requiere múltiples silos de datos institucionales, y la Privacidad Diferencial Local necesita millones de registros para que la señal estadística sobreviva al ruido. Y tercero, una decisión metodológica deliberada: profundizar en dos técnicas comparables antes que cubrir cuatro o cinco de manera superficial.

#### 5.3.2. Generalización a otros conjuntos de datos y dominios

Los experimentos realizados han tenido lugar sobre un único conjunto de datos clínico, por lo que no podríamos afirmar que el comportamiento observado se pueda transferir tal cual a otros dominios sanitarios (oncología, salud mental, urgencias) o a otros sectores regulados (finanzas, educación). Si bien los diferentes atributos del conjunto de datos seleccionado (volumen, dimensionalidad, proporción de variables sensibles) son los típicos de la práctica clínica, replicar la investigación usando conjuntos de datos complementarios es necesario antes de elevar las recomendaciones a guía sectorial.

### 5.3.3. Familias algorítmicas analizadas

El *benchmarking* se ha restringido a cuatro modelos tradicionales de *Machine Learning*: Regresión Logística, Random Forest, Árbol de Decisión y Naive Bayes Gaussiano. Es importante señalar que el rendimiento de las redes neuronales profundas en comparación con estas técnicas de privacidad puede variar considerablemente, sobre todo en el caso de DP-SGD, donde el optimizador se relaciona de manera particular con la geometría de los gradientes. La posibilidad de ampliar el estudio para incluir redes neuronales, en especial arquitecturas como *Tabular Transformer* o *TabNet*, se presenta como una línea para futura investigación.

### 5.3.4. Limitaciones de la herramienta de DP utilizada

La librería `diffprivlib` en su versión 0,6,6 aplica la Privacidad Diferencial a través de *output perturbation* con regularización constante. Si bien esta elección es matemáticamente válida, ha resultado en un comportamiento inesperado al combinar DP con  $k$ -anonimidad en el espacio OHE expandido. El uso de mecanismos que se basan en DP-SGD, como `Opacus`, o en *objective perturbation* con regularización adaptable podría brindar un comportamiento más claro y comprensible en escenarios de defensa en profundidad.

### 5.3.5. Tamaño muestral del análisis diferencial

El barrido de Privacidad Diferencial se llevó a cabo con cinco repeticiones por cada punto. Este número de repeticiones es adecuado para estimar la media y la desviación estándar con una cierta robustez, aunque no es suficiente para lograr una significancia estadística estricta en el test de Wilcoxon de una muestra. Aumentar el número de repeticiones a  $n = 20$  permitiría establecer significancia formal y disminuir las bandas de error en los puntos más ruidosos del análisis.

### 5.3.6. Modelo de atacante en la auditoría MIA

El ataque de membresía implementado es de tipo *Black-Box*, utilizando un clasificador de pertenencia como Random Forest, siguiendo la metodología estándar de Shokri et al. (Shokri et al. 2017). Atacantes más avanzados, que utilicen *Likelihood Ratio Tests* o modelos sombra entrenados en distribuciones similares, podrían identificar fugas de información que este ataque no logra detectar. La auditoría exhaustiva del riesgo residual frente a toda la gama de ataques de membresía representa una línea de investigación complementaria a considerar.

## 5.4. Líneas Futuras de Investigación

A partir de los resultados alcanzados y de las limitaciones que hemos expuesto antes, planteo tres líneas de continuación concretas, organizadas en orden de importancia y en la medida en que cierran los problemas que han quedado abiertos de la investigación.

### 5.4.1. Línea 1: DP-SGD con Opacus sobre redes neuronales tabulares

La principal limitación técnica del trabajo —el colapso de la combinación  $k$ -anonimidad + DP en Regresión Logística— tiene con que continuar de manera natural: sustituir la *output perturbation* de `diffprivlib` por DP-SGD con Opacus (Meta AI 2020) sobre una red neuronal tabular. DP-SGD hace injerto directamente el ruido sobre los gradientes durante el entrenamiento, sin imponer la regularización fija sobre los pesos finales que es detrás del problema que hemos descrito. Esta línea abre varios frentes interesantes:

- Indagar arquitecturas profundas que sean capaces de captar interacciones no lineales entre los componentes y las variables clínicas.
- Tender un hilo conductor metodológico hacia modelos de lenguaje médico, donde el DP-SGD es la herramienta de privacidad estandarizada.

La integración con la fase ARX existente debería ser sencilla: solamente sería necesario adaptar el *pipeline* de la carga.

### 5.4.2. Línea 2: generación de datos sintéticos diferencialmente privados utilizando CTGAN

La taxonomía del Capítulo 2 sitúa la generación de datos sintéticos como tercer eje del paradigma de privacidad, junto a la  $k$ -anonimidad y la privacidad diferencial. En la guía metodológica destaco CTGAN (Xu et al. 2019) como técnica especializada para datos tabulares mixtos. Aplicarla sobre el mismo *dataset* clínico permitiría:

- Ser capaces de cuantificar la fidelidad estadística de los conjuntos sintéticos frente a los originales a partir de métricas como el *Train Synthetic Test Real* (TSTR).
- Auditar el riesgo de membresía sobre el modelo generativo — una pregunta crítica para validar la sintetización como mecanismo de privacidad, según la literatura más reciente («Differentially Private Synthetic Data Enables Public Release of Behavioral Health Information with High Utility» 2025).
- Comparar la curva privacidad-utilidad de la sintetización con las dos técnicas atender a las que hemos evaluado en el transcurso de este trabajo.

La biblioteca SDV (Patki, Wedge y Veeramachaneni 2016) pone a disposición la implementación de estas técnicas y gracias a su interfaz uniforme facilita mucho esta extensión.

### 5.4.3. Línea 3: validación externa y árbol de decisión refinado

Las recomendaciones de este marco propuesto, para que sean generalizables, deberían validarse contra los resultados de, al menos, dos conjuntos de datos sanitarios alternativos: uno con perfil oncológico (alta sensibilidad de los atributos sensibles) y otro con perfil de urgencias (alta proporción de valores raros y *outliers*), que ayudarían a llevar a cabo un refinamiento del árbol de decisión incorporando los resultados de estas validaciones junto a criterios cuantitativos para la selección automatizada del *fairness* como resultado de la optimización bayesiana. Concebir el marco de referencia que obtendríamos a partir de esta propuesta de investigación sería conseguir agregar un marco de referencia que podría resultar útil para la comunidad de la ciencia de datos para la implementación de modelos predictivos en entornos sanitarios regulados.

## 5.5. Reflexión Final

El TFM partía de una pregunta que en principio parecía sencilla: ¿cuánta utilidad hay que sacrificar para proteger la privacidad de los pacientes en un sistema de predicción de readmisión hospitalaria? Los datos experimentales muestran que la respuesta es bastante más matizada que la dicotomía que suele aparecer en la literatura. En este caso de uso concreto, la *k*-anonimidad protege de forma sustantiva a cambio de menos del 0,6 % de *Accuracy*; la Privacidad Diferencial, en cambio, tiene un coste explícito que solo merece la pena cuando hay una exigencia regulatoria o contractual de garantía matemática formal. Y la equidad demográfica no es un detalle secundario: las dos técnicas tienen efectos opuestos sobre los grupos minoritarios, y esa diferencia importa.

Más allá de los números, lo que aporta este trabajo es una forma reproducible de medir ese compromiso en cualquier caso de uso parecido. Las herramientas, los *notebooks* y los resultados que se publican con esta memoria buscan que esa evaluación se haga por defecto en cualquier proyecto de inteligencia artificial responsable, en línea con lo que pide la Ley de IA de la Unión Europea ([Reglamento \(UE\) 2024/1689 2024](#)) y el Reglamento General de Protección de Datos ([Reglamento \(UE\) 2016/679 2016](#)).



# Bibliografía

- Abadi, Martin et al. (2016). «Deep Learning with Differential Privacy». En: *Proceedings of the 2016 ACM SIGSAC Conference on Computer and Communications Security (CCS)*. ACM, págs. 308-318. DOI: [10.1145/2976749.2978318](https://doi.org/10.1145/2976749.2978318).
- Argyriou, Vasileios et al. (2025). «Quantitative Metrics for Balancing Privacy and Utility in Pseudonymized Big Data». En: *Electronics* 14.21, pág. 4350. DOI: [10.3390/electronics14214350](https://doi.org/10.3390/electronics14214350).
- Bagdasaryan, Eugene, Omid Poursaeed y Vitaly Shmatikov (2019). «Differential Privacy Has Disparate Impact on Model Accuracy». En: *Advances in Neural Information Processing Systems* 32.
- Benchmarking Differential Privacy Optimizers* (2024). URL: <https://helda.helsinki.fi/server/api/core/bitstreams/62f20dfb-058d-48c6-a84d-a039a01d3eb2/content>.
- «Differentially Private and Adversarially Robust Machine Learning: An Empirical Evaluation» (2024). En: *arXiv preprint arXiv:2401.10405*. URL: <https://arxiv.org/abs/2401.10405>.
- «Differentially Private Synthetic Data Enables Public Release of Behavioral Health Information with High Utility» (2025). En: *arXiv preprint arXiv:2507.02971*. URL: <https://arxiv.org/abs/2507.02971>.
- Dwork, Cynthia (2006). «Differential Privacy». En: *International Colloquium on Automata, Languages, and Programming (ICALP)*. Springer, págs. 1-12. DOI: [10.1007/11787006\\_1](https://doi.org/10.1007/11787006_1).
- Dwork, Cynthia et al. (2006). «Calibrating Noise to Sensitivity in Private Data Analysis». En: *Theory of Cryptography Conference (TCC)*. Springer, págs. 265-284. DOI: [10.1007/11681878\\_14](https://doi.org/10.1007/11681878_14).
- «Empirical Analysis of Privacy-Fairness-Accuracy Trade-offs in Federated Learning» (2025). En: *arXiv preprint arXiv:2503.16233*. URL: <https://arxiv.org/abs/2503.16233>.
- Galileo AI (2025). *How Membership Inference Attacks Expose AI Data*. URL: <https://galileo.ai/blog/membership-inference-attacks>.
- Goodfellow, Ian et al. (2014). «Generative Adversarial Nets». En: *Advances in Neural Information Processing Systems* 27.
- Holohan, Naoise et al. (2019). «Diffprivlib: The IBM Differential Privacy Library». En: *arXiv preprint arXiv:1907.02444*. URL: <https://arxiv.org/abs/1907.02444>.

- Hu, Yuanzhe et al. (2020). «Explainable Multi-class Classification of Medical Data». En: *arXiv preprint arXiv:2012.13796*. URL: <https://arxiv.org/abs/2012.13796>.
- Iyengar, Vijay S. (2002). «Transforming Data to Satisfy Privacy Constraints». En: *Proceedings of the 8th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, págs. 279-288. DOI: [10.1145/775047.775089](https://doi.org/10.1145/775047.775089).
- Kohlmayer, Florian et al. (2012). «Flash: Efficient, Stable and Optimal  $K$ -Anonymity». En: *2012 ASE/IEEE International Conference on Privacy, Security, Risk and Trust*. IEEE, págs. 708-717. DOI: [10.1109/SocialCom-PASSAT.2012.52](https://doi.org/10.1109/SocialCom-PASSAT.2012.52).
- Labelia Labs (2024). *Going Differentially Private: techniques and tools of the trade*. URL: <https://www.labelia.org/en/blog/going-differentially-private>.
- LeFevre, Kristen, David J. DeWitt y Raghu Ramakrishnan (2006). «Mondrian Multidimensional  $K$ -Anonymity». En: *22nd International Conference on Data Engineering (ICDE'06)*. IEEE, págs. 25-25. DOI: [10.1109/ICDE.2006.101](https://doi.org/10.1109/ICDE.2006.101).
- Li, Ninghui, Tiancheng Li y Suresh Venkatasubramanian (2007). « $t$ -Closeness: Privacy Beyond  $k$ -Anonymity and  $l$ -Diversity». En: *2007 IEEE 23rd International Conference on Data Engineering*. IEEE, págs. 106-115. DOI: [10.1109/ICDE.2007.367856](https://doi.org/10.1109/ICDE.2007.367856).
- Linux Foundation AI & Data (2018). *Adversarial Robustness Toolbox (ART)*. URL: <https://github.com/Trusted-AI/adversarial-robustness-toolbox>.
- Liu, Yiding et al. (2024). «Comparative evaluation of machine learning models for predicting hospital readmission of diabetic patients». En: *Journal of Medical Artificial Intelligence*. URL: <https://jmai.amegroups.org/article/view/9179>.
- Machanavajjhala, Ashwin et al. (2007). « $l$ -Diversity: Privacy Beyond  $k$ -Anonymity». En: vol. 1. 1. ACM, 3-es. DOI: [10.1145/1217299.1217302](https://doi.org/10.1145/1217299.1217302).
- McMahan, Brendan et al. (2017). «Communication-Efficient Learning of Deep Networks from Decentralized Data». En: *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS)*. PMLR, págs. 1273-1282.
- «Membership Inference Attacks Against Synthetic Health Data» (2022). En: *Journal of the American Medical Informatics Association*. DOI: [10.1093/jamia/ocab273](https://doi.org/10.1093/jamia/ocab273). URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC8766950/>.
- Meta AI (2020). *Opacus: Train PyTorch models with Differential Privacy*. URL: <https://opacus.ai/>.
- «Modeling and Evaluation of  $k$ -anonymization Metrics» (2020). En: *AAAI Workshop on Privacy-Preserving Artificial Intelligence (PPAI)*. URL: [https://www2.isye.gatech.edu/~fferdinando3/cfp/PPAI20/papers/paper\\_18.pdf](https://www2.isye.gatech.edu/~fferdinando3/cfp/PPAI20/papers/paper_18.pdf).
- Patki, Neha, Roy Wedge y Kalyan Veeramachaneni (2016). *The Synthetic Data Vault*. DOI: [10.1109/DSAA.2016.49](https://doi.org/10.1109/DSAA.2016.49).
- Prasser, Fabian y Florian Kohlmayer (2015). «Putting Statistical Disclosure Control into Practice: The ARX Data Anonymization Tool». En: *Medical Data Privacy Handbook*. Springer, págs. 111-148. DOI: [10.1007/978-3-319-23633-9\\_6](https://doi.org/10.1007/978-3-319-23633-9_6).

- «Privacy-preserving machine learning: a review of federated learning techniques and applications» (2025). En: *Frontiers in Big Data*. DOI: [10.3389/fdata.2025.1517985](https://doi.org/10.3389/fdata.2025.1517985). URL: <https://www.researchgate.net/publication/388822437>.
- «Privacy, Utility and Fairness: Navigating Trade-offs in Differentially Private Machine Learning» (2025). En: *Proceedings of the AAAI Conference on Artificial Intelligence*. URL: <https://ojs.aaai.org/index.php/AAAI/article/view/35205>.
- Provably Private Data Anonymization: Or, k-Anonymity Meets Differential Privacy* (2010). Inf. téc. CERIAS, Purdue University. URL: [https://www.cerias.purdue.edu/assets/pdf/bibtex\\_archive/2010-24-report.pdf](https://www.cerias.purdue.edu/assets/pdf/bibtex_archive/2010-24-report.pdf).
- Reglamento (UE) 2016/679* (2016). Diario Oficial de la Unión Europea, L 119, 4 de mayo de 2016.
- Reglamento (UE) 2024/1689* (2024). Diario Oficial de la Unión Europea, L, 12 de julio de 2024.
- «Secure Data Sharing in Machine Learning: Exploring K-Anonymization and Differential Privacy» (2024). En: *Journal of Information Systems Engineering and Management*. DOI: [10.55267/iadt.07.15198](https://doi.org/10.55267/iadt.07.15198). URL: <https://jisem-journal.com/index.php/journal/article/download/1198/456>.
- Shokri, Reza et al. (2017). «Membership Inference Attacks Against Machine Learning Models». En: *2017 IEEE Symposium on Security and Privacy (SP)*. IEEE, págs. 3-18. DOI: [10.1109/SP.2017.41](https://doi.org/10.1109/SP.2017.41).
- Strack, Beata, Jonathan DeShazo et al. (2014). *Diabetes 130-US hospitals for years 1999-2008*. UCI Machine Learning Repository. DOI: <https://doi.org/10.24432/C5230J>.
- Strack, Beata, Jonathan P. DeShazo et al. (2014). «Impact of HbA1c Measurement on Hospital Readmission Rates: Analysis of 70,000 Clinical Database Patient Records». En: *BioMed Research International* 2014, pág. 781670. DOI: [10.1155/2014/781670](https://doi.org/10.1155/2014/781670).
- Sweeney, Latanya (2002). «k-Anonymity: A Model for Protecting Privacy». En: vol. 10. 05. World Scientific, págs. 557-570. DOI: [10.1142/S0218488502001648](https://doi.org/10.1142/S0218488502001648).
- Synthetic Data – what, why and how?* (2024). Inf. téc. The Royal Society. URL: [https://royalsociety.org/-/media/policy/projects/privacy-enhancing-technologies/Synthetic\\_Data\\_Survey-24.pdf](https://royalsociety.org/-/media/policy/projects/privacy-enhancing-technologies/Synthetic_Data_Survey-24.pdf).
- Xu, Lei et al. (2019). «Modeling Tabular Data using Conditional GAN». En: *Advances in Neural Information Processing Systems* 32.